

北部湾近岸海域有害藻华预测及其原因种 监测方法研究

**Study on the Prediction of Harmful Algal Blooms and Monitoring
Method for Their Causative Species in the Coastal Area of Beibu
Gulf**

摘要

有害藻华是一种典型的海洋生态灾害，对生态环境、经济发展、公共卫生，以及人类健康构成严重威胁。近年来，我国南海北部湾近岸海域有害藻华的发生频率、爆发规模，以及持续时间呈明显上升趋势，主要原因种包括蓝藻、甲藻、硅藻，以及球形棕囊藻等。长期的环境监测和研究表明，气候变化引起的水温上升和水体富营养化导致的营养结构改变是有害藻华扩张的主要驱动因素。然而，目前对有害藻华形成的关键环境因素识别及其预测方法的研究仍较为匮乏，常规方法难以对球形棕囊藻等异养藻类的生物量实现有效监测。本研究基于我国沿海有害藻华区域性、非线性、随机性，以及原因种多样性等特征，对南海北部湾近岸海域环境要素的时空分布特征进行分析，采用机器学习方法对藻华生消的主要环境因子进行了特征选择，并以环境因子作为特征变量建立了基于逻辑回归的“藻华/常态”分类预测模型，探讨了提高有害藻华预测能力的必要条件。针对常规方法难以监测的特殊藻种，提出了基于计算机视觉的技术框架，为实现有害藻类生物量的监测提供了一种有效方案。

本研究以叶绿素 a 浓度作为衡量有害藻华风险的定量指标，采用空间插值与相关性分析方法揭示了环境要素的时空分布特征，并利用随机森林回归算法评估了环境因子对叶绿素 a 浓度影响的特征重要性，对藻华预测所需的关键特征变量进行了筛选，发现了北部湾海域藻华发生前营养盐动态变化的信号特征。研究结果表明，水温、无机态营养盐，和盐度是影响北部湾近岸海域叶绿素 a 浓度变化的主要因素。其中，水温对藻华风险的影响最为显著，研究区域内藻类的最佳生长温度在 30—32 °C 之间；盐度也是影响叶绿素 a 浓度另一重要因素，22—28 psu 的“中盐度”条件是研究区域内藻类生长的最适盐度范围。分析结果表明，当海水环境条件同时符合高营养水平、高水温，以及中盐度中任意两个条件时，有害藻华风险将显著升高，月均叶绿素 a 浓度将由 3—4 $\mu\text{g}\cdot\text{L}^{-1}$ 上升至 10 $\mu\text{g}\cdot\text{L}^{-1}$ 左右。此外，无机态营养盐浓度在 24 小时内出现大幅度下降是预测藻华爆发的重要信号，而适宜的水温或盐度条件能够将两者之间的间隔缩短至 4 小时以内。

针对藻华爆发过程中表现出的非线性与随机性特征，本研究提出了基于关键特征变量的有害藻华分类预测方法，建立了逻辑回归二分类预测模型，采用该模型对不同案例进行了预测，探讨了营养盐吸收和原因种差异等因素对预测结果的影响。研究结果表明，模型的预测准确率最高可达 88.6%，不同原因种对营养盐

的吸收偏好差异是影响藻华预测精度的主要因素。其中，蓝绿藻藻华对硝氮和活性磷酸盐的吸收都较为显著，预测精确率相对较高，至少达 70%；球形棕囊藻藻华对硝氮的吸收显著，但对活性磷酸盐的吸收不显著，预测精确率为 60.78%；中肋骨条藻藻华对硝氮和活性磷酸盐的吸收都不显著，预测精确率相对较低，仅为 50%。研究表明，通过掌握藻华原因种的生物量信息，进而明确其优先吸收的营养盐类型，是提升有害藻华预测能力的必要条件之一。

针对常规方法难以有效监测异养藻类生物量的问题，本研究提出了以水下显微成像—图像处理—目标检测为基础的技术框架，以球形棕囊藻作为监测目标开展了实验研究。结果表明，该框架在识别藻类方面表现出良好的性能。在暗场照明拍摄的图像中，YOLOv8 目标检测模型能够将形态特征相近的球形棕囊藻和小球藻属之间的误检率限制在接近 0%。在图像处理环节，自适应色阶对比度算法放大了图像中藻类之间的颜色差异并消除了图像中的虚焦干扰，提高了模型对藻类检测的精确率。随后的暗通道先验算法有效去除了图像的背景散射，降低了模型漏检率。最终使得 YOLOv8 目标检测模型对球形棕囊藻的识别精确率从 74% 提高到 91%。

关键词：有害藻华，环境因子，藻华预测，原因种，目标检测

ABSTRACT

Harmful algal blooms are a prevalent ecological disaster in marine environments, causing immeasurable damage to the local ecology, economy, and public health. In recent years, the frequency, scale, and duration of harmful algal blooms in the coastal areas of the Beibu Gulf, South China Sea, have increased significantly. The main causative species include *cyanobacteria*, *dinoflagellates*, diatoms, and *Phaeocystis globosa*. Long-term environmental monitoring and studies have shown that rising water temperatures caused by climate change, as well as alterations in nutrient composition due to eutrophication, are the main drivers of the expansion of harmful algal blooms. However, there is still a lack of research on identifying key environmental factors and making predictions for harmful algal blooms. Traditional methods are also inadequate to effectively monitoring the biomass of heterotrophic algae such as *Phaeocystis globosa*. Based on the characteristics of regionality, nonlinearity, randomness, and diversity of causative species, this study analyzes the spatio-temporal distribution characteristics of environmental factors in the coastal areas of the Beibu Gulf, South China Sea. The feature selection of the key environmental factors affecting algal blooms is carried out using machine learning methods, and a logistic regression-based "bloom/normal" classification prediction model is established with these environmental factors as feature variables, which discusses the essential conditions for enhancing the capability of harmful algal bloom prediction. For special algae that are difficult to monitor by conventional methods, a technological framework based on computer vision is proposed, presenting an effective solution for monitoring the biomass of harmful algae.

In this study, the chlorophyll-a concentration is used as a quantitative index to measure the risk of harmful algal blooms. Spatial interpolation and correlation analysis are used to reveal the spatial-temporal distribution characteristics of environmental factors. Random forest regression is utilized to assess the importance of environmental factors on the chlorophyll-a concentration to select the key characteristic variables required for algal bloom prediction. The signal of nutrient dynamic changes before algal blooms in the Beibu Gulf are identified. The results

show that water temperature, inorganic nutrients, and salinity are the main factors affecting chlorophyll-a concentration in the coastal areas of the Beibu Gulf. The influence of water temperature on the risk of algal blooms is the most significant. The optimum temperature of algal blooms in the study area is between 30—32 °C. Salinity is another important factor affecting chlorophyll-a concentration, and the salinity range of 22—28 psu, referred to as "medium salinity," is optimal for algal growth in the study area. The results show that the risk of harmful algal blooms would increase significantly, and the monthly average chlorophyll-a concentration would rise from 3—4 $\mu\text{g}\cdot\text{L}^{-1}$ to about 10 $\mu\text{g}\cdot\text{L}^{-1}$ when the environmental conditions meet any two of the following: high nutrient level, warm temperature, and medium salinity. In addition, a significant decrease in the concentration of inorganic nutrients within 24 hours is an important indicator for predicting algal blooms, and the appropriate temperature or salinity conditions can shorten the interval between these events to less than 4 hours.

Considering the nonlinearity and randomness of algae blooms, this study proposes an algal bloom prediction method based on key characteristic variables. Logistic regression classification prediction models are established to predict algal blooms in different cases, and the effects of nutrient absorption and species differences on the prediction results are discussed. The results show that the model accuracy rate can reach 88.6%. Variations in nutrient absorption preferences among different causative species is one of the main factors affecting the precision of algal bloom prediction. Among them, blue-green algae blooms have significant absorption of $\text{NO}_{2,3}^{-}\text{-N}$ and Ortho-P; the prediction precision is relatively high, reaching at least 70%. *Phaeocystis globosa* blooms have significant absorption of $\text{NO}_{2,3}^{-}\text{-N}$, but not outstanding in Ortho-P; the prediction precision is 60.78%. *Skeletonema costatum* blooms have non-significant absorption of both $\text{NO}_{2,3}^{-}\text{-N}$ and Ortho-P; the prediction precision is relatively low, only 50%. Studies show that comprehending the biomass information of algae species and clarifying the nutrient types absorbed by their blooms are necessary conditions for improving the capability of harmful algal bloom prediction.

Given the challenges associated with monitoring heterotrophic algae biomass using conventional methods, this study proposes a technical framework integrates underwater microscopic imaging, image processing, and object detection to conduct experimental research with *Phaeocystis globosa* as the target species for monitoring. The results indicate that the proposed framework exhibits favorable performance in

recognizing different types of algae. In the images captured by dark field illumination, the YOLOv8 object detection model can limit the false detection rate between *Phaeocystis globosa* and *Chlorella*, which have similar morphologies, to close to 0%. In the image processing, adaptive contrast enhancement amplifies the color discrepancies among algae and eliminates virtual focus interference, thus improving precision of algae classification. Subsequently, dark channel prior reduces the noise caused by image scattering and limits missed detection. Consequently, the precision of *Phaeocystes globosa* recognition using the YOLOv8 model is increased from 74% to 91%.

KEY WORDS: Harmful Algal Blooms, Environmental Factors, Algal Bloom Prediction, Causative Species, Object Detection

目 录

第 1 章 绪论	1
1.1 研究背景与意义	1
1.2 研究综述	4
1.2.1 藻华动态的控制因素	4
1.2.2 藻华爆发的预测方法	6
1.2.3 藻华及其原因种监测方法	8
1.2.4 存在的问题	11
1.3 研究内容	12
第 2 章 北部湾近岸海域环境要素时空分布特征	15
2.1 引言	15
2.2 研究数据与方法	15
2.2.1 研究区域范围及概况	15
2.2.2 研究数据获取及处理	17
2.2.3 环境要素的空间插值	18
2.2.4 环境要素相关性分析	19
2.3 结果与讨论	19
2.3.1 环境要素的年际空间分布特征	19
2.3.2 时间序列下的环境要素相关性	25
2.3.3 藻华高发区域的综合环境特征	33
2.3.4 引起有害藻华爆发的前提条件	33
2.4 本章小结	35
第 3 章 影响藻华动态变化的环境因子特征选择	37
3.1 引言	37
3.2 研究数据与方法	37
3.2.1 藻华研究案例的选取	37
3.2.2 环境特征重要性评估	38
3.2.3 环境因子的初步筛选	39
3.3 结果与讨论	39
3.3.1 藻华动态的环境因子特征识别	39
3.3.2 引发藻华事件的最适温盐条件	45

3.3.3 藻华爆发的关键信号特征提取	47
3.3.4 藻华预测模型的特征变量选取	50
3.5 本章小结	50
第 4 章 基于环境因子的有害藻华预测及其原因种特征	53
4.1 引言	53
4.2 研究数据与方法	53
4.2.1 北部湾有害藻华历史记录	53
4.2.2 藻华/常态二分类预测方法	54
4.2.3 蓝绿藻分布及优势种判定	56
4.3 结果与讨论	57
4.3.1 基于环境因子特征的藻华预测	57
4.3.2 环境因素对藻华发生率的影响	66
4.3.3 藻华事件的蓝绿藻优势种判定	67
4.3.4 原因种差异对预测结果的影响	71
4.4 本章小结	71
第 5 章 基于水下显微成像的有害藻华原因种监测方法研究	73
5.1 引言	73
5.2 材料与方法	74
5.2.1 水槽实验样品显微观察	74
5.2.2 水下显微成像装置搭建	76
5.2.3 水下图像增强与去散射	79
5.2.4 YOLOv8 目标检测模型	80
5.3 结果与讨论	83
5.3.1 水下显微成像的藻类图像特征	83
5.3.2 水下图像优化处理及视觉评估	83
5.3.3 目标检测模型训练及性能评估	92
5.3.4 藻华原因种水下监测功能测试	94
5.4 本章小结	97
第 6 章 结论与展望	99
6.1 结论	99
6.2 创新点	100
6.3 展望	101
参考文献	103
附录	117

附录 A 补充列表	117
附录 B YOLOv8 模型训练与测试结果	118
发表论文和参加科研情况说明	125
致谢	127

第1章 绪论

1.1 研究背景与意义

藻类是一类具有光合作用能力的原生生物，它们主要分布在海洋、江河，以及湖泊等水环境中，是地球上初级生产力的重要组成部分^[1]。然而，水环境中部分有害藻类（如蓝藻、甲藻等）迅速繁殖形成的高密度聚集现象会演变成有害藻华（Harmful Algal Blooms, HABs）事件，对当地生态系统、经济活动，以及人类健康安全产生负面影响。在海洋环境中，有害藻华是一类典型的海洋生态灾害，主要包括由微藻引发的“赤潮（Red tide）^[2]”和“褐潮（Brown tide）^[3]”，以及由大型藻引发的“绿潮（Green tide）^[4]”和“金潮（Golden tide）^[5]”（图 1-1）。有害藻华原因种（Causative Species）主要包括分布在淡水与河口系统中的蓝绿藻（blue-green algae），以及近岸海域的硅藻（diatom）、甲藻（dinoflagellate）、针胞藻（raphidophyte）和海金藻（pelagophyceae）等。有害藻华的形成是由于人类活动排放的污染物引起的水体富营养化，在水温、盐度、光照等其他条件适宜的情况下，导致水生藻类、细菌或浮游生物在短时间内过度增殖^[1-5]。自 1970 年以来，全球有害藻华事件的发生频率、爆发强度，以及影响范围均有所上升^[6]，现已成为水环境领域内最引人关注的议题之一。

有害藻华事件的频发会对当地社会造成重大危害，包括商业、休闲渔业、水产养殖、沿海旅游以及人类健康安全^[2]。藻华爆发期间大量的藻类聚集在海表面会导致水体变色^[7]，阻碍阳光的穿透从而抑制水下植物的光合作用，造成生长停滞甚至死亡，严重影响海洋生态系统食物链的平衡^[8]。同时，有害藻华产生的藻毒素会污染海产品，对公众的健康安全构成潜在风险^[9-11]。根据原因种藻类的特点，可将有害藻华分为三大类^[12]：第一类为无毒但间接有害的藻华，藻类自身不会直接对海洋生态系统或养殖业造成危害，但在其消亡过后的残骸分解过程中会大量消耗水体中的氧气，造成水体低氧或缺氧，间接造成海洋生物大量死亡；第二类为无毒但直接有害的藻华，藻类自身对人体无害，但会对鱼类和无脊椎动物构成直接危害，例如黏附在鱼类的鳃部导致其窒息死亡，从而直接对养殖业造成巨大损失；第三类为有毒且直接有害的藻华，藻类自身会产生有毒物质，如链状裸甲藻（*Gymnodinium catenatum*）产生的麻痹性贝类毒素（Paralytic shellfish poisoning）会通过食物链逐级传递，直接威胁人类健康。此外，一些藻华原因种

如亚历山大藻 (*Alexandrium fundyense*) 在爆发期间不会有很高的细胞密度也不会使海水变色, 但其产生的毒素会直接对人类以及海洋生物构成危害。




图 1-1 国内外近岸海域有害藻华现场照片: (a) 卡伦氏贝氏藻 (*Karenia brevis*) 引发的美国佛罗里达沿海赤潮^[2]; (b) 抑食金球藻 (*Aureococcus anophagefferens*) 引发的渤海近岸褐潮^[3]; (c) 浒苔 (*Ulva prolifera*) 引发的江苏沿海绿潮^[4]; (d) 长囊水云 (*Ectocarpus siliculosus*) 引发的都柏林湾金潮^[5]

中国近海是有害藻华的高发区域, 藻华事件的频发对当地经济发展、生态安全以及人类健康造成极大负面影响^[13]。北部湾是位于我国南海西北部的半封闭海湾, 平均水深约 38 m, 年均气温 21—23 °C^[14], 属亚热带海洋性季风气候, 全年高温且旱季和雨季明显, 夏季高温多雨, 冬季温和少雨^[15]。近年来, 由于气候变暖和水体富营养化等问题, 北部湾近岸海域有害藻华的发生频率、持续时间和规模均呈明显增加趋势^[16]。由于三面环陆, 北部湾近岸海域的水交换能力较差, 使得河流径流输入的大量有机物和无机盐富集, 富营养化水平常年居高不下^[17]。受气候变化和水体富营养化等问题的影响, 北部湾近岸海域有害藻华呈现出多样性特征, 主要原因种从蓝藻、甲藻, 和硅藻转变为球形棕囊藻 (*Phaeocystis globosa*)^[16]。1997 年 10 月, 广东柘林湾首次观测到球形棕囊藻藻华, 全覆盖面积高达 1000 平方公里, 直接经济损失超过 6500 万元^[18]。如今, 球形棕囊藻已从我国当初的

“藻华新记录种”转变为“藻华常见种”，成为我国沿海地区常见的有害藻华原因种之一^[19]。区别于世界上其他海域的棕囊藻藻华，我国的同类藻华具有囊体直径大（直径可达厘米级）、毒性强，以及危害范围广等鲜明特点^[20]。自2011年以来，我国南海北部湾近岸海域屡次遭受球形棕囊藻有害藻华的危害（如图1-2所示）^[21,22]，不仅会对当地生态环境造成极大破坏，还会对沿海核电站的冷源系统等重要公共设施的运行安全构成严重威胁^[23]。2014年12月，广西防城港核电站一期工程发生一起球形棕囊藻藻华事件^[24-28]，核电站冷源取水口附近海域内发现大量漂浮的球形棕囊藻囊体，导致冷源取水口堵塞并造成核电站被迫停机4天，直到清除大部分囊体后才恢复发电^[29]。




图 1-2 北部湾近岸海域有害藻华现场照片^[21]：(a) 球形棕囊藻藻华现场海表面拍摄；
(b) 球形棕囊藻囊体水下拍摄；(c) 球形棕囊藻单细胞显微镜拍摄。

综上所述，基于北部湾近岸海域的环境特征对有害藻华问题实行有效的防控措施，对减轻和避免藻华事件对当地社会、经济和公共安全造成负面影响具有重要意义。因此，有必要对影响北部湾近岸海域有害藻华动态变化的关键控制因素等问题进行深入研究，并探讨科学有效的藻华预测方法。这需要对近岸海域有害藻华的主要控制因素、形成机制，以及原因种特征等问题实现进一步的认识。

1.2 研究综述

1.2.1 藻华动态的控制因素

有害藻华的动态变化受多种因素影响,包括物理、化学、生物、水动力,以及原因种类型等^[30]。其中,水体富营养化和气候变暖等综合影响是导致近年来近岸海域有害藻华频发的主要驱动因素。

(一) 富营养化

藻类在生长繁殖过程中需要吸收多种营养物质,其中无机盐的浓度和组成结构是影响藻华动态的重要因素^[31]。多项调查研究表明,人类活动引起的水体富营养化和营养结构改变等环境问题是造成近年来近岸海域有害藻华频发的主要因素之一^[11]。Li 等人^[32]利用地理信息系统 (Geographic Information System, GIS) 和统计学方法,分析了黄海 1972—2017 年间的 165 个赤潮数据集和 2008—2017 年间的绿潮数据集。研究发现,因甲藻爆发导致的赤潮在发生频率、规模、季节分布、空间覆盖率等多个方面均呈上升趋势,该趋势与当地水体富营养化、养殖业发展以及周期性大范围爆发的绿潮密切相关。然而, Hallegraeff^[6]认为,除水体中营养盐的含量以外,营养盐成分比例的变化也会影响浮游藻类的生长速率和群落结构,因此单方面地减少营养物排放对解决藻华问题存在相当大的不确定性。Redfield 等人^[33]提出,浮游藻类的 C:N:P 摩尔比值约为 106:16:1,该比值也称作雷德菲尔德化学计量比 (Redfield ratio),是目前评估水体营养盐对当地生态结构影响的重要参照。在浮游植物生长繁殖的过程中,营养成分通常会按照雷德菲尔德比例被吸收和利用,从而影响浮游植物的生长和群落结构。Egge 与 Aksnes^[34]通过海上浮动围栏实验,发现 Si:N 比值的下降会限制硅藻生长,从而有利于甲藻和棕囊藻取代硅藻成为当地优势种 (dominant species)。Bodeanu^[35]于 1992 年在针对黑海海域藻华的研究中,发现硅磷比的下降与原心心形藻 (*proorocentrum cordatum* Doge) 藻华的增加有关。Xiao 等人^[36]对 2006—2018 年渤海海域无机氮和无机磷等数据集进行了整理和分析,发现营养盐的减少可引起浮游植物生产力和群落结构发生显著变化,从而导致有害藻华优势种转变。在北部湾近岸海域的研究中,Lv 等人^[37]利用 4 种不同营养类型的培养皿对比了球形棕囊藻在生长过程中对各类营养盐的吸收偏好,发现并证实在同等条件下,球形棕囊藻对硝酸盐的吸收率明显高于铵盐等其他氮源。针对球形棕囊藻对硝酸盐的吸收偏好,Zhu 等人^[38]结合生态学调查、实验室研究、超转录组学和生物信息学分析结果发现,北部湾近岸海域的高硝酸盐浓度水平有利于球形棕囊藻细胞内高亲和力硝酸盐转运蛋白的基因表达,使其在有害藻华爆发过程中更容易占据生

态位 (ecological niche)。

(二) 气候因素

气候变化引起的海水变暖和海水酸化等问题被认为是导致近年来有害藻华爆发频率与规模呈增长趋势的主要驱动因素之一^[39]。水温和 pH 会影响水生物的基础代谢功能、物种分布特征, 以及生物事件 (如有害藻华等生态灾害) 的发生频率^[40]。Gobler 等人^[41]基于海表面温度数据和两种有害藻类 (亚历山大藻和渐尖鳍藻 *Dinophysis acuminata*) 的温度依赖性增长率 (temperature-dependent growth rates) 分析了 1982 年至 2016 年间大西洋海域有害藻华的发展趋势。结果表明, 在低于当地藻类最大生长温度的前提下, 水温升高是有害藻华风险上升的重要驱动因素。Ding 等人^[42]利用中国东海近年来海表温度的船舶现场监测数据和卫星观测数据, 对有害藻华风险与水温之间的关系进行了研究, 提出了一种基于海表温度的中期 (medium-term) 有害藻华风险评估方法。研究发现, 东海近岸有害藻华的年发生率与 3 月份的平均海表温度呈正相关, 与 3—7 月间海表温度变化率呈负相关。该研究结论认为, 基于海表的温度变化可提前 1—2 月对中国东海海域的有害藻华风险进行评估, 从而有助于减少赤潮造成的损害。Pang 等人^[43]针对我国东南沿海海水酸化引发的赤潮问题研究了二氧化碳浓度变化对亚历山大藻生长的影响。结果表明, 当二氧化碳的大气分压从 395 μatm 上升至 1000 μatm 时, 亚历山大藻的生长率和整体毒性均显著上升。在北部湾近岸海域的研究中, 贺成等人^[17]于 2016 年 12 月至 2017 年 6 月对北部湾海域 29 个站位进行了 6 次综合调查, 发现球形棕囊藻的时空分布特征受多种物理海洋学过程和生物化学过程的综合影响, 其中水温是最主要的影响因素。

(三) 综合因素

藻华的形成通常是由多种因素共同作用的结果, 这些因素为藻类构建了合适的生长环境^[44]。陈炳章等人^[45]通过无菌条件下的单种培养实验研究了温度与盐度对具齿原甲藻 (*prorocentrum dentatum*) 和中肋骨条藻 (*skeletonema costatum*) 生长的影响。结果表明, 具齿原甲藻和中肋骨条藻的最适盐度范围分别为 25—31 psu 和 18—35 psu, 而两种藻类的最适盐度会在水温上升时往中低盐度方向偏移。此外, 河口的冲淡水输入和外海高盐水的混合会形成特定的盐度跃层和锋面结构, 改变营养盐、溶解氧以及光照的空间分布, 也会对该海域浮游植物的生长产生间接影响^[46]。Zhang 等人^[47]于 2013 年 6 月—7 月在渤海秦皇岛近岸海域进行了 4 次褐潮事件调查, 分析了温度、盐度、营养盐等环境因子对抑食金球藻褐潮的影响。调查研究发现, 当温度在 21.5—23.2 $^{\circ}\text{C}$ 且盐度超过 29 psu 时, 褐潮风险最大。同时, 水体中高浓度有机氮和低浓度无机营养盐环境更易引发褐潮爆发。于仁成等人^[48]收集了 230 个有害藻华事件 (1952—2017) 资料以及相关环境

数据（1990—2017），分析了渤海海域有害藻华的时空分布特征和其潜在驱动因素。结果表明，受长期的气候变化、富营养化和海水养殖（mariculture）等影响，渤海海域的有害藻华原因种由甲藻和定鞭金藻（*haptophytes*）向长短鞭毛藻（*pelagophytes*）转变，其频率、季节窗口和致灾物种数量都有所增加。除此之外，在浮游植物进行光合作用时，浊度影响下的水体光照强度也会对浮游藻类的生长产生显著的调控作用^[49]。Fichez 等人^[50]通过对英国北海大乌斯河河口的调查研究发现，河口海域的高浊度环境是当地浮游植物生长的主要限制因素之一。

综上所述，不同区域内藻华动态的控制因素受环境条件和生态结构等影响下存在显著差异，使得目前对有害藻华主要形成机制的讨论依旧存在争议，为当地制定针对性的有害藻华防控措施构成重大挑战^[51]。

1.2.2 藻华爆发的预测方法

随着有害藻华理论研究的逐渐深入，国内外学者们针对多个地区有害藻华的预测展开了研究。目前，有害藻华的主要预测方法包括基于生态学理论的概念模型和基于数据驱动的经验—统计模型^[30]。

（一）基于概念模型的有害藻华预测

概念模型主要通过对复杂的生态系统进行理论上的简化，为确定藻华形成的主要机制提供基本框架，从而模拟出藻类在水体中的时空分布、生长、爆发以及消退等过程^[52]。由 Margalef^[53]提出的 Mandala 模型是典型的概念模型之一，该模型解释了硅藻和鞭毛藻在不同营养浓度和湍流强度下的生长差异。Smayda 和 Reynolds^[54]将光的可用性与混合层的深度联系起来，对该模型进行了改进，使该模型能够评估从河口到近岸海域内不同种类鞭毛藻的生长状态。研究结果表明，对特定的环境条件组合（如光线、营养物质和湍流）的识别可以帮助确定优势种藻类，这些环境组合在某些情况下可能导致有害藻华爆发。在最近的研究中，Glibert^[55]对该模型进行了进一步的改进，增加了光适应、自养或混合养倾向、相对生长速度、毒素生产能力和放牧结果等特征。研究结果表明，改进后的 Mandala 模型有助于基于特征的建模方法和理解与有害藻华相关的环境因素。

除 Mandala 模型以外，生态位周期表（Periodic Table of Niches）也是较为经典的概念模型之一，该方法利用生物的生境特征、生活史、营养吸收以及代谢等维度作为基本要素，并根据实测数据预测浮游植物群落对环境变化的潜在反应^[56]。Xiao 等人^[57]构建了南海 9 个浮游植物类群（鞭毛藻、硅藻、甲藻等）的生态位周期表，基于温度、辐照度和硝酸盐浓度数据预测了当地浮游植物群落对海洋变暖和富营养化的反应。Alves-de-Souza 等人^[58]针对智利峡湾开发了基于厄尔尼诺（El Niño）指数、河流流量和温度等因素的生态位周期表，对当地渐尖鳍藻和

网状原角藻（*Protoceratium reticulatum*）引发的藻华进行了预测。结果表明，在拉尼娜（La Niña）年（海表温度大范围持续下降期间），渐尖鳍藻藻华的爆发风险较高，而在厄尔尼诺年（海表温度大范围持续上升期间），网状原角藻藻华的发生率较高。

此外，一些概念模型也用于预测一些特定的有害藻华事件，例如，Accoroni^[59]等人基于水动力学、温度和营养盐之间的协同效应，构建了亚得里亚海北部沿岸拟菱形藻（*Ostreopsis cf. ovata*）藻华的概念模型，解释了当地藻华的爆发和维持的机制。基于概念模型的有害藻华预测方法主要适用于解释在一些特定条件下藻华的类型、爆发时间和形成机制，因此难以直接应用于近岸海域有害藻华现场预测。

（二）基于经验—统计模型的有害藻华预测

经验—统计模型是通过量化驱动因素与藻华属性（如叶绿素 a 浓度或藻细胞丰度）之间的功能关系并进行预测的方法，这种量化是通过对现场监测数据的统计分析来实现的。Anderson 等人^[60]通过结合海面温度和卫星观测海表面颜色的四个光谱波段，建立了三个多元线性回归模型预测了圣巴巴拉海峡沿岸链状亚历山大藻（*Alexandrium catenella*）的细胞丰度、毒素浓度和细胞毒素产量，并预测了 98% 的有害藻华及其毒素分布情况。由于有害藻华具有明显的非线性和随机性特征，其形成过程存在很多不确定因素，使得基于线性回归的有害藻华预测方法存在局限性^[30]。为克服这一问题，广义加性模型（Generalized Additive Models, GAM）得到了广泛的应用。广义加性模型引入了非线性，并且不局限于描述这些关系的特定函数，利用平滑函数来表征复杂的非线性关系，提供对不同数据结构的适应性，有效解决了线性模型的局限性^[61]。Díaz 等人^[62]设计了一种结合上升流指数、海面温度和潮汐差的广义加性模型，成功地解释了欧洲大西洋沿岸水域约 80% 的尖藻华现象。Xiao 等人^[63]设计了一种基于硅藻和鞭毛藻特征色素的广义加性模型，能够在海洋变暖和富营养化压力下定量预测东海藻华的爆发概率。

随着人工智能和计算机技术的发展，机器学习技术也被广泛应用于生态学领域的研究，该方法不需要建立变量之间复杂的关系方程，因此对解决复杂非线性的问题具有明显的技术优势^[64]。近年来，国内外许多学者开始尝试利用人工神经网络（Artificial Neural Network, ANN）、支持向量机（Support Vector Machine, SVM）等机器学习方法进行有害藻华预测研究。Liu 等人^[65]基于环境要素的时空差异提出了卷积神经网络（Convolutional Neural Network, CNN）—长短期记忆网络（Long Short Term Memory, LSTM）耦合改进模型的方法，对南海近岸叶绿素 a 浓度进行了预测。结果表明该模型在大尺度（半月际）预测中的预测性能优于小尺度预测。由于机器学习算法建立的预测模型具有黑盒特征，单方面地依

赖此类方法难以对有害藻华的成因进行合理解释^[66]。为此,学者们在运用机器学习技术预测有害藻华的同时,还根据水温、营养盐等环境因子的变化对其形成机制进行分析,进而确定预测过程中的关键环境因子。Yu 等人^[67]收集了美国加州海岸斯克里普斯码头海域包括叶绿素 a 浓度、硝氮、水温等多项环境数据,采用梯度提升树回归算法对当地浮游植物生物量进行了预测。结果表明,该方法在选择合适的环境因子的前提下能够实现短期精准预测。Zhao 等人^[68]提出了一种基于典型对应分析 (Canonical Correspondence Analysis, CCA) 算法,对影响蓝藻藻华发生概率的主要驱动因素进行了分析,结果表明,水温、总磷、氨氮,以及化学需氧量是蓝藻藻华的主要驱动因素,而时空尺度差异是影响驱动因子选择的关键因素。Zhang 等人^[69]结合了随机森林 (Random Forest, RF) 和广义加性模型 (Generalized Additive Model, GAM) 的方法,研究了美国奥基乔比湖中环境预测因子对浮游植物生物量重要性的空间变化及其非线性响应关系,发现该水域浮游植物生物量的主要预测因子具有明显的空间异质性 (Spatial Heterogeneity),其中总氮在西部藻华高发区域为主要预测因子,而硝氮和活性磷酸盐为其他区域的主要预测因子。此外,基于各地区对藻华预警等管理策略的需求,机器学习分类模型也被应用于预测水体藻华的状态,其中藻华的状态通常由叶绿素 a 浓度水平或藻细胞生物量决定^[70]。Park 等人^[71]以藻华警戒等级作为目标变量,以多种水质、水动力和气象数据作为特征变量,分别采用了人工神经网络和支持向量机模型对水库蓝藻藻华的警戒级别进行了预测。结果表明,人工神经网络模型性能优于支持向量机,其中人工神经网络的准确率和精确率分别为 81% 和 72%,支持向量机的准确率和精确率分别为 73% 和 62%。由于机器学习预测模型的性能在很大程度上会受到输入特征变量的影响,因此通过多源数据分析明确藻华爆发的关键控制因素是未来提升藻华预测精度的一种努力方向^[72]。

1.2.3 藻华及其原因种监测方法

自 1997 年 10 月我国首次报道大规模球形棕囊藻藻华以来,近岸海域有害藻华监测方法已成为我国海洋科学与技术专业的重点研究方向之一^[73,74]。目前,针对有害藻华及其原因种的监测方法主要包括显微镜镜检法、卫星遥感监测以及浮游生物成像等。

(一) 显微镜镜检法

显微镜镜检法是在显微镜下,以目镜测微尺为标尺,直接测量浮游植物个体的直径、体积,以及其他外形特征,从而实现对藻种的鉴定与计数,是目前常用的有害藻华监测方法之一。陈菊芳^[18]等人通过现场采样调查和显微镜细胞计数法,对 1997 年冬季至 1998 年春季期间我国东南沿海爆发的球形棕囊藻藻华现场进行

了水质监测分析。结果表明,藻华重灾区的叶绿素浓度高于非重灾区,当水体中可溶性氮、磷分别超过 $0.1 \text{ mg}\cdot\text{L}^{-1}$ 和 $0.02 \text{ mg}\cdot\text{L}^{-1}$ 时,有害藻华风险会大幅上升^[75]。于连生和徐雷^[76]采用了基于数字显微镜的赤潮生物计数法,对夜光藻等有害藻华常见原因种进行观测计数,并与北海监测中心孔凡洲^[77]等人的测量结果作了对比。研究发现,该方法通过在计算机屏幕上显示出放大的赤潮生物图像进行人工鉴别,可大大降低人工镜下的劳动成本。张敏^[78]等人通过在獐子岛、海州湾、长江口、大亚湾、北部湾等典型赤潮高发区内采集的水样,汇总了光学显微镜和电子显微镜观察下对微藻的鉴定和分析结果,构建了 2019—2021 年中国近海有毒有害微藻和藻毒素分布数据集。显微镜镜检法具有操作简单、直观、准确率高等优点,是评价其他计数方法有效性的重要参考。但由于该方法涉及实地取样和高强度的实验室分析,人力和时间成本较高,难以直接获取有害藻华的时空变化特征,因此难以有效应用到区域性长期监测工作中^[73]。

(二) 遥感监测

遥感监测是通过测量水体吸收或散射太阳辐射能形成的光谱作为基础,通过反演推算实现对水质进行监测评估的方法^[79],具有效率高、视域广、数据采集频率高、重访周期短等优点,可以高效高频地监测水体表面藻类的时空分布状况,有着不可替代的优越性^[80]。卫星遥感图像能够利用 433 nm 和 686 nm 的光谱吸收峰反演计算水体表面的叶绿素 a 浓度,是监测近岸海域藻华的一种常用方法^[81]。Chen^[82]等人利用 1990—2019 年期间的遥感观测数据,分析了中国沿海赤潮与环境要素(叶绿素 a 浓度、水温以及盐度)的时空分布特征。结果表明,赤潮爆发期间水温较往常水准升高 $0.72\text{—}6.41\text{ }^{\circ}\text{C}$,叶绿素 a 浓度升高 $11.00\text{—}95.36 \text{ mg}\cdot\text{m}^{-3}$,盐度降低 $0.10\text{—}4.34$ 盐度单位(Practical Salinity Units, psu)。然而,叶绿素 a 浓度虽然能够反映水体中藻类的生物量,但无法直接量化其有害程度,因此还需结合现场采样、毒素分析,以及利用衍生算法等手段确定藻华的有害程度^[73]。Pour 和 Hashim^[83]采用相控阵型 L 波段合成孔径雷达(Phased Array type L-band Synthetic Aperture Radar, PALSAR)卫星遥感数据结合实地采样测量的方法,对马来西亚海湾 2015 年 5 月 20 日至 5 月 25 日的赤潮时空分布特征进行了分析。结果表明,与河口相连的半封闭海湾(如吉隆坡湾和新山湾)发生赤潮的频率明显更高。Lubac 等人^[79]将卫星遥感方法应用到了球形棕囊藻藻华监测中,并根据现场观测到的遥感反射光谱,提出了一种基于多光谱和高光谱的方法,对英吉利海峡东部和北海南部海域的球形棕囊藻生物量进行了反演估算。遥感监测具有范围大、效率高等优点,但该方法存在时空分辨率低、目视效果不佳等问题,因此在针对小规模和低生物量有害藻华的监测方面依旧存在挑战^[73,84]。

（三）计算机视觉与机器学习技术

随着硬件技术的发展以及对有害藻华高精度、高频率、长期限的监测需求,基于计算机视觉的浮游生物成像仪器的开发应用逐渐受到了学者们的重视^[85]。如表 1-1 所示,计算机视觉技术在 1992 年以来发展迅速,多位学者以及工程师们针对有害藻华监测设计出了不同类型的设备。其中, Sieracki 等人^[86]设计出了一种原位浮游生物成像装置 VPR (Video Plankton Recorder), 该装置可自动对藻类等浮游生物进行实时拍照, 并装置于浮标上进行图像与环境信息的实时获取。Junku 等人^[87]开发了一种水下机器人设备 AUV (Autonomous Underwater Vehicle), 该设备可以在水下多个区域内进行藻类细胞的图像收集, 与 VPR 相比其机动性有了很大的提高。于翔^[88]等人设计了一款水下全自动显微成像仪, 该设备可用于对直径在 1—100 μm 范围内的浮游生物/颗粒物进行原位拍摄, 最大工作水深可达 100 m。

浮游生物成像仪能够在短时间内获取大量藻类图像, 因此需要结合准确高效的目标检测方法才能够真正提高有害藻华监测效率。相较于传统的人工鉴定, 基于图像机器学习的目标检测方法兼具了高精度、高效率等优点, 适用于分析水下成像装置在工作过程中输出的大量图像数据^[89]。许多有害藻类可通过细胞形态特征进行初步的分类识别, 因此在许多情况下基于图像机器学习的方法可以用来识别浮游植物和浮游动物的属, 为有害藻华预测提供重要信息^[90]。Otálora 等人^[91]开发了基于人工神经网络的微藻培养物表征模型, 采用流式细胞仪 (FlowCAM) 获取培养样品中的藻类细胞图像作为训练集对模型进行训练。结果表明, 该模型对藻类分类的准确率可高达 97.27%, 证明了目标检测模型是监测水体中微藻种类和生物量的有效工具。Zhou 等人^[92]采用了 YOLO (You Only Look Once) 算法对显微镜下的海洋微藻进行了分类和计量, 并与 TOOD (Task-aligned one-stage object detection) 和 R-CNN (Region-based Convolutional Neural Network) 算法进行了比较, 发现 YOLO 模型的准确率最高, 可达到 82.6%。Chan 等人^[93]采用了 MobileNetV3 图像分类模型对 20 种淡水藻类图像数据库进行了训练与检测, 并对比了该模型对原始藻类图像与经 StyleGAN2-ADA 算法图像增强处理后的数据集的训练效果。结果表明, 图像增强算法可以有效提高藻类自动分类的效率和准确度, 对未来有害藻华监测工作具有重要意义。由于机器学习模型通常需要充足的训练集数据对模型进行训练^[70], 使得基于浮游生物成像仪与图像机器学习的藻华监测方法需要在获取当地藻类图像数据的前提下才能实现有效应用。

表 1-1 常见的浮游生物成像仪器

型号	研制年份	研制单位	功能特点	适用场景
Video Plankton Recorder (VPR)	1992	美国伍兹霍尔海洋研究所 ^[86]	利用水下显微镜采集浮游生物和粒子的原位图像，并存储在内部存储器中	水下浮游生物原位图像采集
水下显微成像仪	2009	中国国家海洋技术中心 ^[88]	利用水下显微镜记录水下 100 μm 以下的微小颗粒	原位测量
FlowCAM	2004	美国 Fluid Imaging Technology 公司	采用流式细胞仪结构，将荧光光谱技术和 CCD 相机相结合对水样进行分析	浮游藻类实验室样品分析
ZooScan	2007	法国 Hydroptic 公司	实现实验室内对采集的水样进行扫描成像，利用图像处理软件分割并识别藻类	浮游生物实验室样品分析
LOKI 浮游生物图像原位采集系统	2009	德国 iSiTEC 公司	采集浮游生物图像、环境参数及样本，同时实现浮游生物分布和环境参数可视化	水下浮游生物原位图像采集
Imaging FlowCytobot (IFCB)	2006	美国伍兹霍尔海洋研究所	通过水下显微成像实现原位图像采集和识别赤潮原因种，并通过有线网络连接地面服务器，实现在线监测	原位监测分析

1.2.4 存在的问题

基于上述研究综述可知，国内外学者们对有害藻华的控制因素、预测方法，以及监测鉴定技术等方面已取得一定的研究成果和进展。然而，由于我国近岸海域有害藻华具有区域性、非线性、随机性，以及原因种多样性特征^[67]，目前仍存在一些问题亟须解决。

（一）影响有害藻华动态的关键控制因素难以明确。有害藻华具有区域性特征，不同地区藻华的形成机制受环境条件影响存在差异，使得目前我国许多海域内影响有害藻华生消的关键控制因素难以明确。

（二）有害藻华预测方法存在适用性局限。藻华的爆发过程具有非线性与随

机性特征,使得基于概念模型的藻华预测方法难以适用于现场预测;而基于机器学习的藻华预测模型受限于训练集数据,只能在局部区域或时段内维持较高的精确度。

(三)常规方法难以有效监测异养藻类引发的藻华。鉴于我国近岸海域有害藻华的原因种多样性特征,某些异养藻类(如北部湾近岸海域的球形棕囊藻)的细胞形态特征与其他藻类无显著差异,且藻华期间对叶绿素 a 浓度、溶解氧和 pH 等水质指标的影响较小,使得常规方法难以对其实行有效的监测与鉴定^[94]。

1.3 研究内容

针对上述研究现状以及存在的问题,本研究以我国南海北部湾近岸海域作为研究区域,对以下问题展开了研究:

(一)**影响北部湾近岸海域藻华动态的关键控制因素**。整理北部湾近岸海域水质监测数据,分析叶绿素 a 浓度及其相关环境要素的时空分布特征,探讨环境因子对有害藻华动态的综合影响,筛选有害藻华预测所需的关键环境因子。

(二)**基于环境因子特征的藻华预测方法**。基于藻华生消过程中营养盐变化的信号特征,建立基于环境因子特征变量的藻华预测模型,分析不同原因种藻华对预测精确度的影响机制,探讨掌握原因种生物量信息及其优先吸收营养盐类型对提升有害藻华预测能力的意义。

(三)**基于光学图像特征的有害藻华原因种监测方法**。针对传统方法难以有效监测异养藻类生物量的问题,以球形棕囊藻为主要监测对象,设计并搭建有害藻华原因种监测技术框架,分析不同藻种之间的光学图像特征差异,实现在水下对有害藻生物量的自动监测识别。

本文的章节安排和具体研究内容如下:

第一章 为**绪论**。该章节主要介绍了有害藻华的研究背景和意义,介绍了国内外对有害藻华控制因素、预测方法,以及原因种监测方法的研究现状,总结了目前相关研究中存在的问题与不足,最后阐述了本文的研究内容和技术路线。

第二章 为**北部湾近岸海域环境要素时空分布特征**。介绍了研究区域内环境概况和监测数据信息,采用空间插值算法分析了环境要素的年际空间分布特征。基于相关性分析结果研究了各项环境要素对北部湾近岸海域藻华风险的综合影响,总结导致有害藻华风险上升的必要条件。

第三章 为**影响藻华动态变化的环境因子特征选择**。选取了 2013—2014 年间研究区域内的藻华高风险时段作为研究案例,采用随机森林回归算法评估了各案例中环境因子对叶绿素 a 浓度影响的特征重要性,筛选了藻华预测所需的关键预

测因子，并探讨了水温和盐度影响下藻华爆发前后的营养盐变化特征。

第四章 为**基于环境因子的有害藻华预测及其原因种特征**。基于有害藻华非线性与随机性特征，以第三章筛选的关键环境因子作为特征变量，建立了逻辑回归预测模型对各研究案例进行了“藻华/常态”二分类预测，结合各案例中蓝绿藻的生物量和当地有害藻华历史记录，分析了不同原因种引发的藻华对营养盐的吸收偏好，探讨了原因种差异对有害藻华预测结果的影响。

第五章 为**基于水下显微成像的有害藻华原因种监测方法研究**。针对目前手段无法有效监测球形棕囊藻藻华的问题，该章节提出了基于水下显微成像—图像处理—目标检测为基础的有害藻华原因种监测技术框架，搭建了水下显微成像原理样机并以球形棕囊藻作为监测目标开展了水槽实验。采用了多种图像增强算法对比分析了球形棕囊藻与其他藻类之间的光学图像特征，采用 YOLOv8 目标检测模型对水下拍摄的藻类图像进行了训练与测试，对该框架监测水下有害藻类生物量的性能进行了评价。

第六章 为**结论与展望**。该章节对本文的研究工作进行了总结回顾，并根据本文存在的问题以及后续可能的研究工作提出了可行的研究思路和解决方案。

第2章 北部湾近岸海域环境要素时空分布特征

2.1 引言

叶绿素 a 的浓度是反映水体浮游藻类生物量的重要指标,也是评估当地水环境初级生产力水平与有害藻华风险的重要依据^[95-97]。掌握叶绿素 a 浓度与营养盐、水温、盐度等环境要素之间的关系有助于进一步了解有害藻华形成机制^[98]。在近岸海域,河口作为河流与海洋之间的过渡地带,大量陆源营养物质通过地表径流被输送到近岸海域从而影响近岸海域的生态环境^[99]。丰富的营养物质和良好的光照条件等因素共同促进河口海域浮游藻类的快速繁殖,从而引发有害藻华事件^[100,101]。因此,掌握近岸海域环境要素时空分布特征对划分有害藻华主要风险区域/时段具有重要指导作用,是推进有害藻华监测方案制定的重要前提。

我国南海北部湾近岸海域水系发达、河口众多,包括位于防城港的防城江、茅尾海的钦江和茅岭江,以及廉州湾的南流江和大风江等^[102]。北部湾复杂的地形结构和密集的河口分布使得该海域有害藻华事件频发且时空分布规律难以预测^[103]。本章基于广西壮族自治区环境监测中心站提供的北部湾近岸海域水质监测数据,分析研究区域内叶绿素 a 浓度以及其他环境要素的时空分布特征,探讨环境要素对有害藻华风险分布的综合影响。

2.2 研究数据与方法

2.2.1 研究区域范围及概况

如图 2-1 所示,本文的研究区域为南海北部湾近岸海域(20.8°N—22.0°N, 108.0°E—109.6°E),研究区域内 16 个监测站点覆盖了珍珠湾、防城港、钦州湾、廉州湾、铁山港,以及涠洲岛。其中,防城港、茅尾海、钦州湾、廉州湾,和涠洲岛为重点监测区域(图 2-1 中红色点位),该区域为浮标自动监测与现场趋势性监测站点,其他测站点(图 2-1 中黑色点位)为浮标自动监测站点。此外,表 2-1 展示了主要监测区域内测站点的具体坐标信息。其中,测站点 GX03 位于防城港防城江河口南侧,测站点 GX04 位于茅尾海钦江河口西南侧,测站点 GX06

位于钦州湾金窝水库出海口南侧，测站点 GX09 和测站点 GX10 位于廉州湾南流江河口西南侧，测站点 GX12 位于涠洲岛南侧。




图 2-1 本研究区域监测站点分布（黑色点位为浮标自动监测站点，红色点位为浮标自动监测与现场趋势性监测混合站点）

表 2-1 主要监测站点地理坐标信息

测站点	经度 (°E)	纬度 (°N)
GX03	108.40	21.52
GX04	108.55	21.80
GX06	108.61	21.66
GX09	109.03	21.52
GX10	109.04	21.48
GX12	109.10	21.02

在重点监测区域中，防城港作为广西沿海最大港口和中国西部第一港，该区域的生态环境问题近年来一直是国家关注焦点^[104]。防城江作为北部湾较大的入海河流之一，受工农业发展和城市化的影响，每年输入到北部湾近岸海域的污水量高达数十亿立方米，使得 2011 年以来防城江河口以南海域有害藻华爆发频率与规模逐年上升，成为威胁沿海生态平衡与安全的主要问题之一^[105]。钦州湾是位于中国南海北部湾北部的一个海湾，为典型的溺谷型半封闭式海湾^[106]。除受茅岭江和钦江两条常年河流输入影响外，钦州湾还受钦州市大量工业废水和富含营养物质的生活污水排放的影响，使得该海域的污染负荷明显加重，生态环境问题越发明显^[107]。廉州湾位于广西合浦县西南部，地处南流江三角洲，东临北海市，南临北部湾^[108]。南流江作为廉州湾乃至北部湾最大的独流入海河流，流域内人口和经济高度集中，导致该流域乃至河口营养负荷高，是害藻华等海洋生态灾害高发区域^[109]。涠洲岛是位于南海北部湾北部的一座火山岛，面积 26 km²，

海水平均盐度约为 31.9 psu，平均海表面温度 24.5 °C^[110]。近年来受岛上人类活动的影响，该岛屿周边海域氮磷比呈现出升高趋势^[111]。

《广西壮族自治区海洋环境质量公报》^[112]显示，以南流江、大风江、钦江、防城江以及茅岭江等河口每年的污染物排放量高达数十万吨，其中化学需氧量、氮、磷等营养物质占比超过 90%，导致近岸海水质量常年处于较差水平，多为三类（适用于一般工业用水区和滨海风景旅游区）、四类（适用于海洋港口水域和海洋开发作业区）和劣四类（劣于国家海水水质标准中第四类海水水质）海水水质（海水水质标准参考 GB 3097-1997）。如图 2-2 所示，2013 年北部湾近岸海域劣四类海水水质面积达到 838 km²，主要集中在茅尾海、钦州湾，以及廉州湾南流江河口东南部。




图 2-2 2013 年北部湾近岸水质等级分布^[112]

2.2.2 研究数据获取及处理

本研究的数据由广西壮族自治区环境监测中心站提供，数据来源于浮标在线自动监测和船舶现场趋势性监测。其中，浮标在线自动监测的 16 个站点（图 2-1 所有点位）均采用内置传感器（YSI 6600 型多参数水质仪，质检参数详见附录 A）对当地海域的叶绿素 a 浓度、水温、盐度、溶解氧、pH 值和浊度进行实时自动监测^[113]。硝氮（硝酸盐—亚硝酸盐）和活性磷酸盐（正磷酸盐）2 项营养盐指标由监测站工作人员在监测站点 GX03、GX04、GX06、GX09、GX10，以及 GX12（图 2-1 中红色点位）所在区域进行船舶现场监测。现场监测采用 8 L 采样器对表层（水面下 0.5 m）进行现场采样，样品的采集、保存、分析以及质量控制均

按《海洋监测规范》（GB 17378.7-2007）进行^[14]。研究数据的时间覆盖范围为2013年1月1日至2014年12月31日，数据的记录时间分别为每日的2:00、6:00、10:00、14:00、18:00和22:00。

由于原始数据难免存在重复、缺失、数值异常、量纲不统一等问题，从而对后续的数据分析及运算结果产生影响。因此，为保证结果的准确性，本研究前期对原始数据进行了数据清洗、集成，以及规范化等预处理操作。其中，在数据清洗过程中，筛选出异常值、离群值等特殊数据，并用均值或空值进行替换。例如，当数据出现水温 $< 0\text{ }^{\circ}\text{C}$ （研究区域内水温通常为 $12\text{--}34\text{ }^{\circ}\text{C}$ ）等异常数值时，用相邻时间序列内的均值进行替换。在数据集成过程中，将重点监测区域的浮标自动监测数据与船舶现场监测数据进行合并，用于后续章节研究。最后，对研究区域内环境要素在各测站点的年均值与月均值进行统计，其中重点监测区域内测站点的年均值统计如表2-2所示。

表 2-2 重点监测区域测站点环境要素年际水平统计

年份	测站 点	硝氮 $/\mu\text{g}\cdot\text{L}^{-1}$	活性磷酸盐 $/\mu\text{g}\cdot\text{L}^{-1}$	水温 $/^{\circ}\text{C}$	盐度 $/\text{psu}$	溶解氧 $/\text{mg}\cdot\text{L}^{-1}$	pH	浊度 $/\text{NTUs}$	叶绿素 a $/\mu\text{g}\cdot\text{L}^{-1}$
2013	GX03	105.995	7.652	24.362	28.600	7.562	8.212	3.492	4.244
	GX04	149.671	13.180	24.519	13.017	7.271	7.737	23.795	2.636
	GX06	182.473	5.386	24.783	23.039	6.964	8.120	12.818	2.920
	GX09	181.073	9.084	24.059	24.285	7.362	8.149	14.972	6.917
	GX10	68.893	15.532	24.012	27.615	7.466	8.186	8.564	5.227
	GX12	120.650	8.399	25.379	30.606	7.057	8.193	2.769	2.485
2014	GX03	106.278	9.929	23.569	28.854	7.604	8.189	2.639	3.805
	GX04	234.472	11.743	23.989	15.807	7.544	7.787	10.58	3.155
	GX06	111.629	10.773	24.455	24.039	7.032	8.013	6.346	3.260
	GX09	142.187	18.647	23.627	26.545	7.547	8.144	15.529	5.173
	GX10	127.207	13.803	24.572	28.933	7.269	8.081	2.672	2.889
	GX12	114.488	11.291	24.847	31.122	7.025	8.241	2.914	2.761

2.2.3 环境要素的空间插值

本章基于每个测站点的位置坐标和水质监测数据年平均值，采用克里金（Kriging）空间插值方法对研究区域内各项环境要素的空间分布进行绘制，分析叶绿素 a 浓度、营养盐等环境要素的空间分布特征，进而探讨研究区域内藻华风险与环境要素之间的关系。

克里金插值法又称空间自协方差最佳插值法，它是以法国科学家 D.G. Krige

的名字命名的一种最优内插算法,该方法基于采样点的相互位置关系与待预测点的空间位置关系,通过变异函数理论提供的结构信息,对研究区域内采样点的数据赋予权重,对未测点位进行线性方差最小的估算,具有精度高、适用性广等优点^[115]。目前,克里金插值算法已被广泛应用于水环境监测、海底地形制图等领域,是一种可靠的空间插值网格化方法^[116]。

2.2.4 环境要素相关性分析

由于有害藻华受多种环境因素的共同影响,通常呈非线性变化特征^[64,117-119]。针对该特征,本章统计了各测站点环境要素的月际均值,并分别绘制叶绿素 a 浓度以及各项环境要素的月际变化趋势图,采用斯皮尔曼相关性分析 (Spearman Rank Correlation Analysis) 方法分析重点监测区域 (GX03、GX04、GX06、GX09、GX10, 以及 GX12) 叶绿素 a 浓度与环境要素之间的相关性。

斯皮尔曼秩相关性分析是一种非参数秩统计量,常用于衡量变量之间的相关性,相关性系数通常用 ρ 表示^[120]。 ρ 值的范围为 $[-1, 1]$, 在通常情况下, $\rho = -1$ 为完全负相关; $\rho = 0$ 为无相关性; $\rho = 1$ 为完全正相关; $0 < |\rho| < 0.2$ 为极弱 (正/负) 相关; $0.2 < |\rho| < 0.4$ 为弱 (正/负) 相关; $0.4 < |\rho| < 0.6$ 为中度 (正/负) 相关; $0.6 < |\rho| < 0.8$ 为强 (正/负) 相关; $0.8 < |\rho| < 1$ 为极强 (正/负) 相关。该方法利用两变量之间的秩次大小进行相关性分析,对原始变量的分布不作要求,适用于判断离散的有序型/连续型数据之间的相关性,具有稳定性强、适用范围广等优点^[121]。

2.3 结果与讨论

2.3.1 环境要素的年际空间分布特征

(一) 叶绿素 a 浓度分布

如图 2-3 所示,研究区域内叶绿素 a 浓度的空间分布在大部分海域内呈明显的近岸高一远岸低特征。其中,在岸线较为开阔的河口海域 (GX01、GX02、GX03、GX08、GX09、GX10 和 GX14), 水体叶绿素 a 浓度水平相对较高,显著高于半封闭河口海域 (GX04 与 GX06) 和离岸近海区域 (GX12、GX13 和 GX16)。根据表 2-2 的统计,在重点监测区域内,廉州湾南流江河口南部海域 (GX09 和 GX10) 的叶绿素 a 浓度水平最高,其中测站点 GX09 在 2013 年和 2014 年的年均叶绿素 a 浓度分别达到 $6.917 \mu\text{g}\cdot\text{L}^{-1}$ 和 $5.173 \mu\text{g}\cdot\text{L}^{-1}$ 。同时,防城江河口南部 (GX03) 海域叶绿素 a 浓度水平也显著高于除廉州湾以外的其他海域,测站点

GX03 在 2013 年和 2014 年的年均叶绿素 a 浓度分别为 $4.244 \mu\text{g}\cdot\text{L}^{-1}$ 和 $3.805 \mu\text{g}\cdot\text{L}^{-1}$ 。相对而言,茅尾海(GX04)、钦州湾南部(GX06),以及涠洲岛所在海域(GX12)的年均叶绿素 a 浓度较低,当地测站点监测的年均值仅在 $2.4\text{—}3.3 \mu\text{g}\cdot\text{L}^{-1}$ 之间。




图 2-3 研究区域叶绿素 a 浓度空间分布图

(二) 硝氮与活性磷酸盐分布

如图 2-4 所示,重点监测区域硝氮浓度的年际空间分布在部分海域内呈近岸高一远岸低的特征。与叶绿素 a 浓度不同的是,硝氮在半封闭河口海域(GX04 和 GX06)的整体水平高于岸线开阔的河口海域(GX03、GX09 和 GX10)。根据表 2-2 的统计,2013 年茅尾海(GX04)和钦州湾(GX06)的硝氮浓度水平最高,测站点 GX04 和 GX06 对当地监测的年际均值分别达到 $182.473 \mu\text{g}\cdot\text{L}^{-1}$ 和 $149.671 \mu\text{g}\cdot\text{L}^{-1}$ 。而防城港(GX03)和涠洲岛(GX12)的硝氮浓度水平相对较低,测站点 GX03 和 GX12 对当地监测的年均值分别为 $105.995 \mu\text{g}\cdot\text{L}^{-1}$ 和 $120.650 \mu\text{g}\cdot\text{L}^{-1}$ 。此外,位于廉州湾的 GX09 和 GX10 两个相邻测站点所在海域的硝氮浓度水平差异较大,其中北侧靠近河口的测站点 GX09 年均值较高,达到 $181.073 \mu\text{g}\cdot\text{L}^{-1}$,而南侧的测站点 GX10 仅为 $68.893 \mu\text{g}\cdot\text{L}^{-1}$,明显低于其他海域。然而,研究区域内在 2014 年的硝氮浓度分布特征较 2013 年有所不同,其中位于茅尾海的硝氮水平最高,测站点 GX04 对当地的监测年均值达到 $234.472 \mu\text{g}\cdot\text{L}^{-1}$,而钦州湾南部海域的硝氮水平较前一年明显降低,测站点 GX06 监测的年均值仅为 $111.629 \mu\text{g}\cdot\text{L}^{-1}$ 。

如图 2-5 所示,活性磷酸盐的年际空间分布特征与叶绿素 a 浓度具有一定的

相似性，两者的最高监测值都出现在廉州湾南流江河口南部海域。其中，2013年的测站点 GX10 和 2014 年的测站点 GX09 监测的年均活性磷酸盐浓度在同年内最高，分别达到 $15.532 \mu\text{g}\cdot\text{L}^{-1}$ 和 $18.647 \mu\text{g}\cdot\text{L}^{-1}$ 。然而，叶绿素 a 浓度水平仅次于廉州湾的防城港年均活性磷酸盐浓度水平较低，测站点 GX03 在 2013 年与 2014 监测的年均值未超过 $10 \mu\text{g}\cdot\text{L}^{-1}$ 。而在整体叶绿素 a 浓度水平较低的茅尾海，GX04 监测的年际均值达到 $12 \mu\text{g}\cdot\text{L}^{-1}$ 左右，在重点研究区域内仅低于廉州湾。

根据北部湾水质等级分布情况（图 2-2）可知，2013 年研究区域内的营养盐空间分布特征与劣四类海水水质分布情况基本相符。然而，尽管防城港的整体营养盐水平较低，且大部分区域为一类或二类海水水质，但该海域的叶绿素 a 浓度显著高于整体营养水平更高且海水水质等级更低（劣四类）的钦州湾。




图 2-4 研究区域硝氮空间分布图




图 2-5 研究区域活性磷酸盐空间分布图

（三）水温分布

如图 2-6 所示，研究区域内各测站点所在海域之间的整体温差较小，年均水温整体在 24—25 °C 之间。其中，纬度较高的北部沿海地区水温比南部离岸海域水温略低。其中，受高纬度陆源淡水输入的影响，防城港（GX02 和 GX03）、茅尾海（GX04）、廉州湾（GX09 和 GX10），以及铁山港（GX14）所在海域的水温相对较低，年均水温在 23.5—24.5 °C 之间。而南部的涠洲岛所在海域水温最高，年均值约为 25.2 °C。结合图 2-3 叶绿素 a 浓度分布特征可知，仅依靠年际空间分布特征无法直接反映研究区域内水温对藻华风险的影响。




图 2-6 研究区域水温空间分布图

（四）盐度分布

如图 2-7 所示，研究区域内的盐度分布呈现出整体近岸低—远岸高的特征。其中，受钦江与茅岭江淡水输入和高度封闭的边界条件的共同影响，茅尾海的年均盐度仅为 15 psu 左右，明显低于其他海域。而距离河口/岸线较远的涠洲岛所在海域年均盐度最高，达到 31 psu 左右。而在叶绿素 a 浓度相对较高、边界条件较为开阔的防城港（GX02 和 GX03）、廉州湾（GX09 和 GX10），以及铁山港（GX14），年均盐度大约在 24—28 psu 之间，相较于整个研究区域属中盐度范畴。本章的叶绿素 a—盐度的空间分布表明，岸线开阔的河口附近海域内的中盐度条件可能是导致当地叶绿素 a 浓度水平较高的主要原因之一^[122,123]。




图 2-7 研究区域盐度空间分布图

(五) 溶解氧分布

如图 2-8 所示,研究区域内溶解氧的空间分布特征与叶绿素 a 浓度高度相似,但整体水平差异不大。其中,叶绿素 a 浓度较高的防城港、廉州湾,以及铁山港的溶解氧水平相对较高,年均值约为 $7.4 \text{ mg}\cdot\text{L}^{-1}$ 。而叶绿素 a 浓度水平较低的钦州湾和涠洲岛周边海域的溶解氧水平相对较低,年际均值约为 $7 \text{ mg}\cdot\text{L}^{-1}$ 。




图 2-8 研究区域溶解氧空间分布图

（六）pH 值分布

如图 2-9 所示，研究区域内 pH 值的空间分布特征与盐度（图 2-8）相似，整体呈近岸低—远岸高的特征。受陆源输入淡水和半封闭岸线影响，茅尾海和铁山港东北侧海域（GX15）的年均 pH 值显著低于其他海域，为 7.7—7.9 之间。涠洲岛周边海域的年均 pH 值最高，为 8.2—8.3 之间。叶绿素 a 浓度较高的防城港（GX02 和 GX03）、廉州湾（GX09 和 GX10），以及铁山港（GX14 和 GX15）的年均 pH 值在 7.9—8.2 之间。此外，本研究区域内的整体 pH 值基本处于大部分近岸海域浮游植物的适宜生长范围（pH 值约为 6.5—9.0^[124]）。




图 2-9 研究区域 pH 值空间分布图

（七）浊度分布

如图 2-10 所示，与盐度和 pH 值的分布特征相反，研究区域内浊度的空间分布呈整体近岸高一远岸低的特征。其中，2013 年茅尾海的浊度水平最高，测站点 GX04 监测的年均浊度达到 23.795 NTUs。而在 2014 年，廉州湾的浊度水平最高，为 15—16 NTUs 之间。离岸线较远的涠洲岛周边海域的浊度最低，年均浊度在 3 NTUs 以下，明显低于其他海域。叶绿素 a 浓度水平较高的防城港、廉州湾，以及铁山港之间的浊度水平差异较大，廉州湾和铁山港的年均浊度可达到 10 NTUs 以上，而防城港的浊度仅在 3—7 NTUs 之间。




图 2-10 研究区域浊度空间分布图

2.3.2 时间序列下的环境要素相关性

图 2-11 (a)和(b)所示为 2013 年和 2014 年重点监测区域内叶绿素 a 浓度与其他环境要素之间的斯皮尔曼相关性分析结果（具体相关系数见附录 A 表 A-2）。其中，在叶绿素 a 浓度水平较高的测站点 GX03 和 GX09 所在海域，2013 年的叶绿素 a 浓度与营养盐（硝氮与活性磷酸盐）之间都呈现显著弱负相关和极弱负相关。该结果与图 2-3、图 2-4，以及图 2-5 呈现出的叶绿素 a—营养盐之间空间分布关系相反。而在 2014 年，测站点 GX03 的叶绿素 a 浓度与营养盐呈显著的弱正相关，叶绿素 a 浓度与硝氮和活性磷酸盐的斯皮尔曼相关系数分别为 0.243 和 0.259。说明在较长的时间跨度下，叶绿素 a 与营养盐之间的变化关系可能受不同藻类的营养吸收偏好影响存在差异^[125]。此外，大部分测站点的叶绿素 a 浓度与水温、溶解氧和 pH 值都呈较为显著的正相关，说明本研究区域内浮游植物的生长在大多数情况下会受水温的直接影响^[9]，且它们的呼吸—光合作用也会直接影响水体的溶解氧和 pH 值^[126]。

综上所述，在年际时间尺度下，叶绿素 a 浓度与环境要素之间的相关性分析结果能够提供的信息量较为有限。为进一步分析研究区域内环境要素对叶绿素 a 浓度的影响，本章将基于重点监测区域内 6 个测站点的叶绿素 a 浓度与其他 7 项环境要素之间的月际变化关系，进一步探讨引发当地藻华事件的主要控制因素。





图 2-11 各测站点叶绿素 a 浓度与环境要素之间的斯皮尔曼相关性: (a) 2013 年; (b) 2014 年。

(一) 叶绿素 a 浓度与硝氮

如图 2-12 所示,重点监测区域内各测站点叶绿素 a—硝氮之间的月际变化关系在大部分时段内无显著特征。然而,当叶绿素 a 浓度出现峰值 ($> 7.5 \mu\text{g}\cdot\text{L}^{-1}$) 时,相邻时段内叶绿素 a 浓度与硝氮之间通常呈显著负相关。例如图 2-12 (a)中测站点 GX03 所在海域在 2013 年 9 月叶绿素 a 浓度达到 $12.948 \mu\text{g}\cdot\text{L}^{-1}$ 时,同时段的硝氮水平处于最低点,仅为 $28.167 \mu\text{g}\cdot\text{L}^{-1}$,且显著低于相邻时段。此外,图 2-11 (b)中 2014 年 7 月—10 月的测站点 GX04、图 2-11 (d)中 2013 年 3 月—7 月和 2014 年 4 月—8 月的测站点 GX09 等时段内的叶绿素 a—硝氮之间也存在相似的负相关。




图 2-12 重点监测区域叶绿素 a 浓度与硝氮的月际变化及相关性: (a) 测站点 GX03; (b) 测站点 GX04; (c) 测站点 GX06; (d) 测站点 GX09; (e) 测站点 GX10; (f) 测站点 GX12。

(二) 叶绿素 a 浓度与活性磷酸盐

如图 2-13 所示,研究区域叶绿素 a—活性磷酸盐的变化关系与叶绿素 a—硝氮整体上相似,即叶绿素 a 浓度达到当地峰值的时间段内两者呈显著负相关,而在其他时段无明显相关性特征。不同的是,图 2-13 (c)中 2014 年 7 月—9 月测站点 GX06 的叶绿素 a 浓度与活性磷酸盐的月际变化呈正相关,且两者的峰值都出

现在 2014 年 7 月。




图 2-13 重点监测区域叶绿素 a 浓度与活性磷酸盐的月际变化及相关性：(a) 测站点 GX03；(b) 测站点 GX04；(c) 测站点 GX06；(d) 测站点 GX09；(e) 测站点 GX10；(f) 测站点 GX12。

(三) 叶绿素 a 浓度与水温

如图 2-14 所示，重点监测区域内的水温整体呈季节性周期变化，其中在每年的 5 月—9 月最高，整体稳定在 30 °C 左右。其中，在 2014 年的测站点 GX03、2013 年的测站点 GX04、2014 年的测站点 GX09，以及 2014 年的测站点 GX10，叶绿素 a—水温之间的月际变化呈显著正相关，大部分测站点所在海域内叶绿素 a 浓度峰值都分布在水温较高的 5 月—9 月，如 2013 年 9 月的 GX03、2014 年 8 月的 GX04、2014 年 8 月的 GX06、2013 年 5 月—6 月和 2014 年 6 月的 GX09，以及 2013 年 6 月和 9 月的 GX10。此外，在水温仅有 18 °C 左右的 2013 年 12 月，测站点 GX09 和 GX10 所在海域的月均叶绿素 a 浓度也分别达到 9.903 $\mu\text{g}\cdot\text{L}^{-1}$ 和 9.011 $\mu\text{g}\cdot\text{L}^{-1}$ 的峰值水平，该结果可能与廉州湾内棕囊藻等有害藻华原因种具有广温性 (eurythermic) 特征有关^[127]。




图 2-14 重点监测区域叶绿素 a 浓度与水温的月际变化及相关性: (a) 测站点 GX03; (b) 测站点 GX04; (c) 测站点 GX06; (d) 测站点 GX09; (e) 测站点 GX10; (f) 测站点 GX12。

(四) 叶绿素 a 浓度与盐度

如图 2-15 所示, 受陆源淡水输入和降水的影响, 重点监测区域内距离岸线较近的测站点 GX03、GX04、GX06、GX09, 以及 GX10 所在海域内盐度都呈现出干季高一湿季低的周期性特征, 在每年的 4 月—7 月间呈大幅下降趋势, 7 月—10 月回升。其中, 图 2-15 (b) 中的测站点 GX04 所在海域的盐度季节性变化最为明显, 月均盐度变化范围在 5—23 psu 之间。然而, 与同样处于季节性变化的水温不同, 大部分测站点 (GX06、GX09、GX10, 以及 GX12) 所在海域内叶绿素 a—盐度之间主要呈极弱正/负相关。当叶绿素 a 浓度达到峰值时, 同时段内的盐度通常处于当地中等水平范围。例如图 2-15 (a) 中测站点 GX03 所在海域在 2013 年 9 月叶绿素 a 浓度达到 $12.948 \mu\text{g}\cdot\text{L}^{-1}$ 时, 同时段的盐度为 26.526 psu, 属当地整体盐度范围内 (24—30 psu) 中等水平; 同理, 图 2-15 (d) 中测站点 GX09 所在海域在 2013 年 5 月 ($11.785 \mu\text{g}\cdot\text{L}^{-1}$)、6 月 ($12.355 \mu\text{g}\cdot\text{L}^{-1}$)、12 月 ($9.903 \mu\text{g}\cdot\text{L}^{-1}$), 以及 2014 年 6 月 ($9.985 \mu\text{g}\cdot\text{L}^{-1}$), 同时段内的盐度分别为 25.726 psu、22.525 psu、23.970 psu, 以及 22.083 psu, 属当地整体盐度范围内 (18—28 psu) 中低水平。





图 2-15 重点监测区域叶绿素 a 浓度与盐度的月际变化及相关性: (a) 测站点 GX03; (b) 测站点 GX04; (c) 测站点 GX06; (d) 测站点 GX09; (e) 测站点 GX10; (f) 测站点 GX12。

(五) 叶绿素 a 浓度与溶解氧

如图 2-16 所示, 受水温的季节性变化的影响, 各测站点所在海域内溶解氧的月际变化整体呈夏季低—冬季高的特征, 整体范围在 $5.8-9.9 \text{ mg} \cdot \text{L}^{-1}$ 之间, 整体处于正常范围。在叶绿素 a 浓度变化幅度较大的 5 月—9 月, 各测站点叶绿素 a—溶解氧之间整体呈显著正相关, 其中图 2-15 (d) 中测站点 GX09 最为明显。







图 2-16 重点监测区域叶绿素 a 浓度与溶解氧的月际变化及相关性:(a) 测站点 GX03;(b) 测站点 GX04;(c) 测站点 GX06;(d) 测站点 GX09;(e) 测站点 GX10;(f) 测站点 GX12。

(六) 叶绿素 a 浓度与 pH 值

如图 2-17 所示, pH 值在各测站点的月际变化幅度较小, 除盐度波动很大的测站点 GX04 外, 其他海域的月际 pH 值变化幅度不超过 0.4, 未发现严重影响浮游植物生长的 pH 值异常情况 ($\text{pH} < 6$ 或 $\text{pH} > 9$)。在大部分海域内, 叶绿素 a—pH 值之间通常呈显著正相关, 说明水体 pH 值受当地浮游植物的呼吸/光合作用的影响不可忽视。






图 2-17 重点监测区域叶绿素 a 浓度与 pH 值的月际变化及相关性: (a) 测站点 GX03; (b) 测站点 GX04; (c) 测站点 GX06; (d) 测站点 GX09; (e) 测站点 GX10; (f) 测站点 GX12。

(七) 叶绿素 a 浓度与浊度

如图 2-18 所示, 研究区域内叶绿素 a—浊度之间通常呈极弱正/负相关。当叶绿素 a 浓度达到峰值时, 同时段内的浊度最高可达 36.513 NTUs (2014 年 6 月的 GX09), 最低仅为 1.971 NTUs (2013 年 9 月的 GX03)。该结果表明, 研究区域内 0—50 NTUs 范围的浊度变化对浮游植物光合作用及生长的影响效果可能不显著^[128], 而叶绿素 a 浓度的变化也不一定会对水体浊度产生直接影响。




图 2-18 重点监测区域叶绿素 a 浓度与浊度的月际变化及相关性: (a) 测站点 GX03; (b) 测站点 GX04; (c) 测站点 GX06; (d) 测站点 GX09; (e) 测站点 GX10; (f) 测站点 GX12。

2.3.3 藻华高发区域的综合环境特征

有研究表明,陆源的淡水输入引发的水体富营养化是造成近岸河口海域有害藻华频发的主要因素^[129]。在本研究区域内,位于廉州湾南流江河口的测站点 GX09 所在海域的年际叶绿素 a 浓度和综合营养水平(年均活性磷酸盐水平最高,硝氮水平仅低于茅尾海)均较高,这一现象与以往研究中对叶绿素 a—营养盐之间关系的主流观点基本一致^[130]。然而,茅尾海(GX04)作为营养水平较高且水质问题最严重(多为劣四类海水水质)的海域,其年均叶绿素 a 浓度低于营养水平较低、水质较好(多为一类和二类海水水质)的防城港防城江河口南部海域(GX03)。因此,水质等级和营养水平的高低不能作为评估当地藻华风险的唯一依据。

本研究区域内叶绿素 a 浓度水平较高的防城港、廉州湾,以及铁山港的岸线边界相对开阔,在防城江、南流江,以及南康江等陆源淡水输入影响下,常年处于 18—28 psu 左右的中盐度水平,具有干季高一湿季低的季节性特征。相比之下,由于钦江和茅岭江的淡水输入和较为封闭的岸线边界条件影响,茅尾海的整体盐度较低,仅在 5—23 psu 之间。同时,Huang 等人^[131]通过水动力数值模拟研究和观测发现,茅尾海在洪潮期的最大表面海水流速可超过 $2\text{ m}\cdot\text{s}^{-1}$,而防城江河口附近海域的海表面最大水流速度仅为 $0.2\text{ m}\cdot\text{s}^{-1}$ ^[132]。因此,茅尾海的低盐度环境和高活跃度的水动力条件可能是抑制当地藻类生长和聚集的主要原因,导致该海域的叶绿素 a 水平显著低于综合营养水平更低的防城港。此外,尽管图 2-11 的相关性分析结果和图 2-14 的叶绿素 a—水温的月际变化都表明,水温的季节性变化(17—32 °C)对当地水体叶绿素 a 浓度的影响显著,但图 2-6 的空间分布特征和图 2-14 的季节性变化都表明,各测站点的水温在相同时段内的差异较小,因此不足以对研究区域内叶绿素 a 浓度的空间分布特征产生直接影响。

综上所述,除营养水平外,盐度可能是影响近岸海域藻华风险分布的另一主要因素,廉州湾的叶绿素 a 浓度水平显著高于其他海域的主要原因可能是其高营养水平和中盐度条件共同导致的。因此,在近岸海域有害藻华监测方案的制定过程中,需优先考虑将岸线开阔、营养水平较高,以及中盐度的河口海域内海表面流速相对较低的区域作为重点监测目标。

2.3.4 引起有害藻华爆发的前提条件

表 2-3 统计了重点研究区域内叶绿素 a 浓度达到峰值时的主要环境特征。其中,如图 2-12 和 2-13 所示,由于浮游藻类在生长过程中会吸收大量营养盐^[133],使得各海域内叶绿素 a 浓度大幅上升时,硝氮与活性磷酸盐浓度通常会出现大幅下降,因此在叶绿素 a 峰值时段内的月均营养盐数据无法直接反映实际营养水平。

根据年际空间分布特征(图 2-4 和图 2-5)可知,除 2013 年 9 月的防城港(GX03)以外,叶绿素 a 浓度的峰值时段主要出现在综合营养水平较高(硝氮 $> 110 \mu\text{g}\cdot\text{L}^{-1}$ 且活性磷酸盐 $> 10 \mu\text{g}\cdot\text{L}^{-1}$)的海域。然而,尽管高营养水平是藻华爆发的重要前提条件之一,但由于有害藻华的爆发/消退周期通常较短^[134],仅靠月际变化无法有效呈现浮游植物对营养盐的吸收过程。因此,针对叶绿素 a—营养盐之间的具体作用机制需要在更小的时间尺度下进行分析。

在亚热带季风气候影响下,各测站点所在海域内叶绿素 a 浓度的峰值时段主要出现在水温高达 $30\text{ }^{\circ}\text{C}$ 左右且盐度处于当地中低水平的湿季时期(5 月—9 月)。图 2-11 中相关性分析结果表明,尽管大部分海域内叶绿素 a—水温之间整体呈显著正相关,但在水温长期稳定在 $30\text{ }^{\circ}\text{C}$ 左右的 5 月—9 月期间,叶绿素 a 浓度的变化幅度最大。其中,由图 2-15 可知,叶绿素 a 浓度的峰值时段主要出现盐度处于当地海域中低水平的 5 月—6 月或 8 月—9 月。此外,在月均水温低于 $20\text{ }^{\circ}\text{C}$ 且盐度处于当地中低水平(23.970 psu 和 26.648 psu)的 2013 年 12 月,综合营养水平最高的廉州湾内(GX09 和 GX10)叶绿素 a 浓度依旧超过 $9 \mu\text{g}\cdot\text{L}^{-1}$ 。因此,除高水温和高营养水平以外,中盐度环境可能是诱发藻华爆发的另一重要前提条件。

综上所述,高营养水平、高水温,以及中盐度条件会为当地藻华爆发提供有利的环境,当海水环境满足其中至少两项前提条件时,有害藻华风险会大幅上升,使得月均叶绿素 a 浓度从平时的 $2\text{—}5 \mu\text{g}\cdot\text{L}^{-1}$ 上升至 $10 \mu\text{g}\cdot\text{L}^{-1}$ 左右。例如在 2013 年,尽管防城港(GX03)所在海域的综合营养水平相对较低,但在水温高达 $29.05\text{ }^{\circ}\text{C}$ 、盐度为 26.526 psu 的 9 月,叶绿素 a 浓度从 8 月的 $5.283 \mu\text{g}\cdot\text{L}^{-1}$ 激增至 $12.948 \mu\text{g}\cdot\text{L}^{-1}$ 。

表 2-3 各测站点叶绿素 a 浓度峰值时段主要环境特征统计(√为符合,×为不符合)

序号	测站点	年	月	叶绿素 a 浓度 ($\mu\text{g}\cdot\text{L}^{-1}$)	高营养 水平	高水温	中盐度
1	GX03	2013	9	12.948	×	√	√
2	GX04	2014	8	7.751	√	√	×
3	GX06	2014	8	14.407	√	√	×
4			5	11.785		√	√
5	GX09	2013	6	12.355	√	√	√
6			12	9.903		×	√
7		2014	6	9.985		√	√
8			6	8.886		√	√
9	GX10	2013	9	8.796	√	√	√
10			12	9.011		×	√

2.4 本章小结

本章基于广西壮族自治区环境监测中心站提供的 2013—2014 年水质监测数据,采用空间插值方法分析了北部湾近岸海域环境要素的时空分布特征,并结合相关性分析结果探讨了藻华风险上升的前提条件,主要结论如下:

1) 叶绿素 a 浓度的空间分布特征主要受营养水平和盐度的双重影响。廉州湾南流江河口海域内叶绿素 a 浓度水平显著高于其他海域的主要原因可能是高营养水平和中盐度条件共同导致的。

2) 在有害藻华监测方案制定过程中,需优先考虑将岸线开阔、营养水平较高、中盐度,以及海表面流速相对较低的河口海域作为重点监测目标。

3) 各海域叶绿素 a 浓度的峰值时段主要出现在水温达到 30 °C 且盐度处于年内中低水平的 5 月—6 月和 8 月—9 月。然而,在兼具高营养水平和中盐度的廉州湾,藻华风险在水温不足 20 °C 时依旧长期维持在较高水平。

4) 在北部湾近岸海域内,高营养水平、高水温和中盐度是藻华爆发的重要前提条件。当海水环境满足其中至少两项时,有害藻华风险会大幅上升,月均叶绿素 a 浓度会从平时的 2—5 $\mu\text{g}\cdot\text{L}^{-1}$ 上升至 10 $\mu\text{g}\cdot\text{L}^{-1}$ 左右。

第3章 影响藻华动态变化的环境因子特征选择

3.1 引言

有害藻华的爆发/消退周期通常在1—5日之间，少部分大型藻华事件的持续时长能达到20—30日左右^[135]。因此，针对藻华动态影响机制的研究需在以日或小时为单位的时间尺度下进行。本章选取了研究区域内多个藻华风险较高的时段作为研究案例，评估各案例中环境因子对叶绿素a浓度影响的重要性，识别并提取影响藻华动态变化的关键控制因素，为后续建立有害藻华预测模型及其特征变量的选择提供重要参考。

3.2 研究数据与方法

3.2.1 藻华研究案例的选取

基于第2章表2-3对叶绿素a峰值时段的统计，本章在研究数据中选取了10个藻华高风险时段作为研究案例，如表3-1所示。其中：案例1为2013年9月1日至9月30日的测站点GX03；案例2为2014年8月1日至8月14日的测站点GX04；案例3为2014年8月1日至8月14日的测站点GX06；案例4为2013年5月1日至5月31日的测站点GX09；案例5为2013年6月1日至6月8日的测站点GX09；案例6为2013年12月1日至12月31日的测站点GX09；案例7为2014年6月1日至6月8日的测站点GX09；案例8为2013年6月1日至6月8日的测站点GX10；案例9为2013年9月1日至9月30日的测站点GX10；案例10为2013年12月1日至12月31日的测站点GX10。

表3-1 研究区域内藻华高风险时段研究案例信息统计

研究案例	测站点	年份	时间段
1	GX 03	2013	09-01 至 09-30
2	GX 04	2014	08-01 至 08-14
3	GX 06	2014	08-01 至 08-14

续表 3-1 研究区域内藻华高风险时段研究案例信息统计

研究案例	测站点	年份	时间段
4	GX 09	2013	05-01 至 05-31
5			06-01 至 06-08
6			12-01 至 12-31
7		2014	06-01 至 06-08
8	GX 10	2013	06-01 至 06-08
9			09-01 至 09-30
10			12-01 至 12-31

3.2.2 环境特征重要性评估

本章通过建立随机森林（Random Forest, RF）回归模型，以叶绿素 a 浓度和选定的环境因子分别作为因变量和自变量，对各研究案例中的环境因子进行特征重要性评估。随机森林是一个包含多个决策树的集成学习算法，是由 Breiman^[136]于 2001 年提出。该算法通过构建多个决策树并将它们的预测结果进行集成来进行回归任务^[137]。在随机森林中，每一棵决策树都是独立且在随机选择的子样本中进行训练的，可有效减少过拟合的风险。随机森林回归通过将多个决策树的预测结果进行加权平均，得到最终的回归结果。在随机森林回归模型中，每个决策树都会选择一个最佳分割点时会考虑到数据集中所有特征，并计算每个特征对于分类或回归任务的贡献程度，这种贡献程度被称作特征重要性（Feature Importance）^[137]。特征重要性的常用计算方法是采用基尼（Gini）指数，具体计算方式如下：

$$Gini(p) = \sum_{k=1}^K p_k(1-p_k) = 1 - \sum_{k=1}^K p_k^2 \quad (3-1)$$

其中， K 为特征变量类别总数， p_k 为类别 k 的样本权重。特征变量 X_j 在节点 m 上的重要性的 Gini 指数变化量为：

$$VIM_{jm}^{(Gini)} = GI_m - GI_l - GI_r \quad (3-2)$$

其中， GI_l 和 GI_r 分别表示分枝后两个新节点的基尼指数。假设特征变量 X_j 在决策树 i 中出现的节点在集合 M 中， X_j 在第 i 棵树的重要性为：

$$VIM_{ij}^{(Gini)} = \sum_{m \in M} VIM_{jm}^{(Gini)} \quad (3-3)$$

假设该随机森林模型中有 n 棵决策树， X_j 在该模型中的特征重要性为：

$$VIM_j^{(Gini)} = \sum_{i=1}^n VIM_{ij}^{(Gini)} \quad (3-4)$$

最后，将求得特征重要性进行归一化处理后可得：

$$VIM_j = \frac{VIM_j}{\sum_{i=1}^n VIM_i} \quad (3-5)$$

其中，分母为所有特征增益之和，分子为特征 j 的基尼指数。

随机森林具有准确性高、不易过拟合、易于并行化等优点，适合分析具有非线性、高维度特征的数据集^[137]。第2章对环境要素时空分布特征的分析表明，研究区域内叶绿素 a 浓度与其他环境要素之间无显著线性关系，而本研究的数据集包括水温、营养盐等多个环境要素，因此兼具非线性与高维度特征，适于采用随机森林回归方法进行分析。

3.2.3 环境因子的初步筛选

多项研究结论表明，硝氮^[138]、活性磷酸盐^[139]、水温^[9]和盐度^[123]都是影响藻华动态变化的重要环境因素。同时，水体浊度的变化对藻类光合作用及其生物量的影响同样不可忽视^[140]。图 2-11 的相关性分析结果和图 2-18 的月际变化关系都表明，研究区域内浊度与叶绿素 a 浓度之间相关性较弱，因此不会直接受叶绿素 a 浓度的反向影响。然而，水体中的溶解氧和 pH 值通常是响应浮游藻类呼吸/光合作用的重要指标，藻类生物量的变化会对溶解氧与 pH 值产生直接影响^[141]。第2章图 2-11 的相关性分析结果表明，研究区域内叶绿素 a 浓度通常与溶解氧/pH 值呈显著正相关，且数据集中未发现缺氧（溶解氧 $< 2 \text{ mg} \cdot \text{L}^{-1}$ ）或异常 pH 值（ $\text{pH} < 7.0$ 或 $\text{pH} > 8.5$ ）等严重影响藻类生长的极端情况。说明在本研究的数据集中，溶解氧和 pH 值通常会受叶绿素 a 浓度的反向影响，因此不能作为影响叶绿素 a 浓度的环境因子。综上所述，本章选择硝氮、活性磷酸盐、水温、盐度，以及浊度作为各研究案例中影响叶绿素 a 浓度的环境因子。

3.3 结果与讨论

3.3.1 藻华动态的环境因子特征识别

（一）研究案例 1：测站点 GX03 2013 年 9 月 1 日—9 月 30 日

如图 3-1 所示，叶绿素 a 浓度在 9 月 8 日—9 月 9 日期间从原先的 $10 \mu\text{g} \cdot \text{L}^{-1}$ 左右大幅上升至 $25 \mu\text{g} \cdot \text{L}^{-1}$ 以上，随后在 9 月 16 日—9 月 21 日期间回落至 $12 \mu\text{g} \cdot \text{L}^{-1}$ 以内。环境因子中，盐度对叶绿素 a 浓度影响最大，特征重要性达到 58.8%，两者呈显著强负相关。除盐度以外，硝氮和水温也对叶绿素 a 浓度影响占据重要比

重, 分别为 17.1% 和 12.7%。其中, 在叶绿素 a 浓度大幅上升至超过 $30 \mu\text{g}\cdot\text{L}^{-1}$ 的前半月, 盐度稳定在 25 psu 左右, 随着后半月盐度逐渐上升至 29 psu, 叶绿素 a 浓度逐渐回落。




图 3-1 2013 年 9 月 1 日—9 月 30 日测站点 GX03 各项环境因子对叶绿素 a 浓度变化的特征重要性、变化趋势, 以及斯皮尔曼相关性系数 (ρ)。

(二) 研究案例 2: 测站点 GX04 2014 年 8 月 1 日—8 月 14 日

如图 3-2 所示, 叶绿素 a 浓度的整体水平自 8 月 7 日起由先前的 $2\text{—}5 \mu\text{g}\cdot\text{L}^{-1}$ 上升至 $10\text{—}25 \mu\text{g}\cdot\text{L}^{-1}$, 并于 8 月 13 日回落。环境因子中, 硝氮对叶绿素 a 的影响最为显著, 特征重要性达到 40%, 两者呈显著强负相关。同时, 盐度和浊度的特征重要性也分别达到 25.4% 和 15.6%。在 8 月 7 日叶绿素 a 浓度开始大幅上升前, 硝氮与活性磷酸盐浓度出现了不同程度的下降, 其中硝氮的下降更为明显, 8 月 1 日起从 $100 \mu\text{g}\cdot\text{L}^{-1}$ 左右下降至 $25 \mu\text{g}\cdot\text{L}^{-1}$ 以内。此外, 与其他研究案例不同的是, 该时段内水温与叶绿素 a 浓度呈显著弱负相关, 其中在水温整体超过 32°C 的 8 月 1 日—8 月 7 日期间, 叶绿素 a 浓度始终稳定在 $2\text{—}5 \mu\text{g}\cdot\text{L}^{-1}$ 的较低水平, 直到 8 月 7 日水温下降至低于 32°C 后, 叶绿素 a 浓度开始大幅上升。




图 3-2 2013 年 8 月 1 日—8 月 14 日测站点 GX04 各项环境因子对叶绿素 a 浓度变化的特征

重要性、变化趋势，以及斯皮尔曼相关性系数 (ρ)。

(三) 研究案例 3: 测站点 GX06 2014 年 8 月 1 日—8 月 14 日

如图 3-3 所示，叶绿素 a 浓度在 8 月 1 日起迅速上升，持续到 8 月 12 日开始回落。环境因子中，水温对叶绿素 a 浓度影响的特征重要性最高，达 51.8%，但两者仅呈较为显著的弱正相关。同时，硝氮和浊度的特征重要性也分别达到 14.6% 和 15.2%，但与叶绿素 a 浓度无显著相关性。其中，在叶绿素 a 浓度大幅上升的 8 月 1 日—8 月 3 日期间内，水温和硝氮分别从 33 °C 和 230 $\mu\text{g}\cdot\text{L}^{-1}$ 下降至 31 °C 和 10 $\mu\text{g}\cdot\text{L}^{-1}$ 左右。




图 3-3 2013 年 8 月 1 日—8 月 14 日测站点 GX06 各项环境因子对叶绿素 a 浓度变化的特征重要性、变化趋势，以及斯皮尔曼相关性系数 (ρ)。

(四) 研究案例 4: 测站点 GX09 2013 年 5 月 1 日—5 月 31 日

如图 3-4 所示，5 月 16 日起叶绿素 a 浓度在开始从 2—5 $\mu\text{g}\cdot\text{L}^{-1}$ 大幅上升至 30—50 $\mu\text{g}\cdot\text{L}^{-1}$ 之间，随后在 5 月 19 日—5 月 26 日呈逐步下降趋势，月末回落至月初的水平。在此期间，水温对叶绿素 a 浓度影响的特征重要性最高，达到 57.1%，两者呈显著强正相关。同时，硝氮和盐度的特征重要性也分别达到 18.6% 和 14.5%，与叶绿素 a 浓度分别呈较为显著的弱正相关和弱负相关。其中，在 5 月 1 日—5 月 16 日叶绿素 a 浓度较低的时段内，水温从月初的 25 °C 左右缓慢上升至 31 °C，并在叶绿素 a 浓度大幅上升后稳定在 30—32 °C 之间。此外，在 5 月 16 日叶绿素 a 浓度激增之前，硝氮浓度先后出现了大幅度的上升和下降。该结果可能是由于当地水环境受沿岸上升流 (upwelling) 的影响，使得 5 月 15 日—5 月 16 日期间浮游植物在海面大幅聚集^[142]，并在藻华爆发的前期大幅吸收硝氮等无机态营养盐所致^[143]。




图 3-4 2013 年 5 月 1 日—5 月 31 日测站点 GX09 各项环境因子对叶绿素 a 浓度变化的特征重要性、变化趋势，以及斯皮尔曼相关性系数 (ρ)。

(五) 研究案例 5: 测站点 GX09 2013 年 6 月 1 日—6 月 8 日

如图 3-5 所示，叶绿素 a 浓度在 8 日内先后在 6 月 1 日、6 月 3 日，以及 6 月 5 日出现 3 次大幅震荡。环境因子中，水温对叶绿素 a 浓度的影响最为显著，特征重要性达 72%，两者呈显著中度正相关。其中，水温与叶绿素 a 浓度随时间的变化趋势高度同步，且在 32 °C 左右时叶绿素 a 浓度达到最高（约 35 $\mu\text{g}\cdot\text{L}^{-1}$ ）。此外，该时段内的叶绿素 a 浓度与无机态营养盐之间无显著相关性，其中活性磷酸盐在叶绿素 a 浓度上升期间始终处于 1—5 $\mu\text{g}\cdot\text{L}^{-1}$ 的较低水平。




图 3-5 2013 年 6 月 1 日—6 月 8 日测站点 GX09 各项环境因子对叶绿素 a 浓度变化的特征重要性、变化趋势，以及斯皮尔曼相关性系数 (ρ)。

(六) 研究案例 6: 测站点 GX09 2013 年 12 月 1 日—12 月 31 日

如图 3-6 所示，叶绿素 a 浓度在 12 月 3 日—12 月 16 日期间出现极大起伏，最高时达到约 50 $\mu\text{g}\cdot\text{L}^{-1}$ ，并在 12 月底的短时间内再次出现小幅度升高。环境因子中，水温和活性磷酸盐的特征重要性远高于另外 3 个环境因子，分别达到 45.5% 和 24.9%，与叶绿素 a 浓度分别呈显著中度正相关和显著中度负相关。在叶绿素

a 浓度大幅上升的前半月, 水温稳定在 20 °C 上下, 并在 12 月 10 日左右下降至 18 °C 以下。在此期间, 水温的下降可能是导致叶绿素 a 浓度大幅回落的主要原因。此外, 活性磷酸盐浓度在前半月叶绿素 a 浓度大幅上升前出现了小幅度的下降, 从 12 $\mu\text{g}\cdot\text{L}^{-1}$ 左右下降至大约 3 $\mu\text{g}\cdot\text{L}^{-1}$ 。该结果可能是浮游植物对营养盐的吸收受制于雷德菲尔德比率中大约 16:1 的氮磷摩尔比^[144], 使得活性磷酸盐的吸收现象需在大量浮游植物聚集和生长过程中才能明显观测出来。




图 3-6 2013 年 12 月 1 日—12 月 31 日测站点 GX09 各项环境因子对叶绿素 a 浓度变化的特征重要性、变化趋势, 以及斯皮尔曼相关性系数 (ρ)。

(七) 研究案例 7: 测站点 GX09 2014 年 6 月 1 日—6 月 8 日

如图 3-7 所示, 叶绿素 a 浓度在 8 日内先后出现多次大幅度上升, 最高时接近 30 $\mu\text{g}\cdot\text{L}^{-1}$ 。环境因子中, 硝氮和活性磷酸盐的特征重要性最高, 分别达到 34.2% 和 21.6%。在叶绿素 a 浓度大幅上升前的 4 小时内, 硝氮和活性磷酸盐浓度出现多次大幅度下降, 其中硝氮更为明显。




图 3-7 2014 年 6 月 1 日—6 月 8 日测站点 GX09 各项环境因子对叶绿素 a 浓度变化的特征重要性、变化趋势, 以及斯皮尔曼相关性系数 (ρ)。

(八) 研究案例 8: 测站点 GX10 2013 年 6 月 1 日—6 月 8 日

如图 3-8 所示, 叶绿素 a 浓度在 6 月 2 日至 6 月 5 日间先后出现 4 次大幅度上升, 最高时超过 $30 \mu\text{g}\cdot\text{L}^{-1}$ 。环境因子中, 活性磷酸盐、水温, 和盐度的特征重要性相对较高, 分别达到 34.6%、24.1%和 18.7%。其中, 在叶绿素 a 浓度大幅上升期间, 监测到活性磷酸盐浓度出现小幅度下降。




图 3-8 2013 年 6 月 1 日—6 月 8 日测站点 GX10 各项环境因子对叶绿素 a 浓度变化的特征重要性、变化趋势, 以及斯皮尔曼相关性系数 (ρ)。

(九) 研究案例 9: 测站点 GX10 2013 年 9 月 1 日—9 月 30 日

如图 3-9 所示, 叶绿素 a 浓度从 9 月 4 日开始大幅上升, 并且在 9 月 4 日至 9 月 20 日之间出现多次大幅度的波动。在本研究案例的 5 个环境因子中, 水温的特征重要性最高, 达到 53.1%, 与叶绿素 a 浓度呈显著强正相关。其他 4 个环境因子特征重要性差别不大, 都在 10% 左右。此外, 硝氮和活性磷酸盐浓度都与叶绿素 a 浓度呈较为显著的弱负相关, 且在叶绿素 a 浓度上升前都出现了不同程度的下降。




图 3-9 2013 年 9 月 1 日—9 月 30 日测站点 GX10 各项环境因子对叶绿素 a 浓度变化的特征重要性、变化趋势, 以及斯皮尔曼相关性系数 (ρ)。

(十) 研究案例 10: 测站点 GX10 2013 年 12 月 1 日—12 月 31 日

如图 3-10 所示, 叶绿素 a 浓度在月初呈整体上升趋势, 并在 12 月 9 日至 15 日之间达到最高水平后迅速回落。环境因子中水温和盐度的特征重要性较高, 分别为 46.2% 和 26.9%, 与叶绿素 a 浓度之间分别呈显著中度正相关和显著弱正相关。其中, 在叶绿素浓度升高的前半月, 水温和盐度相对稳定, 分别在 20 °C 和 26 psu 左右。




图 3-10 2013 年 12 月 1 日—12 月 31 日测站点 GX10 各项环境因子对叶绿素 a 浓度变化的特征重要性、变化趋势, 以及斯皮尔曼相关性系数 (ρ)。

综上所述, 水温在大部分研究案例中 (案例 3—案例 6、案例 9—案例 10) 对叶绿素 a 浓度的影响最为显著, 特征重要性通常达到 50—70%。同时在部分研究案例中, 硝氮 (案例 2、案例 7)、活性磷酸盐 (案例 8), 以及盐度 (案例 1) 的特征重要性也达到最高权重。相比之下, 浊度对叶绿素 a 浓度的影响程度相对较低, 其特征重要性在所有研究案例中都未超过 20%。此外, 叶绿素 a 浓度在大部分研究案例中与水温呈显著正相关 (案例 1、案例 3—案例 6、案例 8—案例 10), 与无机态营养盐呈负相关 (案例 1—案例 3、案例 5—案例 9)。

3.3.2 引发藻华事件的最适温盐条件

水温会影响植物的代谢和对矿物质的吸收过程, 是影响藻类生长状态的关键控制因素^[145]。环境因子特征重要性分析结果表明, 水温对叶绿素 a 浓度变化的影响最为显著, 其特征重要性最高可达到 72% (案例 5)。其中, 在低于 32 °C 时, 水温随时间的变化趋势通常与叶绿素 a 浓度高度同步, 两者之间呈显著正相关, 相关性系数 ρ 最高可达到 0.671 (案例 4)。而当水温超过 32 °C 时, 叶绿素 a 浓度通常会因水温的上升而下降, 两者之间呈现负相关关系 (如案例 2)。该结果与 Gobler^[9]通过长期观测得出的结论一致, 即在既定海域内, 因水温升高而促

进有害藻华事件发生的必要条件是当下的温度低于支持当地浮游植物群落生长的最高值。为进一步确定本研究区域内藻类的最佳生长温度,本章选取了 8 个(案例 1—5、案例 7—9)整体水温较高的研究案例,绘制了叶绿素 a—水温关系散点图,如图 3-11 所示。其中,当水温在 24—30 °C 之间时,叶绿素 a 浓度的整体分布逐渐走高,于 30—32 °C 之间达到最高水平,并在超过 32 °C 后出现明显回落趋势。该结果表明,研究区域内浮游植物群落的最佳生长温度在 30—32 °C 之间,最高不超过 32 °C。




图 3-11 叶绿素 a—水温关系散点图。

海水盐度是直接影响藻类自身渗透压水平的重要因素,盐度超出适宜范围时会导致细胞脱水或水化过度,从而限制藻类的代谢和生长速率^[146]。环境因子特征重要性评估结果表明,盐度同水温和营养盐一样是影响叶绿素 a 浓度的重要因素之一,但两者之间的相关性在不同研究案例中存在显著差异。其中,案例 1 中,盐度对叶绿素 a 浓度影响的特征重要性最高,两者在 24—30 psu 的盐度范围内呈显著强负相关。当叶绿素 a 浓度大幅上升时,盐度整体稳定在 25 psu 左右。而在整体盐度水平最低 (< 20 psu) 的案例 2 中,盐度在特征重要性达到 25.4% 的情况下与叶绿素 a 呈显著正相关。为进一步探讨研究区域内浮游藻类的最适生长盐度范围,本章基于各研究案例的监测数据,统计了各时刻叶绿素 a—盐度的值并绘制了散点图,如图 3-13 所示。其中,当盐度在 3—22 psu 范围内时,随盐度升高,叶绿素 a 浓度最大值缓慢升高,并在 22—28 psu 盐度范围内呈现最高水平。该结果表明,22—28 psu 的盐度范围可能是北部湾近岸海域棕囊藻^[22]以及硅藻^[147]等有害藻华原因种的最佳生长盐度。然而,与水温不同的是,当盐度超过 28 psu 时,整体叶绿素 a 浓度水平迅速降低,并且在盐度超过 30 psu 后几乎未出

现叶绿素 a 浓度超过 $10 \mu\text{g}\cdot\text{L}^{-1}$ 的情况, 说明盐度过高对大部分藻类的生长存在显著的抑制作用^[99], 因此 30 psu 左右的盐度条件可能是涠洲岛附近海域 (GX12) 整体叶绿素 a 浓度水平较低的主要原因之一。





图 3-12 叶绿素 a—盐度关系散点图。

3.3.3 藻华爆发的关键信号特征提取


普遍的观点认为, 营养盐是促进藻类生长的主要驱动因素^[148]。第 2 章叶绿素浓度、硝氮和活性磷酸盐的年际空间分布特征表明, 高营养水平是有害藻华风险上升的一个重要前提条件。然而, 大部分研究案例中硝氮/活性磷酸盐—叶绿素 a 之间呈显著负相关, 说明在藻华爆发前, 浮游植物对营养盐的吸收作用会使得当地海域硝氮和活性磷酸盐的浓度出现大幅下降。其中硝氮的下降幅度可达到 $200 \mu\text{g}\cdot\text{L}^{-1}$ 以上, 例如在研究案例 3 的 8 月 1 日—8 月 3 日期间, 硝氮在 24 小时内从 $230 \mu\text{g}\cdot\text{L}^{-1}$ 下降到 $10 \mu\text{g}\cdot\text{L}^{-1}$ 左右。多项研究表明, 硝氮和活性磷酸盐是多种浮游藻类优先吸收的营养盐类型。例如, Lv 等人^[37]通过多项实验发现, 广泛分布于北部湾近岸海域的球形棕囊藻在生长过程中对硝酸盐的吸收具有显著优先性。此外, Boyd 和 Musig^[139]也通过实验证明, 水体内浮游植物群落可在 24 小时内吸收大量活性磷酸盐。

为进一步提取研究区域内藻华爆发前的环境信号特征, 本章基于 10 个研究案例中的数据, 统计了不同水温和盐度范围内硝氮/活性磷酸盐浓度的下降和叶绿素 a 浓度大幅上升之间的时间间隔频次。如图 3-13 和图 3-14 所示, 研究区域内浮游植物对硝氮的吸收速率整体上略高于活性磷酸盐, 在叶绿素 a 浓度大幅上升前的 12 小时内, 硝氮浓度出现 25 次显著下降, 其中有 12 次在 4 小时内。而

在相同情况下，活性磷酸盐的大幅下降监测到 15 次，两者时间间隔在 4—8 小时之间的占比最多，共 8 次，而在 4 小时以内的仅 5 次。此外，藻类吸收营养盐的速率在不同水温和盐度条件下存在显著差异。以硝氮为例，如图 3-13 (a)所示，10 个研究案例中总计 19 次监测到硝氮下降与叶绿素 a 浓度上升之间的间隔不超过 8 小时，其中水温在 26—32 °C 的范围内频次为 13 次，占比最大；而在图 3-14 (a)中，有 11 次是在 22—28 psu 的最佳藻类生长盐度范围内，同样占比最高。




(a)




(b)

图 3-13 不同水温范围内营养盐浓度下降与叶绿素 a 浓度升高之间的间隔频次统计：

(a) 硝氮；(b) 活性磷酸盐。



(a)



(b)

图 3-14 不同盐度范围内营养盐浓度下降与叶绿素 a 浓度升高之间的间隔频次统计：

(a) 硝氮；(b) 活性磷酸盐。

综上所述，硝氮和活性磷酸盐等无机态营养盐浓度在短时间内的大幅下降可作为预测当地海域有害藻华的一个重要信号，而适宜的水温和盐度条件能够缩短营养盐吸收与藻华爆发之间的时间间隔。因此，为保证有害藻华预测工作的有效性和准确度，在一些高风险区域或时间段内的海洋环境监测中，数据采集的间隔需低于 4 小时，且单次的监测周期不能少于 24 小时。此外，在叶绿素 a 浓度回落并稳定在 $5 \mu\text{g}\cdot\text{L}^{-1}$ 以下的 1—5 日内，部分研究案例中能够监测到活性磷酸盐浓度有明显回升（如案例 5、案例 6，以及案例 8），该现象可能是有害藻华消退后大量浮游植物细胞被分解，从而释放的无机磷所致^[149]。因此，监测过程中叶绿素 a 浓度回落并稳定在正常浓度水平后的 1—5 日内活性磷酸盐浓度的回升

可被当作有害藻华事件结束的信号。

3.3.4 藻华预测模型的特征变量选取

目前,有害藻华的预测高度依赖于大量数据集支持下的人工智能预测模型^[69],从而容易忽视不同海域因环境差异导致的藻华形成机制的不同。由于有害藻华事件具有随机性和突发性等特点,因此在建立藻华预测模型并对其进行训练时,往往需要大范围长期的监测数据为基础才能有效保证预测准确度。这会导致在前期工作过程中产生大量的数据冗余,从而增加人力物力和时间成本。因此,掌握监测区域内有害藻华爆发前的关键环境特征,既是建立藻华预测模型的必要条件,也是制定合理的环境监测方案的基础前提。

第2章的环境要素时空分布特征和本章的10个研究案例分析结果表明,硝氮、活性磷酸盐、水温,以及盐度都是影响叶绿素a浓度的重要环境因子。其中,水温对叶绿素a浓度的影响最为显著,两者通常呈显著强正相关。然而,研究案例6和案例10表明,在水温仅20℃左右的12月,廉州湾(GX09和GX10)依旧存在较高的藻华爆发风险。相应地,硝氮和活性磷酸盐的急剧减少在不同的水温盐度条件下都是预测藻华爆发的重要信号。因此,虽然水温是研究区域内对藻华风险长期评估中最重要的影响因素,但硝氮和活性磷酸盐等无机态营养盐是短期内预测藻华的首要预测因子。此外,在不同的水温和盐度条件下,营养盐浓度下降与叶绿素a浓度上升之间的时间间隔存在显著差异,因此水温和盐度也是藻华预测中不可忽视的重要特征变量。相比之下,尽管浊度的变化会间接影响水体中浮游植物的光合作用,但本文在不同时空尺度下的数据分析结果中均未发现浊度与叶绿素a浓度存在显著的变化关系。造成该结果的主要原因可能是大部分浮游藻类的生长饱和(growth saturation)光强较低^[150],而且研究区域内0—50 NTUs的整体浊度水平造成的海水透光率下降在大部分情况下不足以让浅层海水的光照强度低于浮游植物的生长饱和强度,使得浊度在大部分研究案例中对叶绿素a浓度的变化影响较小,因此在后续的藻华预测研究中不考虑将浊度作为藻华预测模型的特征变量。

3.5 本章小结

本章基于第2章叶绿素a浓度和环境要素的时空分布特征,选取了各测站点藻华风险较高的时段作为研究案例,采用随机森林回归方法对硝氮、活性磷酸盐、水温、盐度和浊度5项环境因子进行了特征重要性分析,并结合环境因子与叶绿素a浓度之间的相关性,探讨了藻华爆发前后的主要环境信号特征,具体结论如

下:

1) 环境因子中, 水温的变化对浮游植物生长的影响最为显著, 研究区域内藻类的最佳生长温度在 30—32 °C 之间, 最高不超过 32 °C。

2) 盐度同水温和营养盐一样是影响藻华动态变化的重要因素, 北部湾近岸海域的藻华爆发事件通常发生在 22—28 psu 的“中盐度”范围内。

3) 在藻华爆发前的 24 小时内, 硝氮和活性磷酸盐浓度出现大幅度下降可作为藻华预测的关键信号。同时, 适宜的水温和盐度条件会将营养盐浓度下降与藻华爆发的间隔缩短至 4 小时以内。

4) 与水温、盐度, 和营养盐相比, 0—50 NTUs 范围内的浊度变化引起的海水透光率下降对藻类生长的影响程度相对较小, 因此在建立藻华预测模型时, 浊度作为特征变量的选择优先级较低。

第4章 基于环境因子的有害藻华预测及其原因种特征

4.1 引言

目前，机器学习技术在有害藻华预测中得到了广泛应用^[151]，基于藻华自身的特征选择合理的回归/分类方法是建立可靠预测模型的关键前提^[152]。本章基于第三章对环境因子特征选择的结果，以硝氮、活性磷酸盐、水温，以及盐度作为特征变量建立预测模型，对相关研究案例进行有害藻华预测分析，并探讨环境因素和原因种差异对有害藻华预测结果的影响。

4.2 研究数据与方法

4.2.1 北部湾有害藻华历史记录

表 4-1 统计了近年来北部湾近岸海域已被记录的有害藻华事件信息。其中，第 3 章的研究案例 5 在时间和地点上与表 4-1 中记录的发生于 2013 年 6 月的廉州湾（测站点 GX09）中肋骨条藻（硅藻）藻华相符。此外，2014 年 2 月发生于廉州湾的球形棕囊藻藻华期间由于叶绿素 a 浓度、溶解氧，以及 pH 值等常规水质监测指标未发现异常^[114]，通过海表面观测到囊体才得以鉴定，在本章作为案例 11 进行分析。

表 4-1 2000 年以来北部湾有害藻华事件历史记录^[153]

时间	海域	原因种（门类）	备注	鉴定方法
2004-2	廉州湾	水华微囊藻（蓝藻）	-	镜检法
2010-7	廉州湾	中肋骨条藻（硅藻）	-	镜检法
2011-4	钦州湾	夜光藻（甲藻）	-	镜检法
2011-11	廉州湾	球形棕囊藻（定鞭藻）	-	海表面观测
2013-6	廉州湾	中肋骨条藻（硅藻）	案例 5	镜检法
2014-2	铁山港	球形棕囊藻（定鞭藻）	-	海表面观测
2014-2	廉州湾	球形棕囊藻（定鞭藻）	常规监测未发现异常^[114]（案例 11）	海表面观测

4.2.2 藻华/常态二分类预测方法

由于有害藻华具有随机性和非线性特征,使得基于叶绿素 a 浓度或藻类生物量的藻华预测存在较大挑战。因此,基于关键环境因子作为特征变量采用分类的方法是一种合理有效的藻华预测手段^[154]。如表 4-2 所示,在我国近岸海域有害藻华风险等级分类中,当叶绿素 a 浓度 $\geq 10 \mu\text{g}\cdot\text{L}^{-1}$ 时,风险指数 $D_R=10$,表明该海域即将或已经发生有害藻华事件,需发布有害藻华红色(一级)预警并随时准备启动应急预案^[155]。因此在中国近岸海域,通常将叶绿素 a 浓度 $10 \mu\text{g}\cdot\text{L}^{-1}$ 作为对有害藻华事件预测的参考阈值^[156]。

本章以叶绿素 a 浓度 $10 \mu\text{g}\cdot\text{L}^{-1}$ 作为分类阈值,将 10 个研究案例中水体状态分为“藻华”($\geq 10 \mu\text{g}\cdot\text{L}^{-1}$)和“常态”($< 10 \mu\text{g}\cdot\text{L}^{-1}$),以硝氮、活性磷酸盐、水温,以及盐度作为特征变量,建立逻辑回归(Logistic Regression, LR)预测模型对各研究案例进行预测,探讨环境因子的变化在水体状态由“常态”转为“藻华”过程中的影响。逻辑回归是一种广义的线性回归预测模型,通常用来解决二分类问题,其实质是在寻找一个最优的拟合函数对某事件(有害藻华事件)的发生和影响因素(环境因子)之间的关系进行定量描述^[157]。对于二分类问题,逻辑回归算法采用对数概率比线函数进行拟合^[158],具体原理如下:

$$\ln \frac{P(Y=0|x)}{P(Y=1|x)} = \omega^T x \quad (4-1)$$

式中, x 为实例样本, ω 为代求系数, ω 的选择将使得实例属于各个类的概率之和等于 1, 即:

$$\sum_{j=0}^1 P(Y=j|x) = 1 \quad (4-2)$$

联立式(4-1)和式(4-2)可得:

$$\begin{cases} P(Y=0|x) = \frac{e^{\omega^T x}}{1 + e^{\omega^T x}} \\ P(Y=1|x) = \frac{1}{1 + e^{\omega^T x}} \end{cases} \quad (4-3)$$

式中, ω 可作为概率相关参数,按照对数极大似然估计方法进行计算,得出的损失函数如下:

$$L(\omega) = \sum_{j=0}^1 \sum_{i=0}^{N_j} \ln P(x_i^{(j)} | Y=j; \omega) + c \quad (4-4)$$

式中, N_j 为第 j 类事件的频数; $x_i^{(j)}$ 表示实例 x_i 属于第 j 类事件, c 为某一常量根据贝叶斯公式:

$$P(x_i^{(j)} | Y = m; \omega) = \frac{P(x_i^{(j)})P(Y = j | x_i^m; \omega)}{P(Y = j)} \quad (4-5)$$

得出目标函数：

$$L(\omega) = \sum_{j=0}^1 \sum_{i=0}^{N_j} \ln P(Y = j | x_i^{(j)}; \omega) + c \quad (4-6)$$

目标函数确定后，在点 x 处沿着 d 方向的变化率可用方向导数来表达。对于可微函数，方向导数等于梯度与方向的内积，即：

$$Df(x, d) = \nabla f_{(x)}^T d \quad (4-7)$$

因此，求函数在点 x 处的下降最快的方向，等同于求解非线性规划问题：

$$\begin{cases} \min f(x)^T d \\ s.t. |d| \leq 1 \end{cases} \quad (4-8)$$

根据柯西-施瓦兹不等式，可得：

$$|\nabla f(x)^T d| \leq |\nabla f(x)| |d| \leq |\nabla f(x)| \quad (4-9)$$

因此，式(4-8)可化简为：

$$\nabla f(x)^T d \leq -|\nabla f(x)| \quad (4-10)$$

逻辑回归模型的预测结果具有很好的可解释性，可通过回归系数的正负和大小推断特征变量对分类结果的影响程度，从而获得对问题的深入理解，因此适用于针对有害藻华等具有随机性与非线性特征的事件进行预测分析。

表 4-2 我国近岸海域有害藻华风险指数分类赋值标准^[155]

风险指数 (D_R)	原因种生物细胞 (个体) 参考密度 (cells·L ⁻¹)	叶绿素 a 浓度 (μg·L ⁻¹)
1	[0, 1×10 ⁴)	[0, 2)
2	[1×10 ⁴ , 5×10 ⁴)	[2, 3)
3	[5×10 ⁴ , 8×10 ⁴)	[3, 4)
4	[8×10 ⁴ , 1×10 ⁵)	[4, 5)
5	[1×10 ⁵ , 5×10 ⁵)	[5, 6)
6	[5×10 ⁵ , 1×10 ⁶)	[6, 7)
7	[1×10 ⁶ , 5×10 ⁶)	[7, 8)
8	[5×10 ⁶ , 8×10 ⁶)	[8, 9)
9	[8×10 ⁶ , 1×10 ⁷)	[9, 10)
10	[1×10 ⁷ , +∞)	[10, +∞)

4.2.3 蓝绿藻分布及优势种判定

蓝绿藻是我国北部湾近岸海域有害藻华的主要原因种之一，通常分布在盐度较低的河口海域^[159]。由蓝绿藻引发的有害藻华会释放毒素污染水源，对当地水生态环境造成严重破坏^[160]。本章的蓝绿藻生物量监测数据由广西壮族自治区环境监测中心站提供，该数据为监测站采用 YSI 6600 型多参数水质仪在各测站点进行浮标在线自动监测（同第 2 章 2.2.2）。该方法根据蓝藻体内特有的藻蓝蛋白进行定量监测，测量值代表水体中蓝藻门（*Cyanophyta*）的生物量，计量单位为 $\text{cells} \cdot \mu\text{L}^{-1}$ ^[161]。

北部湾近岸海域蓝绿藻的生物量分布如图 4-1 所示，研究区域内 2013 与 2014 年的蓝绿藻空间分布特征呈现出明显的近岸高一远岸低的特征。除茅尾海以外，蓝绿藻的整体的空间分布特征与叶绿素 a 浓度（第 2 章图 2-3）相近，但在部分海域存在差异。其中，叶绿素 a 浓度水平较低的茅尾海与钦州湾的蓝绿藻密度最高，测站点 GX04 在 2013 年和 2014 年的平均密度分别达到 $4.968 \text{ cells} \cdot \mu\text{L}^{-1}$ 和 $5.166 \text{ cells} \cdot \mu\text{L}^{-1}$ 。此外，叶绿素 a 浓度水平最高的廉州湾也具有较高的蓝绿藻密度，年均生物量约为 $4.5 \text{ cells} \cdot \mu\text{L}^{-1}$ 左右。




图 4-1 研究区域蓝绿藻生物量空间分布图

由于我国已记录的近岸海域有害藻华事件通常为单相型或双相型^[162]，即藻华爆发期间采集的水样中通常只有 1—2 种藻类的生物量占据绝对优势^[163]。因此，藻华爆发期间的优势种藻类的生物量通常与叶绿素 a 浓度呈正相关。基于以上特

征，本章采用斯皮尔曼相关性分析与最小二乘线性回归^[164]方法分析各研究案例中叶绿素 a 浓度与蓝绿藻密度之间的关系，并将“藻华”与“常态”两种状态下的蓝绿藻生物量进行比较，作为判定蓝绿藻是否为该案例的优势种的主要依据。

4.3 结果与讨论

4.3.1 基于环境因子特征的藻华预测

（一）研究案例 1：测站点 GX03 2013 年 9 月 1 日—9 月 30 日

如图 4-2 所示，逻辑回归预测模型对研究案例 1 的“藻华/常态”预测准确率为 88.1%，其中对“藻华”和“常态”的预测精确率（真正率和真负率）分别为 88.46%和 87.88%。如表 4-3 所示，特征变量中硝氮的回归系数为-0.015 且 p 值在 0.05 以内，说明本研究案例中硝氮浓度的大幅度下降会对“藻华”率产生显著的正向影响。此外，盐度的回归系数为-1.037 且 p 值为 0.001，说明在本研究案例中，盐度的上升会对“藻华”率产生显著的负向影响，26.53 psu 的盐度可能高于案例中浮游植物群落的最佳生长盐度。




图 4-2 研究案例 1 “藻华/常态”二分类预测归一化混淆矩阵

表 4-3 研究案例 1 特征变量的均值、回归系数以及 p 值统计（角标为 p 值范围：***: $p < 1\%$;

** : $1\% < p < 5\%$; * : $5\% < p < 10\%$; 无角标: $p > 10\%$)

特征变量	均值	回归系数	p 值
硝氮	28.17 $\mu\text{g}\cdot\text{L}^{-1}$	-0.015	0.041**
活性磷酸盐	1.81 $\mu\text{g}\cdot\text{L}^{-1}$	-0.033	0.104
水温	29.05 $^{\circ}\text{C}$	0.419	0.200
盐度	26.53 psu	-1.037	0.001***

（二）研究案例 2：测站点 GX04 2014 年 8 月 1 日—8 月 14 日

如图 4-3 所示，逻辑回归预测模型对研究案例 2 的“藻华/常态”预测准确率为 83.6%，其中对“藻华”和“常态”的预测精确率分别为 70%和 89.36%。如表 4-4 所示，特征变量中硝氮的回归系数为-0.059， p 值在 0.05 以内，说明在硝氮浓度出现较大幅度下降时会对“藻华”率产生显著的正向影响。此外，盐度的回归系数为 0.419 且 p 值为 0.001，说明在本研究案例中盐度的上升会对“藻华”率产生显著的正向影响，9.84 psu 的整体盐度水平显著低于本案例中浮游植物群落的最佳生长盐度。




图 4-3 研究案例 2 “藻华/常态”二分类预测归一化混淆矩阵

表 4-4 研究案例 2 特征变量的均值、回归系数以及 p 值统计（角标同表 4-3）

特征变量	均值	回归系数	p 值
硝氮	52.47 $\mu\text{g}\cdot\text{L}^{-1}$	-0.059	0.041**
活性磷酸盐	11.24 $\mu\text{g}\cdot\text{L}^{-1}$	-0.255	0.104
水温	31.61 $^{\circ}\text{C}$	-0.703	0.200
盐度	9.84 psu	0.419	0.001***

（三）研究案例 3：测站点 GX06 2014 年 8 月 1 日—8 月 14 日

如图 4-4 所示，逻辑回归预测模型对研究案例 3 的“藻华/常态”预测准确率为 75%，其中对“藻华”和“常态”的预测精确率分别为 90%和 42.86%。如表 4-5 所示，特征变量中只有盐度对“藻华”率具有显著影响，回归系数为 0.686， p 值为 0.004。说明在本研究案例中，盐度的上升会对“藻华”率产生显著的正向影响，20.54 psu 的整体盐度水平低于当地浮游植物群落的最佳生长盐度。然而，硝氮和活性磷酸盐的回归系数均为正，且 p 值在 0.1 以上，说明在该案例中藻华爆发时未出现对硝氮或活性磷酸盐的显著吸收现象。




图 4-4 研究案例 3 “藻华/常态”二分类预测归一化混淆矩阵

表 4-5 研究案例 3 特征变量的均值、回归系数以及 *p* 值统计（角标同表 4-3）

特征变量	均值	回归系数	<i>p</i> 值
硝氮	149.10 μg·L ⁻¹	0.013	0.105
活性磷酸盐	25.90 μg·L ⁻¹	0.049	0.442
水温	30.93 °C	0.047	0.953
盐度	20.54 psu	0.686	0.004***

（四）研究案例 4：测站点 GX09 2013 年 5 月 1 日—5 月 31 日

如图 4-5 所示，逻辑回归预测模型对研究案例 4 的“藻华/常态”预测准确率为 86.1%，其中对“藻华”和“常态”的预测精确率分别为 77.27%和 90%。如表 4-6 所示，特征变量中水温对“藻华”率的影响最为显著，其回归系数为 1.86 且 *p* 值为 0.003。说明在本研究案例中，水温的上升会对“藻华”率产生显著的正向影响，28.23 °C的平均水温低于当地浮游植物群落的最佳生长温度。




图 4-5 研究案例 4 “藻华/常态”二分类预测归一化混淆矩阵

表 4-6 研究案例 4 特征变量的均值、回归系数以及 p 值统计（角标同表 4-3）

特征变量	均值	回归系数	p 值
硝氮	123.53 $\mu\text{g}\cdot\text{L}^{-1}$	0	0.904
活性磷酸盐	3.76 $\mu\text{g}\cdot\text{L}^{-1}$	0.176	0.441
水温	28.23 $^{\circ}\text{C}$	1.86	0.003***
盐度	25.73 psu	-0.06	0.441

（五）研究案例 5：测站点 GX09 2013 年 6 月 1 日—6 月 8 日

根据表 4-1 的记录，该案例的藻华原因种为中肋骨条藻。如图 4-6 所示，逻辑回归预测模型对研究案例 5 的“藻华/常态”预测准确率为 72.7%，其中对“藻华”和“常态”的预测精确率分别为 50%和 85.71%。如表 4-7 所示，硝氮、活性磷酸盐和盐度都未发现对“藻华”率有显著影响，造成该结果的原因可能是中肋骨条藻藻华爆发期间对硝氮和活性磷酸盐的吸收不显著所致。此外，尽管本案例中水温的回归系数为正且 p 值在 0.05 以内，但根据第 3 章图 3-5 中水温与叶绿素 a 浓度的关系表明，水温在部分时段内超过当地藻类的最适生长温度（32 $^{\circ}\text{C}$ ）时叶绿素 a 浓度会出现下降，这可能是导致本案例的二分类预测结果中真正率较低的主要原因。




图 4-6 研究案例 5 “藻华/常态”二分类预测归一化混淆矩阵

表 4-7 研究案例 5 特征变量的均值、回归系数以及 p 值统计（角标同表 4-3）

特征变量	均值	回归系数	p 值
硝氮	118.39 $\mu\text{g}\cdot\text{L}^{-1}$	0	0.994
活性磷酸盐	2.49 $\mu\text{g}\cdot\text{L}^{-1}$	-0.034	0.881
水温	31.37 $^{\circ}\text{C}$	2.627	0.030**
盐度	22.53 psu	0	1.000

(六) 研究案例 6：测站点 GX09 2013 年 12 月 1 日—12 月 31 日

如图 4-7 所示，逻辑回归预测模型对研究案例 6 的“藻华/常态”预测准确率为 33.33%，其中对“藻华”和“常态”的预测精确率分别为 56.82%和 88.64%。如表 4-8 所示，特征变量中活性磷酸盐、水温和盐度对“藻华”率的影响都较为显著。其中，活性磷酸盐的回归系数为-0.225 且 p 值为 0.001。说明活性磷酸盐的显著下降会对“藻华”率产生显著的正向影响。水温的回归系数为 0.271， p 值在 0.05 以内。说明在本研究案例中，水温的大幅上升会对“藻华”率产生显著的正向影响，16.95 °C 的平均水温远低于当地浮游植物群落的最佳生长温度。同理，盐度的回归系数和 p 值表明，23.97 psu 的整体盐度水平显著低于当地浮游植物群落的最佳生长盐度。




图 4-7 研究案例 6 “藻华/常态”二分类预测归一化混淆矩阵

表 4-8 研究案例 6 特征变量的均值、回归系数以及 p 值统计（角标同表 4-3）

特征变量	均值	回归系数	p 值
硝氮	217.61 $\mu\text{g}\cdot\text{L}^{-1}$	-0.001	0.240
活性磷酸盐	9.02 $\mu\text{g}\cdot\text{L}^{-1}$	-0.225	0.001***
水温	16.95 $^{\circ}\text{C}$	0.271	0.003***
盐度	23.97 psu	0.375	0.000***

(七) 研究案例 7：测站点 GX09 2014 年 6 月 1 日—6 月 8 日

如图 4-8 所示，逻辑回归预测模型对研究案例 7 的“藻华/常态”预测准确率为 81.8%，其中对“藻华”和“常态”的预测精确率分别为 70%和 86.96%。如表 4-9 所示，活性硝氮、磷酸盐和水温对“藻华”率的影响都较为显著。其中，硝氮和活性磷酸盐的回归系数分别为 0.021 和-0.105，且 p 值都为 0.05 以内，结合第 3 章图 3-7 活性磷酸盐与叶绿素 a 浓度在 6 月 2 日—6 月 3 日期间的变化，

22.50 $\mu\text{g}\cdot\text{L}^{-1}$ 的平均活性磷酸盐浓度可能导致在该时段内出现氮限制, 使得水体由“常态”转向“藻华”时浮游植物对活性磷酸盐的吸收更为显著^[150]。此外, 水温的回归系数为 3.108 且 p 值为 0.05 以内, 表明在该时段内的水温的上升能增加“藻华”发生概率, 31.72 $^{\circ}\text{C}$ 的平均水温可能低于本案例中浮游植物的最佳生长温度。




图 4-8 研究案例 7 “藻华/常态”二分类预测归一化混淆矩阵

表 4-9 研究案例 7 特征变量的均值、回归系数以及 p 值统计 (角标同表 4-3)

特征变量	均值	回归系数	p 值
硝氮	131.36 $\mu\text{g}\cdot\text{L}^{-1}$	0.021	0.041**
活性磷酸盐	22.50 $\mu\text{g}\cdot\text{L}^{-1}$	-0.105	0.014**
水温	31.72 $^{\circ}\text{C}$	3.108	0.030**
盐度	22.08 psu	0.184	0.157

(八) 研究案例 8: 测站点 GX10 2013 年 6 月 1 日—6 月 8 日

如图 4-9 所示, 逻辑回归预测模型对研究案例 8 的“藻华/常态”预测准确率为 88.6%, 其中对“藻华”和“常态”的预测精确率分别为 70%和 96%。如表 4-10 所示, 盐度对“藻华”率的影响最为显著, 其回归系数为-0.536 且 p 值在 0.05 以内, 说明在本案例中, 盐度的上升会对“藻华”率产生显著的负向影响, 23.63 psu 的整体盐度水平可能略高于当地浮游植物群落的最佳生长盐度。此外, 硝氮和活性磷酸盐的回归系数和均值表明, 该时间段内可能存在因硝氮水平过低而导致的氮限制。




图 4-9 研究案例 8 “藻华/常态”二分类预测归一化混淆矩阵

表 4-10 研究案例 8 特征变量的均值、回归系数以及 p 值统计（角标同表 4-3）

特征变量	均值	回归系数	p 值
硝氮	17.09 $\mu\text{g}\cdot\text{L}^{-1}$	0.026	0.661
活性磷酸盐	16.02 $\mu\text{g}\cdot\text{L}^{-1}$	-0.131	0.088*
水温	30.78 $^{\circ}\text{C}$	1.121	0.175
盐度	23.62 psu	-0.536	0.049**

（九）研究案例 9：测站点 GX10 2013 年 9 月 1 日—9 月 30 日

如图 4-10 所示，逻辑回归预测模型对研究案例 9 的“藻华/常态”预测准确率为 77%，其中对“藻华”和“常态”的预测精确率分别为 65.38%和 83.33%。如表 4-11 所示，水温对“藻华”率的影响最为显著，其回归系数为正且 p 值仅为 0.005。说明在本研究案例中，水温的上升会对“藻华”率产生显著的正向影响，28.64 $^{\circ}\text{C}$ 的平均水温低于当地浮游植物群落的最佳生长温度。




图 4-10 研究案例 9 “藻华/常态”二分类预测归一化混淆矩阵

表 4-11 研究案例 9 特征变量的均值、回归系数以及 p 值统计（角标同表 4-3）

特征变量	均值	回归系数	p 值
硝氮	129.30 $\mu\text{g}\cdot\text{L}^{-1}$	-0.003	0.282
活性磷酸盐	9.59 $\mu\text{g}\cdot\text{L}^{-1}$	-0.068	0.512
水温	28.64 $^{\circ}\text{C}$	0.856	0.005***
盐度	22.66 psu	0.169	0.091*

（十）研究案例 10：测站点 GX10 2013 年 12 月 1 日—12 月 31 日

如图 4-11 所示，逻辑回归预测模型对研究案例 10 的“藻华/常态”预测准确率为 86.4%，其中对“藻华”和“常态”的预测精确率分别为 84.85%和 87.01%。如表 4-12 所示，水温对“藻华”率的影响最为显著，其回归系数为正且 p 值为 0。说明在本研究案例中，水温的上升会对“藻华”率产生显著的正向影响，17.94 $^{\circ}\text{C}$ 的平均水温远低于当地浮游植物群落的最佳生长温度。




图 4-11 研究案例 10 “藻华/常态”二分类预测归一化混淆矩阵

表 4-12 研究案例 10 特征变量的均值、回归系数以及 p 值统计（角标同表 4-3）

特征变量	均值	回归系数	p 值
硝氮	70.52 $\mu\text{g}\cdot\text{L}^{-1}$	0	0.984
活性磷酸盐	18.07 $\mu\text{g}\cdot\text{L}^{-1}$	-0.022	0.554
水温	17.94 $^{\circ}\text{C}$	0.875	0.000***
盐度	26.65 psu	0.027	0.845

（十一）研究案例 11：测站点 GX09 2014 年 2 月 1 日—3 月 10 日

根据李波等人^[114]的记录，廉州湾球形棕囊藻藻华事件于 2014 年 2 月 20 日左右开始爆发，3 月 5 日左右消退。受影响的海域主要为南流江河口至北海市冠头岭附东侧，因此测站点 GX09 包含在影响海域范围内。图 4-12 展示了球形棕

囊藻藻华爆发前后时间段内测站点 GX09 监测的叶绿素 a 浓度的变化趋势。其中，叶绿素 a 浓度在藻华爆发期间上升幅度较小，最高值仅为 $12.6 \mu\text{g}\cdot\text{L}^{-1}$ ，远低于其他案例的 $30\text{—}50 \mu\text{g}\cdot\text{L}^{-1}$ 。因此，基于叶绿素 a 浓度的藻华监测方法难以对水中球形棕囊藻的生物量及其藻华爆发情况进行有效评估。




图 4-12 测站点 GX09 在球形棕囊藻藻华爆发前后时段内叶绿素 a 浓度变化趋势图

本案例选取了测站点 GX09 在 2014 年 2 月 1 日至 3 月 10 日期间段作为研究案例，以 2 月 20 日至 3 月 5 日时段内作为“藻华”其他时段作为“常态”，并以硝氮、活性磷酸盐、水温和盐度作为特征变量（同其他案例）进行逻辑回归二分类预测。如图 4-13 所示，逻辑回归预测模型对本案例的“藻华/常态”预测准确率为 80.6%，其中对“藻华”和“常态”的预测精确度分别为 60.78%和 94.52%。如表 4-13 所示，硝氮的回归系数为-0.001 且 p 值为 0.26，说明球形棕囊藻藻华爆发期间会大量吸收硝氮，该结果与 Lv 等人^[37]针对球形棕囊藻对硝氮吸收的实验研究结论相符。然而，活性磷酸盐的回归系数为 0.213 且 p 值仅为 0.001，说明球形棕囊藻藻华爆发期间对活性磷酸盐的吸收不显著，且藻华期间水体除硝氮外的整体营养水平可能还存在上升趋势。




图 4-13 研究案例 11（球形棕囊藻藻华）“藻华/常态”二分类预测混淆矩阵

表 4-13 研究案例 11 特征变量的均值、回归系数以及 p 值统计（角标同表 4-3）

特征变量	均值	回归系数	p 值
硝氮 ($\mu\text{g}\cdot\text{L}^{-1}$)	181.34	-0.001	0.260
活性磷酸盐 ($\mu\text{g}\cdot\text{L}^{-1}$)	11.53	0.213	0.001***
水温 ($^{\circ}\text{C}$)	15.18	0.071	0.267
盐度 (psu)	28.31	0.050	0.562

4.3.2 环境因素对藻华发生率的影响

预测结果表明，以硝氮、活性磷酸盐、水温和盐度作为环境因子（特征变量）的逻辑回归二分类预测模型对“藻华/常态”的预测方法准确率能够稳定在 72% 以上，最高可达 88.6%。然而，由于不同案例中的营养盐吸收、水温/盐度条件等环境因素存在差异，使得逻辑回归预测模型对“藻华”状态的预测精确率差距较大，最高可达 90%（案例 3），最低仅为 50%（案例 5）。

（一）营养盐吸收

第 3 章的藻华信号特征提取（3.3.3 节）结果表明，浮游植物对硝氮、活性磷酸盐等营养盐的大量吸收是预测藻华爆发的重要信号。然而，在“藻华/常态”二分类预测结果中，硝氮和活性磷酸盐的回归系数存在较大差异。其中，在案例 1 和案例 2 中，两种营养盐的回归系数都为负且 p 值在 0.12 以内，逻辑回归预测模型对“藻华/常态”的整体预测准确率分别达到 88.1% 和 83.6%，其中对“藻华”状态的预测精确度至少达到 70%，整体预测效果相对良好。相应地，在案例 6、案例 7、案例 8，以及案例 11 中，仅有 1 种营养盐的回归系数为负且 p 值在 0.26 以内，逻辑回归预测模型对“藻华/常态”的预测准确率为 76.5%—88.6% 之间，但对“藻华”状态的预测精确度相对较低，仅在 56%—70% 之间。此外，案例 3、案例 4、案例 5，以及案例 9 中两种营养盐均未呈现显著的吸收现象，逻辑回归预测模型对“藻华/常态”的预测准确率较低，仅案例 4 高于 80%。其中，案例 3、案例 9，以及案例 11 的整体营养水平相对较高，硝氮和活性磷酸盐的均值分别至少达到 $120 \mu\text{g}\cdot\text{L}^{-1}$ 和 $9.5 \mu\text{g}\cdot\text{L}^{-1}$ ，说明该部分案例中的优势种/原因种藻类对硝氮和活性磷酸盐的吸收偏好可能低于其他类型的营养盐，例如硅酸盐是中肋骨条藻（案例 5 原因种）等硅藻类生长的重要营养成分^[165]。此外，案例 4 与案例 5 的磷限制（活性磷酸盐均值低于过 $4 \mu\text{g}\cdot\text{L}^{-1}$ ）以及案例 8 的氮限制（硝氮均值仅为 $17.09 \mu\text{g}\cdot\text{L}^{-1}$ ）也可能是阻碍藻华期间浮游植物吸收营养盐的另一潜在因素。

综上所述，在原因种类型和氮/磷限制等因素的影响下，藻华爆发期间水体浮游植物群落会对营养盐的吸收偏好存在差异^[166]，进而对藻华预测模型的准确度造成影响。因此，实时监测并掌握当地海域的营养盐和浮游植物群落结构，明

确藻华爆发期间优先吸收的营养盐类型,是进一步提高有害藻华预测能力的必要条件之一。

(二) 水温与盐度阈值

预测结果表明,在平均水温低于 30 °C 的案例中(案例 1、案例 4、案例 9—案例 11),水温的上升对“藻华”率起到显著正向作用。而当平均水温高于 30 °C 时,不同案例中水温的变化对“藻华”率的影响存在差异,例如案例 2 中,水温的回归系数为负且 p 值为 0.2,说明 31.61 °C 的平均水温可能高于本案例中藻类的最佳生长温度阈值。而在平均水温为 30.93 °C 的案例 3,水温的变化对“藻华”率无显著影响($p=0.953$),说明本案例中的水温可能长时间在最佳生长阈值上下浮动。因此,当水体温度显著低于 30 °C 时,水温是藻华预测模型中不可或缺的特征变量之一。

与水温相似,在平均盐度低于 22 psu 的案例中(案例 2 和案例 3),盐度的上升对“藻华”率起到显著正向作用。然而,受水温和原因种藻类等差异的影响,不同案例之间的藻类最佳生长阈值存在较大差异。例如,在平均水温超过 30 °C 且盐度在 22—23 psu 之间的案例 5 和案例 7,盐度对“藻华”率未产生显著影响。其中案例 5 中盐度的 p 值达到 1,说明在水温超过 30 °C 时,22.53 psu 的盐度可能接近中肋骨条藻的最佳生长盐度阈值,该结果与陈炳章等人^[45]的研究结果相符,即中肋骨条藻的最适生长盐度会在水温上升时往中低盐度方向偏移。此外,在平均盐度为 28.31 psu 的研究案例 11(球形棕囊藻藻华)中,盐度也未对“藻华”率产生显著影响,该结果与 Xu 等人^[167]对南海近岸球形棕囊藻藻华的研究结论相符,即当水温低于 20 °C 时球形棕囊藻在 30 psu 左右的盐度环境下达到最高生长速率。

综上所述,本章的预测结果进一步证实,30—32 °C 的水温和 22—28 psu 的盐度范围均为本研究区域内浮游植物群落的最佳生长范围,当整体水温/盐度显著低于或高于当地浮游植物群落的最佳生长阈值时,水温和盐度的变化对“藻华”率的影响显著。此外,当水温超过 30 °C 时,中肋骨条藻(案例 5)等浮游植物的最佳生长盐度阈值会降低到 22.5 psu 左右。

4.3.3 藻华事件的蓝绿藻优势种判定

本章对 10 个研究案例中叶绿素 a 浓度与蓝绿藻生物量数据分别进行了相关性分析和线性回归。如图 4-14 所示,时间序列下蓝绿藻生物量与叶绿素 a 浓度之间的关系在各研究案例中存在显著差异。其中,在研究案例 2、案例 4 和案例 8 中,蓝绿藻生物量与叶绿素 a 浓度之间呈显著中度正相关,整体变化趋势相似;而在案例 1、案例 6、案例 9 和案例 10 中,蓝绿藻生物量与叶绿素 a 浓度之间呈

显著负相关，两者变化趋势相反；其余研究案例中两者无显著相关性。




图 4-14 研究案例中时间序列下叶绿素 a 浓度—蓝绿藻生物量的变化关系(ρ 为蓝绿藻生物量与叶绿素 a 浓度之间的斯皮尔曼相关系数; 图中角标为 p 值范围: *** $p < 1\%$; ** $1\% < p < 5\%$; * $5\% < p < 10\%$; 无角标: $p > 10\%$)

蓝绿藻生物量与叶绿素 a 浓度之间的线性回归结果如图 4-15 所示。其中，在研究案例 2 和案例 4 中，蓝绿藻生物量和叶绿素 a 浓度之间呈线性弱正相关；在研究案例 1 和案例 9 中呈线性弱负相关；其余案例中无明显线性关系。




图 4-15 研究案例中叶绿素 a 浓度-蓝绿藻生物量线性关系

根据图 4-14 和图 4-15 呈现的蓝绿藻生物量与叶绿素 a 浓度之间的关系，以及“藻华（叶绿素 a 浓度 $\geq 10 \mu\text{g}\cdot\text{L}^{-1}$ ）”和“常态（叶绿素 a 浓度 $< 10 \mu\text{g}\cdot\text{L}^{-1}$ ）”两种状态下的均值统计，本章对各研究案例的优势种进行了判定，如表 4-14 所示。其中，在研究案例 2、案例 3、案例 4，以及案例 8 中，“藻华”状态下的

蓝绿藻的平均生物量显著高于“常态”，研究案例 2、案例 4 和案例 8 的蓝绿藻生物量与叶绿素 a 浓度都呈显著正相关。因此，在这些案例中蓝绿藻可被确认为藻华主要原因种。而在研究案例 3，蓝绿藻生物量与叶绿素 a 浓度无显著相关性，且“藻华”与“常态”之间蓝绿藻生物量差异仅为 $0.333 \text{ cells} \cdot \mu\text{L}^{-1}$ ，因此蓝绿藻在该研究案例中不能被判定为优势种。此外，尽管案例 7 中蓝绿藻生物量与叶绿素 a 浓度之间无显著相关性，但蓝绿藻生物量整体维持在相对较高的水平，说明在该案例中蓝绿藻可能是非单相型藻华的优势种之一。而在包括中肋骨条藻藻华（案例 5）和球形棕囊藻藻华（案例 11）在内的其他案例中，蓝绿藻作为非优势种，在“藻华”状态下的生物量低于“常态”，说明在有害藻华爆发期间，其他非优势种藻类的生长会受到一定程度的限制。

综上所述，研究区域内以蓝绿藻为优势种的藻华主要发生在茅尾海（案例 2）和廉州湾（案例 4、案例 7 和案例 8），在时间上集中在水温达到 30°C 左右的 5—8 月。该结果符合图 4-1 的蓝绿藻密度空间分布特征，并与孙军^[168]对北部湾记录的夏季藻华主要原因种分布和类型描述基本一致。而在其他研究案例中，藻华事件的原因种可能是中肋骨条藻（案例 5）以及球形棕囊藻（案例 11）等其他藻类^[159]。

表 4-14 研究案例中蓝绿藻生物量—叶绿素 a 浓度关系及优势种判定结果（角标同表 4-3）

研究 案例	藻华 ($\text{cells} \cdot \mu\text{L}^{-1}$)	常态 ($\text{cells} \cdot \mu\text{L}^{-1}$)	相关性 系数 (ρ)	线性 R^2	蓝绿藻优势种 判定结果 (是/否)
1	2.161	2.768	-0.396***	0.141	否
2	3.693	3.037	0.505***	0.158	是
3	4.012	3.679	-0.048	0.011	否
4	6.490	4.291	0.423***	0.241	是
5	3.954	5.658	-0.074	0.033	否
6	2.741	4.563	-0.149*	0.024	否
7	5.173	6.949	-0.035	0.022	是
8	4.312	3.491	0.473***	0.074	是
9	2.530	3.201	-0.366***	0.098	否
10	1.744	2.516	-0.410***	0.073	否
11	2.410	3.402	--	--	否

4.3.4 原因种差异对预测结果的影响

表 4-15 统计了蓝绿藻、中肋骨条藻，以及球形棕囊藻作为原因种/优势种引发的有害藻华事件的逻辑回归二分类预测结果。其中，预测模型对蓝绿藻藻华的预测精确度不低于 70%，显著高于球形棕囊藻藻华（60.78%）和中肋骨条藻藻华（50%）。在研究案例 2、案例 7 和案例 8 中，硝氮和活性磷酸盐至少有一项出现回归系数为负且显著性水平较高（ $p < 0.1$ ）的结果，说明蓝绿藻藻华爆发期间对两种营养盐的吸收较为显著，进而提高了预测模型对“藻华”的预测精确率。而在球形棕囊藻藻华爆发期间，藻类仅对硝氮存在一定程度的吸收，对活性磷酸盐的吸收情况不显著，该结果可能是导致以硝氮和活性磷酸盐作为特征变量时，逻辑回归预测模型对球形棕囊藻藻华的预测精确率（60.78%）低于蓝绿藻藻华（ $\geq 70\%$ ）的原因之一。相比之下，中肋骨条藻藻华（案例 5）爆发期间未监测到硝氮与活性磷酸盐出现明显下降的现象（图 3-5），使得预测模型对“藻华”预测精确率仅为 50%。因此，通过掌握当地藻华优势种信息，进而明确其对营养盐类型的吸收偏好，是提升有害藻华预测准确率的重要前提。

表 4-15 不同原因种引发的藻华预测结果统计（角标同表 4-3）

测站点	研究案例	“藻华”预测精确率	“常态”预测精确率	原因种/优势种	硝氮回归系数	活性磷酸盐回归系数
GX04	2	70.00%	89.36%	蓝绿藻	-0.059**	-0.255
GX09	4	77.27%	90.00%	蓝绿藻	0	0.176
GX09	5	50.00%	85.71%	中肋骨条藻	0	-0.034
GX09	7	70.00%	86.96%	蓝绿藻	0.021**	-0.105**
GX10	8	70.00%	96.00%	蓝绿藻	0.026	-0.131*
GX09	11	60.78%	94.52%	球形棕囊藻	-0.001	0.213***

4.4 本章小结

本章基于北部湾近岸有害藻华历史记录，分别统计了逻辑回归预测模型对蓝绿藻、中肋骨条藻以及球形棕囊藻引发的有害藻华的二分类预测结果，并根据藻华期间对营养盐的吸收情况，分析了原因种差异对预测结果的影响，主要结论如下：

1) 逻辑回归预测模型对 11 个藻华案例的预测结果表明，以营养盐、水温，和盐度作为特征变量的“藻华/常态”二分类预测方法能够将预测准确率稳定在 72%以上，最高可达 88.6%。

2) 蓝绿藻为优势种的藻华主要集中在水温达到 30 °C 左右的 5 月—8 月, 藻华期间对硝氮和活性磷酸盐的吸收都较为显著, 逻辑回归预测模型对“藻华”状态的预测精确率相对较高, 至少达到 70.00%。

3) 球形棕囊藻藻华对硝氮的吸收较为显著, 但对活性磷酸盐的吸收不显著, 逻辑回归预测模型对“藻华”状态的预测精确率为 60.78%, 藻华爆发期间叶绿素 a 浓度的变化不显著, 最高时仅为 12.6 $\mu\text{g}\cdot\text{L}^{-1}$ 。

4) 中肋骨条藻藻华对硝氮和活性磷酸盐的吸收都不显著, 逻辑回归预测模型对“藻华”状态的预测精确率相对较低, 仅为 50.00%, 且当水温超过 30 °C 时, 中肋骨条藻的最适生长盐度阈值会降低到 22.5 psu 左右。

5) 浮游植物在藻华期间对营养盐的吸收显著程度是影响预测模型准确度的重要因素, 因此明确藻华爆发期间优先吸收的营养盐类型是进一步提高有害藻华预测能力的必要条件之一。

第5章 基于水下显微成像的有害藻华原因种监测方法研究

5.1 引言

根据第4章球形棕囊藻藻华（案例11）期间叶绿素a浓度变化可知，常规的水质传感监测方法无法对球形棕囊藻等异养藻类引发的藻华进行监测。此外，显微镜镜检法需经过现场取样、水样保存以及实验室操作等环节，难以达到有害藻华监测工作的时效性需求^[169]，而浮游生物成像仪等硬件产品在市面上的价格较为昂贵，难以直接应用到长期大范围的近岸海域监测中。如图5-1所示，为有效解决目前有害藻华监测方法中的局限性，本章建立了以水下显微成像—图像处理—目标检测为基础的有害藻华原因种监测技术框架，以球形棕囊藻作为主要监测目标开展了针对有害藻类生物量的监测方法研究。




图 5-1 有害藻华原因种监测技术框架示意图

5.2 材料与方法

5.2.1 水槽实验样品显微观察

本章在开展水槽实验前的准备阶段，采用尼康（Nikon）商用光学显微镜的 400 倍镜，对乐清光语生物科技有限公司（Yueqing Guangyu Biological Technology Co., LTD）提供的球形棕囊藻藻液水样、自然水体对照水样，以及球形棕囊藻与对照水样 1:9 体积比例混合后的混合水样进行观察。

如图 5-2 所示，球形棕囊藻在尼康商用光学显微镜 400 倍镜常规透射照明下呈褐绿色半透明球状或椭球状，单细胞直径约为 3—6 μm ，能够观察到细胞分裂和聚集过程。参照王西艳等人^[170]采用扫描电子显微镜对球形棕囊藻的成像（图 5-3），细胞的整体轮廓在光学显微镜下与电镜扫描基本相符，但细胞表面的粗糙凸起特征以及鞭毛较难在光学显微镜中呈现。




图 5-2 尼康商用显微镜拍摄下的球形棕囊藻水样图像




图 5-3 电子显微镜扫描下的球形棕囊藻单细胞形态^[170]：(a) 具有两根长鞭毛及一根短鞭毛的单细胞；(b) 具有凹陷的无鞭毛单细胞；(c) 具有两条短鞭毛突起的单细胞

为避免对照水样中存在部分球形棕囊藻从而对原因种的鉴定分类产生干扰，本研究选用了内陆湖水作为对照水样。如图 5-4 所示，光学显微镜能够在对照水样中观测到多种大小/形态的浮游藻类。根据图 5-5 《中国淡水藻类——系统分类及生态》^[171]中的藻类参考图鉴，对照水样中主要藻类包括长度约 10—40 μm 的硅藻门（*Bacillariophyta*）直链藻属（*Melosira*）、直径约 5—20 μm 的蓝藻门（*Cyanophyta*）微囊藻属（*Microcystis*），以及单细胞直径约 3—6 μm 的绿藻门（*Chlorophyta*）小球藻属（*Chlorella*）等。




图 5-4 尼康商用显微镜拍摄下的对照水样图像（红色框为直链藻属、蓝色框为微囊藻属、黄色框为小球藻属）




图 5-5 《中国淡水藻类——系统分类及生态》^[171]中直链藻属、微囊藻属以及小球藻属的参考图鉴

混合水样在光学显微镜下的成像如图 5-6 所示，在采用镜检法进行人工鉴别的过程中，直链藻属和微囊藻属在形态特征上与球形棕囊藻有着较大差异，因此鉴定分类的难度较低。然而，如图 5-7 所示，尽管球形棕囊藻与小球藻属存在一定颜色差异，但小球藻属在整体形态特征上与球形棕囊藻高度相似，因此在自然水体中对球形棕囊藻采用镜检法进行人工鉴定的难度较高。




图 5-6 尼康商用显微镜拍摄下的混合水样中的人工鉴别结果（红色实线框为球形棕囊藻人工标记，虚线框为小球藻人工标记）




图 5-7 球形棕囊藻与小球藻属的图像特征对比

5.2.2 水下显微成像装置搭建

本章基于透射式暗场照明（Transmitted Darkfield Illumination）的基本原理，对水下显微成像装置的光路进行了设计。暗场照明通过调整光源的照射角度，以较大的入射角照射样本使得通过样本的直射光线不进入物镜光阑内，使得相机更多地接收样本物体的散射光进行成像^[172]。与明场照明相比，暗场照明的主要特点为物体成像的背景为黑色，而物体的边缘或表面呈现亮色，进而提高图像的对比度。以图 5-8 中微型海洋原生动动物放射虫为例，暗场照明生成的图像具有清晰度高和稳定性强等优点，图像中物体的轮廓边界相较于明场照明更加清晰^[173]，

因此通常适用于针对藻类等水生浮游生物的显微观测。




图 5-8 透射式明场照明原理图及其对微型海洋原生动物放射虫的成像效果^[172]

图 5-9 展示了本章搭建的水下原位显微成像装置的详细光路图。该装置根据显微镜镜头工作距离和环形 LED 光源与密封舱透光板之间的距离确定成像区域。其中，环形 LED 光源密封舱壳体与显微镜密封舱壳体之间的距离 L 、水中光源入射角 θ_2 和 LED 光源半径 r_2 之间的关系如式(5-1)所示：

$$L = \frac{r_2}{\tan \theta_2} \quad (5-1)$$

显微镜镜头的最佳工作距离 f 与折射角 θ_1 和显微镜镜头半径 r_1 之间的关系如式(5-2)所示：

$$f = \frac{r_1}{\tan \theta_1} \quad (5-2)$$

其中，密封舱内折射角 θ_1 与光源入射角 θ_2 之间的关系主要受光线在密封舱内空气介质相对于真空的折射率 n_1 和监测水体介质相对于真空的折射率 n_2 影响，如式(5-3)所示：

$$\frac{n_1}{n_2} = \frac{\sin \theta_2}{\sin \theta_1} \quad (5-3)$$

该装置的暗场照明效果最终通过调节环形 LED 光源密封舱壳体与显微镜密封舱

壳体之间的距离 L 来实现。




图 5-9 水下显微成像装置透射式暗场成像详细光路图

本章基于水下暗场成像原理，设计并搭建了一套水下显微成像装置，如图 5-10 所示。该装置主要包括显微镜密封舱壳体和环形发光二极管（Light-Emitting Diode, LED）光源密封舱壳体两大部分，两个壳体通过夹具和连接杆将两个密封舱壳体连接在一条水平线上，两者之间的距离可通过移动夹具进行调节，连接杆上方通过长杆连接外部装置用来控制装置的工作水深。其中，显微镜密封舱壳体部分包括密封舱、透光板以及固定环，密封舱壳内部通过支撑杆将显微镜和 CCD 工业相机进行固定并通过微调使得最佳成像区域固定在镜头前端密封舱固定环外部水体（图 5-10 (a) 中红色部分），使得成像过程中能够有效避免近距离虚焦导致成像质量下降。显微镜密封舱壳体外部的以太网供电（Power Over Ethernet, POE）电源接口通过导线穿过壳体后侧的密封舱固定环，从而连接壳体内部的 CCD 工业相机实现供电。光源密封舱壳体部分包括光源密封舱、透光板和密封舱固定环，并利用支撑杆将内部的环形 LED 光源固定在光源密封舱的密封舱固定环处。两个密封舱壳体之间的距离通过连接杆进行调节从而最大程度实现水下暗场照明效果。

本研究将搭建的水下显微成像装置分别放入球形棕囊藻水样、对照水样，以及球形棕囊藻与对照水样 1:9 混合的混合水样的水槽中进行水槽实验。水槽实验期间，显微镜密封舱壳体后侧通过 POE 供电接口与外部电脑终端相连，通过以太网与终端电脑相连，操纵海康机器视觉工业相机客户端 MVS 界面进行图像拍摄与数据传输。




图 5-10 水下显微成像装置图：(a) 整体结构设计图；(b) 连接杆结构图；(c) 密封舱固定环结构图；(d) 原理样机实物图

5.2.3 水下图像增强与去散射

受浑浊水体中的光线吸收和散射等影响，水下图像通常存在能见度低、色彩失真，以及细节丢失等问题^[174]。若直接采用水下拍摄的图像进行目标检测模型训练，易导致模型性能不佳从而影响对水中藻类的识别效果。为解决这一问题，本章采用多种图像增强算法对水下拍摄的原始图像进行增强处理，并通过直观比较选取增强效果最优的图像集进行去散射处理。

水下图像增强技术主要采用计算机数字图像处理的方法来对水下图像进行调整，以达到提升视觉效果的目的^[175]。目前，国内外已有大量图像增强算法被提出，并且均可获得较好的视觉效果^[176]。以自适应对比度增强 (Adaptive Contrast

Enhancement, ACE) 算法为例, 该算法将图像分成低频和高频两个部分, 其中低频部分是通过图像的低通滤波(平滑模糊)获得, 高频部分由原图减去低频部分得到^[177]。随后对高频部分乘以某个增益系数, 最后重组得到增强的图像。自适应对比度增强算法以图像中某像素点 $x(i, j)$ 为中心, 窗口大小为 $(2n+1) \times (2n+1)$ 区域内, 其局部均值和方差可分别由式(5-4)和式(5-5)表示:

$$m_x(i, j) = \frac{1}{2(2n+1)} \sum_{k=i-n}^{i+n} \sum_{l=j-n}^{j+n} x(k, l) \quad (5-4)$$

$$\sigma^2(i, j) = \frac{1}{2(2n+1)^2} \sum_{k=i-n}^{i+n} \sum_{l=j-n}^{j+n} [x(k, l) - m_x(i, j)]^2 \quad (5-5)$$

均值 m_x 可以近似认为是背景部分, 此时 $x(k, l) - m_x(i, j)$ 即高频细节部分, 对高频作增益乘积, 具体过程为:

$$f(i, j) = m_x(i, j) + G(i, j)[x(i, j) - m_x(i, j)] \quad (5-6)$$

对于增益 $G(i, j)$, 可用大于 1 的常数 C 或与局部协方差成反比的变化值表示:

$$f(i, j) = m_x(i, j) + C[x(i, j) - m_x(i, j)] \quad (5-7)$$

$$f(i, j) = m_x(i, j) + \frac{D}{\sigma_x(i, j)}[x(i, j) - m_x(i, j)] \quad (5-8)$$

其中, 在图像的高频区域, 局部均方差较大, 此时增益值就比较小, 这样结果不会出现过亮情况。但是在图像平滑的区域, 局部均方差很小, 此时增益值比较大, 从而可能会放大噪声信号, 所以需要对增益最大值做一定的限制才能取得较好的效果^[178]。

5.2.4 YOLOv8 目标检测模型

本章采用 YOLOv8 (You Only Look Once vision 8) 目标检测模型对水下拍摄的微藻进行识别与计量。YOLO 系列目标检测模型是 Redmon 等人^[179]于 2015 年提出的基于深度学习的单级 (One-stage) 目标检测算法, 该算法采用了直接回归功能的卷积神经网络来完成整个目标检测/图像识别的过程。该过程从开始的卷积层提取图像特征, 最后通过全连接层预测输出概率。YOLO 算法通过单个卷积网络同时预测多个边界框和这些框的类概率, 并在完整图像上进行训练, 直接优化检测性能^[179]。

YOLO 系列模型的基本工作原理为: 将输入的图像分为 $S \times S$ 的网格, 每个网格单元预测 B 个边界框和这些边界框的置信度值 C , 其中置信度值反映了模型对

认为边界框里有一个物体的预测准确度。置信度的计算原理如下：

$$C = \text{Pr}(\text{Object}) * \text{IOU}_{\text{pred}}^{\text{truth}} \quad (5-9)$$

式中， $\text{Pr}(\text{Object})$ 为框中目标存在的可能性大小，表示是否有人工标记的物体落入了网格内，若框中没有目标物，则 $\text{Pr}(\text{Object})=0$ ，若框中含有目标物，则 $\text{Pr}(\text{Object})=1$ ；IOU（Intersection Over Union）为交/并比，表示所选预测框与真实框相交的面积和预测的框与真实框合并的面积的比例，该值越接近 1 则表示候选框越接近真实的位置。在预测过程中，每个边界框由 5 个预测因子组成： x 坐标、 y 坐标、宽度 w 、高度 h 和置信度 C 。其中，坐标 (x, y) 表示边界框中心点与网格边界的相对位置； w 和 h 是真实物体的宽与高相对于整个图像预测的比值；最终的预测置信度可理解为预测框与任何真实框之间的交/并比。此外，每个网格单元预测类别信息概率 $\text{Pr}(\text{Class}_i|\text{Object})$ 。该过程预测每个网格单元的一组类别的概率，不管边界框的数量 B 是多少。在测试时，该模型将条件类别概率和单个框置信度预测相乘，得到每个候选框预测 Class_i 物体的概率和位置重叠的概率 $\text{Pr}(\text{Class}_i)$ ，具体等式如下：

$$\text{Pr}(\text{Class}_i | \text{Object}) * \text{Pr}(\text{Object}) * \text{IOU}_{\text{pred}}^{\text{truth}} = \text{Pr}(\text{Class}_i) * \text{IOU}_{\text{pred}}^{\text{truth}} \quad (5-10)$$

YOLO 系列经历了多个版本的更新迭代，现已推出了第八个版本 YOLOv8^[180]。YOLOv8 是 Ultralytics 公司在 2023 年 1 月 10 日发布的流行实时对象检测器 YOLO 的最新版本^[181]。它的设计结合了许多实时目标检测器的优点，包括轻量级的网络架构、高效的特征融合方法和更准确的检测结果。YOLOv8 是建立在曾经 YOLO 版本模型的成功基础上，引入了新的功能和改善，以进一步提高模型的性能和灵活性^[182]。如图 5-11 所示，YOLOv8 的基础网络为 CSP-DarkNet 深度卷积神经网络，作为无锚点（anchor-free）模型意味着它将直接预测对象的中心，而不是已知锚点盒（anchor box）的偏移量^[181]。通过减少盒子预测的数量，该方法加快了非最大抑制（Non-Maximum Suppression, NMS）推理步骤，从而具有更快的运行速度。YOLOv8 包括输入侧（input side）、主干网络（backbone network）、颈部网络（Neck network），以及头部（Head）等部分。其中，输入端采用马赛克数据增强、自适应锚框计算、自适应图像缩放等方法减少填充带来的计算冗余，并丰富特征数据的多样性，有利于提高目标检测性能。主干网络和颈部网络部分采用梯度丰富的 C2f 结构^[183]，并针对不同比例的模型调整了不同通道的数量，相较 YOLOv5 等先前版本显著提高了模型的检测性能。C2f 模块是一个瓶颈（Bottleneck）模块，该模块中的栈数（number of stacks）由参数 n 控制，其中 n 的值取决于模型的大小。此外，YOLOv8 还考虑到了相关算子的表征能力和硬件计算消耗之间的平衡，在保持精度的同时减少了延迟，减

轻了解耦头中卷积引起的额外延迟消耗。




图 5-11 YOLOv8 网络结构^[179]

YOLOv8 在完成训练后,会将模型的目标检测性能指标以及相关的训练参数结果示意图保存下来,用于对模型性能进行评估。其中,模型的检测性能指标主要包括准确率 (Accuracy)、精确率 (Precision)、召回率 (Recall)、F1 分数 (F1 Score)、漏检率 (Miss Rate)、虚警率 (False Alarm Rate), 以及平均精确率 (mean Average Precision, mAP) 等。其中,准确率表示正确预测的目标数量与总预测数量的比率;精确率表示模型正确预测为正样本的样本数量占有所有预测为正样本的样本数量的比例;召回率表示模型正确预测为正样本的样本数量占有所有实际正样本的样本数量的比例;F1 分数为综合考虑精确率和召回率,是精确率和召回率的调和平均数;漏检率表示模型未能检测到的目标数量占有所有实际正样本的比例;虚警率表示模型错误地将负样本预测为正样本的数量占有所有负样本的比例。模型的性能指标通过多种运算方式以训练参数结果示意图的形式将模型的检测性能呈现出来。训练参数结果示意图主要包括混淆矩阵、F1-置信度曲线 (F1-Confidence Curve)、召回率-置信度曲线 (Recall-Confidence Curve, RCC)、精确率-置信度曲线 (Precision-Confidence Curve, PCC) 以及精确率-召回率曲线 (Precision-Recall Curve, PRC) 等。

5.3 结果与讨论

5.3.1 水下显微成像的藻类图像特征

水下显微成像装置在水样中拍摄的部分原始图像如图 5-12 所示，在物镜视场为 $1\text{ mm}\times 1\text{ mm}$ 、景深为 1 mm 的范围内，水样中的浮游藻类的分布均匀，且在暗场照明下藻类细胞的形态特征明显。其中，球形棕囊藻呈微小的淡绿色球形图（5-12 (a)），由于其细胞表面粗糙（图 5-3）导致的散射/漫反射效应，使得球形棕囊藻细胞的边缘轮廓较为模糊。而在对照水样中（5-12 (b)），该装置拍摄的浮游生物种类与实验室显微镜拍摄的图 5-4 相比更加丰富。其中，直链藻属呈细长条状，其形态特征与其他藻类存在明显差别，较易辨识。微囊藻属等体积较大（直径 $10\text{ }\mu\text{m}$ 以上）的藻类在图像中呈黄绿色不规则球形，存在一定程度的鉴别难度。而小球藻属呈黄绿色球形，其大小与形状与球形棕囊藻高度相似，使得在混合水样中难以直接将球形棕囊藻和小球藻属进行有效区分。此外，除了直链藻属、微囊藻属以及小球藻属等浮游藻类外，本研究搭建的水下显微成像装置在暗场照明条件下还可清晰地拍摄到长度超过 $100\text{ }\mu\text{m}$ 的小型浮游动物。与传统的显微镜镜检法相比，本研究设计并搭建的水下显微成像装置具有监测效率高、延续性强等优点。




图 5-12 水下显微成像装置在实验水样中拍摄的原始图像：(a) 球形棕囊藻水样；(b) 对照水样；(c) 混合水样。

5.3.2 水下图像优化处理及视觉评估

由图 5-12 可知，由于原始图片尺寸较大（ 1280×1024 像素）且图像中的浮游藻类分布密集，会导致在后续 YOLOv8 模型训练所需的训练集/验证集进行特征标记过程中的人力成本较高。因此，需要将原始图像裁剪为大小合适的子图像，从而在提高特征标记以及图像处理的效率的同时最大程度杜绝操作误差。本章将

拍摄的每一个原始图像裁剪为 16 个 340×256 像素点的子图像，部分子图像如图 5-13 所示。从图中可以看出，每张子图像在后续的特征标记过程中所需的工作量适中，可有效降低操作误差风险，从而保障后续模型训练以及目标检测等环节的顺利进行。




图 5-13 三种水样中拍摄的原始图像经裁剪处理后的部分子图像

根据图 5-12 与图 5-13 可以看出，尽管在暗场照明条件下水样中拍摄的原始图像能够清晰完整地呈现出微米级藻类细胞的轮廓。但由于藻类细胞体积微小，在环形 LED 光源大倾斜角照射下的散射强度较弱，使得藻类细胞在原始图像中较为暗淡且对比度较低。而大幅调高光源的照射强度又会令图像的噪声过大导致图像失真，因此需对原始图像进行对比度增强和散射去除处理。本章采用多种图像增强算法对原始图像进行处理，并选择目视效果最佳的图像集进行后续的去散射处理。

（一）多尺度 Retinex

Retinex 是 Edwin.H.Land 于 1963 年提出的基于人类视觉系统对图像的亮度和颜色感知的理论模型^[184]。Retinex 的基础理论认为物体的颜色是由物体对长波（红色）、中波（绿色）、短波（蓝色）光线的反射能力来决定的，而不是由反射光强度的绝对值来决定的。Retinex 图像增强算法具有提高图像的全局对比度和局部对比度的功能，进而实现增强边缘、颜色恒常、颜色高保真等效果^[185]。其中，单尺度 Retinex（Single Scale Retinex, SSR）算法的具体原理如下：

$$R_i(x, y) = \log I_i(x, y) - \log [F(x, y) * I_i(x, y)] \quad (5-11)$$

其中, *代表卷积运算, SSR 算法的卷积项可看作对空间照度的计算, 其物理意义是通过计算像素与其周围区域加权平均值的比值来消除照度变化的影响^[184]。式中 $R_i(x, y)$ 为该算法在第 i 个颜色谱段的输出, 即坐标 (x, y) 位置的亮度值; $\log$ 为自然对数; $F(x, y)$ 为环绕函数, 具体表达为:

$$F(x, y) = K \exp \left[- (x^2 + y^2) / c^2 \right] \quad (5-12)$$

式中, c 为高斯环绕函数的尺度常数。 c 的大小决定了卷积核的作用范围, 当 c 减小时, 动态范围压缩增大, 图像的局部细节更加突出; 当 c 增大时, 图像的整体效果越好, 图像颜色越自然, 但局部细节不清晰。 K 为归一化因子, 使得环绕函数满足:

$$\iint F(x, y) dx dy = 1 \quad (5-13)$$

由于 SSR 算法难以同时满足动态范围压缩和颜色恒常性, 因此, Jobson 等人^[185]于 1997 年提出了多尺度 Retinex (Multi Scale Retinex, MSR) 算法用以解决这一技术局限。MSR 图像增强算法是在 SSR 算法基础上, 以数学形式将多个 SSR 运算结果进行加权平均, 具体表达式如下:

$$R_{M_i}(x, y) = \sum_{n=1}^N w_n R_{n_i}(x, y) \quad (5-14)$$

$$R_{n_i}(x, y) = \{ \log I_i(x, y) - \log [F_n(x, y) * I_i(x, y)] \} \quad (5-15)$$

式中, $R_{M_i}(x, y)$ 为 MSR 算法在第 i 个颜色谱段的输出; $R_{n_i}(x, y)$ 为第 i 个颜色谱段第 n 个尺度的输出分量; N 为尺度数; w_n 为每个尺度对应的权值。MSR 图像增强算法同时包含了多个尺度的特征, 能够同时实现动态范围的压缩、颜色恒常性和颜色的重现, 使得图像的处理效果更加理想。

如图 5-14 所示, MSR 图像增强算法使得图像中的藻类细胞轮廓清晰度得到了明显的增强, 并且在不同的尺度数量、最大尺度和对比度等参数设置下呈现出了不同的增强效果。其中, 随着尺度数量和最大尺度的增加, 图像中的细节会变得更加清晰, 更有利于对不同藻类进行检测识别。然而, 图像背景的噪声随着对比度的增加而放大, 导致图像失真。因此, 在 MSR 算法的增强处理下, 图像中的藻类细胞的轮廓细节更加突出, 色彩更加丰富, 能够在一定程度上降低图像中藻类的识别难度, 但该算法也存在背景噪声过大等问题, 易导致图像的局部区域色彩失真, 影响整体视觉效果。




图 5-14 多尺度 Retinex 图像增强算法在不同参数设置下对三种水样中拍摄的原始图像的增强效果: (a) 原始图像; (b) 最大尺度为 100、尺度数为 2、对比度为 1; (c) 最大尺度为 200、尺度数为 5、对比度为 3; (d) 最大尺度为 300、尺度数为 8、对比度为 5

(二) 自适应直方图均衡化

直方图均衡化 (Histogram Equalization, HE) 算法是以累积分布函数为核心, 通过调整原始图像的灰度级分布, 将灰度直方图从比较集中的某个灰度区间, 非线性地均匀映射在全部灰度范围内, 从而增强图像的对比度^[186], 具体原理如下:

$$C(r_k) = \frac{1}{n} \sum_{i=0}^{k-1} n_i \quad (5-16)$$

其中, $C(r_k)$ 为原始图像中灰度的概率直方图中设输入像素灰度值为 r_k 的累积分布函数; n_i 为图像中灰度值为 r_i 的像素频数, n 为图像像素总数。设输出像素灰度值为 s_k , 像素范围为 $s_{min} \sim s_{max}$ 。期望输出灰度直方图是均匀分布, 即:

$$P(s) = \frac{1}{s_{max} - s_{min}} \quad s_{min} \leq s \leq s_{max} \quad (5-17)$$

其中, $P(s)$ 为像素灰度值 s 的概率分布函数。令 $C(s_k) = C(r_k)$, 即得:

$$(C(r_k)_{max} - C(r_k)_{min}) \frac{s_k - s_{min}}{s_{max} - s_{min}} + C(r_k)_{min} = C(r_k) \quad (5-18)$$

$$\rightarrow \frac{S_k - S_{\min}}{S_{\max} - S_{\min}} = \frac{C(r_k) - C(r_k)_{\min}}{C(r_k)_{\max} - C(r_k)_{\min}} \quad (5-19)$$

$$\rightarrow \frac{S_k - S_{\min}}{S_{\max} - S_{\min}} = C'(r_k) \quad (5-20)$$

最终的直方图均衡化的点算子为：

$$s_k = (s_{\max} - s_{\min})C'(r_k) + s_{\min} = T(r_k) \quad (5-21)$$

由于当图像中存在广泛的对比度差异时，传统的 HE 算法可能无法产生理想的结果。为了解决这个问题，引入了自适应直方图均衡化（Adaptive Histogram Equalization, AHE）算法。该算法在水平/垂直方向上将图像进行裁剪分割，对每个子分块区域进行直方图均衡化处理，最后重新分布亮度来改变图像对比度，形成最终的输出图像^[187]。

如图 5-15 所示，在不同的水平/垂直分块数和裁剪限幅的设置下，AHE 算法对原始图像呈现出不同的增强效果。其中，当水平/垂直分块数增加时，图像的整体对比度得到显著增强。但图像的背景噪声会因裁剪限幅的增加而放大从而导致图像失真，进而增加藻类的检测识别难度。




图 5-15 自适应直方图均衡化图像增强算法在不同参数设置下对三种水样中拍摄的原始图像的增强效果：(a) 原始图像；(b) 水平/垂直分块数为 2，裁剪限幅为 0.02；(c) 水平/垂直分块数为 20，裁剪限幅为 0.02；(d) 水平/垂直分块数为 20，裁剪限幅为 0.1

（三）自适应色阶与对比度增强

自适应色阶与对比度增强（Adaptive Levels and Contrast Enhancement）算法是基于图像中像素的亮度和对比度的分布，通过重新分配像素值来优化图像对比度的一种图像增强算法^[188]。该算法首先统计原始图像的蓝（Blue）/绿（Green）/红（Red）三个颜色通道的直方图，并分别计算各通道按照给定参数（低切 LowCut 和高切 HighCut）确定色阶的上/下限值。该过程在各通道中从色阶 0 开始向上累加统计直方图，当累加值大于 LowCut 所有像素数时，此时的色阶值计为 MinBlue/MinGreen/MinRed；随后从色阶 255 开始向下累计直方图，如果累加值大于 HighCut 所有像素时，此时色阶值计为 MaxBlue/MaxGreen/MaxRed。随后，获取三个颜色通道分量下限值的最小值（ $\min \{ \text{MinBlue}, \text{MinGreen}, \text{MinRed} \}$ ）和上限值的最大值（ $\max \{ \text{MaxBlue}, \text{MaxGreen}, \text{MaxRed} \}$ ），设立为新的上限/下限构建映射（Mapping）表。其中，映射表的规则是，对于在各通道中小于下限时，映射为 0，大于上限时，映射为 255，介于下限和上限之间的值时进行线性映射，默认是映射为 0 到 255 之间。最后对三个通道的图像数据进行映射计算处理，输出最终的图像。

根据自适应直方图均衡化增强处理的结果，由于水平/垂直分块数的增加有助于图像细节的增强，而降低裁剪限幅有助于控制图像的背景噪声，因此采用自适应色阶和对比度增强算法时将水平/垂直分块数设为最大值（20），并把裁剪限幅控制在最小（0.001）的基础上，通过调整对比度以及颜色通道分离（split）来评估该算法对原始图像的增强效果。其中，通道分离的原理是通过提取图像的各个颜色通道的信息，将每个通道独立展示为一幅单通道图像。其意义在于对图像的各个颜色通道进行独立处理，从而实现对特定颜色的分析、识别以及单独的颜色调整。如图 5-16 所示，随着对比度的增加，图像中藻类的清晰度得到明显加强，同时图像的背景噪声放大幅度不明显，能够大幅提高图像中藻类的识别和检测的效率。此外，通道分离的开启不仅能够在一定程度上降低图像的背景噪声，同时能够增强图像中藻类之间的光学特征差异，有助于进一步提升对不同藻类之间的辨识度。

通过对比三种图像增强算法在不同参数设置下对原始图像的增强效果，本章最终选择了整体效果最好的自适应色阶对比度增强算法作为最终的图像增强处理的方案，其中的参数设置包括：水平/垂直分块数为 20、裁剪限幅 0.001、对比度控制为 5，并开启颜色通道分离。




图 5-16 自适应色阶和对比度图像增强算法在不同参数设置下对三种水样中拍摄的原始图像的增强效果：(a) 原始图像；(b) 对比度控制为 3；(c) 对比度控制为 5；(d) 对比度控制为 5，并开启通道分离

(四) 暗通道先验去散射

由于水体中的浮游藻类等颗粒物会在水下形成光线散射效应，使得图像中出现“雾”状背景从而导致拍摄的图像质量下降^[189]。此外，原始图像经对比度增强算法处理后，光散射导致的“雾”状效果会在一定程度上被放大，对后续的藻类特征标记与目标检测造成影响。如图 5-16 (d)所示，尽管本章采用的自适应色阶对比度图像增强算法在开启颜色通道分离的情况下能够在增强图像对比度的同时最大程度地限制了对图像中“雾”的放大，但部分散射光造成的成像质量下降依旧不可忽视。

本章采用暗通道去散射算法对图像进行进一步的处理。暗通道去散射是认为在没有散射光干扰的图像中，局部区域包含的像素在至少一个颜色通道中具有非常低的强度，并基于暗通道先验（Dark Channel Prior）理论对图像进行恢复^[190]。该算法的理论背景为计算机视觉领域中的雾霾图像模型，具体定义为：

$$I(x) = J(x)t(x) + A(1-t(x)) \quad (5-22)$$

式中， $I(x)$ 代表观测到的带有“雾霾”（针对本章的图像处理即可等同于因藻类颗粒引发的散射现象造成的“雾霾”）图像的光强函数， $J(x)$ 表示没有“雾霾”的图像函数。 A 为全局光照， $t(x)$ 为透射率。当光线传播介质均匀时， $t(x)$ 为：

$$t(x) = e^{-\beta d(x)} \quad (5-23)$$

其中, β 为介质的散射系数。在该算法背景下的暗通道去散射的基本原理如下:

$$J^{dark}(x) = \min_{c \in \{R, G, B\}} (\min_{y \in \Omega(x)} J^c(y)) \quad (5-24)$$

式中, $J^c(y)$ 表示无雾图像 J 的颜色通道 (R/G/B), $\Omega(x)$ 表示以 x 为中心的局部区域块, $J^{dark}(x)$ 表示无雾图像 J 的暗通道强度, 该值在不存在“雾霾”的情况下趋近于 0。

该算法的透射率估算为:

$$\tilde{t}(x) = 1 - \omega \min_c (\min_{y \in \Omega(x)} (\frac{I^c(y)}{A^c})) \quad (5-25)$$

其中, ω ($0 < \omega \leq 1$) 为基于介质的常数。

该公式的推导依据为假设背景光强 A^c 和局部区域 $\Omega(x)$ 均为恒定, 从而对带有雾霾的归一化图像函数 $I^c(y)$ 进行取最小值操作, 具体关系式如下:

$$\min_{y \in \Omega(x)} (\frac{I^c(y)}{A^c}) = \tilde{t}(x) \min_{y \in \Omega(x)} (\frac{J^c(y)}{A^c}) + (1 - \tilde{t}(x)) \quad (5-26)$$

对上式三个颜色通道取最小值操作, 可得:

$$\min_c (\min_{y \in \Omega(x)} (\frac{I^c(y)}{A^c})) = \tilde{t}(x) \min_c (\min_{y \in \Omega(x)} (\frac{J^c(y)}{A^c})) + (1 - \tilde{t}(x)) \quad (5-27)$$

根据暗通道先验理论, 无“雾霾”时 J^{dark} 趋近于 0, 即:

$$J^{dark}(x) = \min_c (\min_{y \in \Omega(x)} J^c(y)) = 0 \quad (5-28)$$

由于 A^c 为一个恒定的正数, 因此可表示为:

$$\min_c (\min_{y \in \Omega(x)} (\frac{J^c(y)}{A^c})) = 0 \quad (5-29)$$

将式(5-29)代入到式(5-27)可得:

$$\tilde{t}(x) = 1 - \min_c (\min_{y \in \Omega(x)} (\frac{I^c(y)}{A^c})) \quad (5-30)$$

为使得修复后的图像更加趋近真实, 引入了常数 ω 最终得出式(5-25)作为最终的透光率计算方程。

在随后的软消光 (Soft Matting) 图像优化阶段, 该算法以 $t(x)$ 作为改进的传输图 (transmission map), 将 $t(x)$ 与式(5-25)估算的透射率 $\tilde{t}(x)$ 改写为向量形式 t 与 $\tilde{t}$, 并最小化成本函数 (cost function) [189]:

$$E(t) = t^T L t + \lambda (t - \tilde{t})^T (t - \tilde{t}) \quad (5-31)$$

其中, L 为 Levin 等人^[191]提出的拉普拉斯消光矩阵 (Matting Laplacian matrix), λ 为一个正则化参数。式(5-31)中, 第一项是一个平滑项, 第二项是一个数据项, L 矩阵的第 (i, j) 项定义为:

$$\sum_{k|(i,j) \in w_k} (\delta_{ij} - \frac{1}{|w_k|} (1 + (I_i - \mu_k)^T (\sum_k + \frac{\varepsilon}{|w_k|} U_3)^{-1} (I_i - \mu_k))) \quad (5-32)$$

其中, I_i 和 I_j 表示输入图像在 i 和 j 处像素的颜色; δ_{ij} 表示克罗内克符号 (Kronecker delta), μ_k 和 Σ_k 分别表示区域 w_k 内的颜色的均值矩阵和协方差矩阵; U_3 是一个 3×3 的单位矩阵; ε 是一个正则化参数; $|w_k|$ 表示区域 w_k 内的像素的个数。

t 的最优解通过求解稀疏线性方程获得:

$$(L + \lambda)Ut = \lambda \tilde{t} \quad (5-33)$$

式中, U 为大小与 I 相同的单位矩阵。

最后, 根据式(5-22)对图像的场景亮度 $J(x)$ 进行恢复, 为避免直接恢复过程中产生的噪声过大, 该算法将透射率 $t(x)$ 设置一个下界 t_0 对图像进行最终的去散射处理, 最终得到的表达式为:

$$J(x) = \frac{I(x) - A}{\max(t(x), t_0)} + A \quad (5-34)$$

本章采用的暗通道去散射算法的参数设置中, 令 t_0 为 0.1、透射率常数 ω 为 0.001 (去散射程度 99.9%)、 ε 值为 0.05、暗通道导向滤波半径和最小值滤波半径均为 5, 最终效果如图 5-17 (d)–(f) 所示。从图中可以看出, 暗通道去散射算法对图像的去散射效果显著, 图像中大部分藻类的形态特征得到良好呈现, 同时最大程度保留了图像对比度增强的效果。其中, 球形棕囊藻水样中的散射噪声去除效果最为明显, 整体图像质量得到显著提高。在对照水样与混合水样中, 多种浮游生物的轮廓更加清晰, 其中的直链藻属与小型浮游动物的形态特征最为明显, 鉴别难度最低。同时, 微囊藻属与小球藻属也可根据体积的大小进行分类。此外, 与图 5-7 相似, 在混合水样中拍摄的图像也可分辨出球形棕囊藻与小球藻属之间在颜色上的差异。




图 5-17 水下图像经暗通道去散射处理前后的效果对比视图：(a)—(c)：处理前的球形棕囊藻水样、对照水样，以及混合水样内的拍摄图像；(d)—(f)：处理后的球形棕囊藻水样、对照水样，以及混合水样内的拍摄图像

5.3.3 目标检测模型训练及性能评估

在对 YOLOv8 目标检测模型进行训练的准备工作中，本章将水下显微成像装置在球形棕囊藻藻液与对照水样中拍摄的图像经裁剪—增强—去散射处理后，采用 LabelImg 进行特征标记，以 8:1:1 的比例作为 YOLOv8 目标检测模型的训练集/验证集/测试集分配。此外，本章还将混合水样中拍摄的图像一起纳入测试集，用于最终对 YOLOv8 目标检测模型实际预测效果的检验。

在标注设置中，为确保标记简洁且易分辨，本章在 LabelImg 中将球形棕囊藻 *Phaeocystis Globosa* 标记为“PG”，训练集中序号为 0；直链藻属 *Melosira* 标记为“Mel”，训练集中序号为 1；微囊藻属 *Microcystis* 标记为“Mic”，训练集中序号为 2；小球藻属 *Chlorella* 标记为“Chl”，训练集中序号为 3。此外，所有图像中工作距离外呈淡蓝色的远距离虚焦成像不予标记，部分的标记内容如图 5-18 所示。其中，球形棕囊藻在图像中呈小型亮绿色球状，在图 5-20 (a)中由红色方框标记；小球藻属在图像中呈绿色小型球状，在图 5-20 (b)中由绿色方框标记，小球藻属细胞轮廓处的散射光圈与球形棕囊藻相比较为暗淡，轮廓清晰度更高；直链藻属在图像中呈绿色条状，在图 5-20 (b)中由蓝色方框标记；微囊藻属呈深绿色球状，在图 5-20 (b)中由白色方框标记，其个体之间的直径存在一定程度上的差异且轮廓处的散射光圈较为明显。最终，LabelImg 为每张图片生成

YOLO 格式的 txt 标记文件。




图 5-18 训练集/验证集中 LabelImg 标记的部分藻类：(a) 球形棕囊藻藻液部分；(b) 对照水样部分

为量化评估图像对比度增强和去散射处理对目标检测效果的影响，本章以先后经过自适应色阶对比度增强与暗通道去散射处理后的 LabelImg 特征标记文件作为基础，分别输入原始图像、经自适应色阶对比度增强的图像，以及先后经过自适应对比度增强与暗通道去散射后的图像三组数据集，对 YOLOv8 目标检测模型进行训练。其中，训练参数设定中，训练迭代次数 epoch=300、输入图像大小 imgs=640、每批图像数量 batch=16、数据加载的工作线程数 workers=4。三组训练集/验证集的训练结果混淆矩阵如图 5-19 所示（其他训练结果详见附录 B）。

原始图像集的训练结果可以看出，YOLOv8 目标检测模型对球形棕囊藻与直链藻属的识别效果相对较好，精确率分别达到 74%和 76%，但对小球藻属和微囊藻属的训练效果不理想，精确率均未超过 65%，且所有藻类的漏检率（预测为背景 Background）都超过 25%。原始图像在经过自适应色阶对比度增强处理后，模型的整体性能得到显著提升，特别是微囊藻属和小球藻属的误检率从 18%下降到 6%，且每种藻类的漏检率都降低 10%左右。图像在经过进一步的暗通道去散射处理后，模型对球形棕囊藻、微囊藻属，以及小球藻属的漏检率进一步限制在 10%以下。此外，模型对球形棕囊藻与微囊藻属的识别精确率分别提升 7%和 6%。然而，由于暗通道去散射对藻类周围散射光去除的效果显著，使得微囊藻属与小球藻属之间的误检率略有增加。

综上所述，在 YOLOv8 模型的性能方面，自适应色阶对比度增强与暗通道去散射方法都在不同程度上增强了模型对藻类的检测和分类能力。然而，藻类形态和颜色的差异对模型性能的影响是不同的。例如，虽然自适应色阶对比度增强

算法能够通过放大不同藻类之间的颜色差异来提高 YOLOv8 模型的检测精确度,但也不可避免地放大了图像的背景散射干扰,导致球形棕囊藻与小球藻属/微囊藻之间的误检率相对于原始图像集略有增加。相应地,暗通道去散射算法通过消除散射干扰有效降低模型的漏检率,但也增加了模型对颜色相近藻类(小球藻和微囊藻)之间的误检率。因此,对水下原始图像的处理方案需根据主要监测对象的细胞图像特征(即形态和颜色)进行调整,而不是采用统一的方法。




图 5-19 YOLOv8 目标检测模型训练结果中的归一化混淆矩阵

5.3.4 藻华原因种水下监测功能测试

为了对训练后的 YOLOv8 目标检测模型性能进行测试,本章分别将输入三组数据集训练后的模型对测试集进行目标检测实验,部分测试结果如图 5-20 所示(完整图像测试结果见附录 B)。

如图 5-20 (a)所示,在球形棕囊藻藻水样拍摄的原始图像中,藻类在最佳景深内的成像与景深外的虚焦成像之间差异较小,使得模型易产生误检。原始图像在经过自适应色阶对比度增强后,藻类的虚焦成像与景深内成像之间的光学特征差异得到了放大,使得经训练后的模型能够在较大程度上避免对虚焦背景的误检。图像在经过进一步的暗通道去散射处理后,图像中背景的散射光得到了有效去除,有效降低了模型对球形棕囊藻的漏检率。如图 5-20 (b)所示,在对照水样中,模型对原始图像中的直链藻属与小球藻属的整体识别效果较好,但由于微囊藻属的轮廓存在较为明显的散射光圈,因此模型对微囊藻属易造成漏检。原始图像在经过对比度增强后,微囊藻属的漏检率得到了有效限制。然而,尽管图像在经过暗通道去散射处理后能够通过排除散射光的干扰进一步降低模型对藻类的漏检率,但同时易导致模型对球形棕囊藻、微囊藻属以及小球藻属之间误检率的上升。因此,在采用暗通道去散射算法对图像进行散射光去除时,需根据目标原因种的细

胞光学特征来对参数进行设置,避免因散射光去除过度导致目标原因种细胞轮廓处的散射被弱化。如图 5-20 (c)所示,在混合水样中,原始图像在经过自适应色阶对比度图像增强后,模型对形态特征相近的球形棕囊藻与小球藻属实现了显著的分类效果,说明 YOLOv8 目标检测模型能够对形状大小相似但光学特征存在差异的藻类进行有效区分,因此适用于水下浮游生物的原位实时监测。




图 5-20 YOLOv8 对拍摄的三种水样图像(测试集)的部分目标检测结果: (a) 球形棕囊藻水样; (b) 对照水样; (c) 混合水样

基于 YOLOv8 目标检测模型的测试结果,水样中不同藻类的生物量可根据显微镜的视场 $\times$ 景深进行计算,具体如式(5-35)所示:

$$C_i = \frac{N_i}{A \cdot D} \quad (5-35)$$

其中, C_i 为藻类 i 的生物量, N_i 为目标检测结果中藻类 i 的数量, A 为显微成像装置的有效视场面积, D 为景深。本章所采用的显微镜头参数中,其视场为 $1 \text{ mm} \times 1 \text{ mm}$, 景深为 1 mm , 因此计量浓度单位为 $(\text{cells} \cdot \mu\text{L}^{-1})$ 。

以图 5-20 中测试集所在的完整图像目标检测结果进行统计为案例,具体统计结果如表 5-1 所示。根据统计结果可知, YOLOv8 目标检测模型在对球形棕囊藻藻液和对照水样的测试中,直接误检率趋近于零。其中,在检出生物量超过

260 cells· μL^{-1} 的球形棕囊藻藻液中误检为小球藻属和微囊藻属的结果均不超过 1 个; 在检出生物量超过 260 cells· μL^{-1} 的对照水样中误检为球形棕囊藻的结果不超过 4 个。

为进一步测试经训练的 YOLOv8 目标检测模型的功能, 本章在测试集中加入了球形棕囊藻藻液与对照水样约 1:9 比例混合水样中拍摄的图像。在对混合水样的目标检测测试结果中, 模型对原始图像中的球形棕囊藻识别效果不理想, 仅在混合水样图像中检测出 6 个。同时, 球形棕囊藻与小球藻属之间的误检率较高, 模型在混合水样中检测出小球藻属生物量达到 135 cells· μL^{-1} , 远远超过对照水样中检测的数量, 因此该结果与实际相差较大。在对图像经过自适应色阶对比度增强后, 球形棕囊藻与小球藻属之间的误检率得到了有效控制, 检测出的球形棕囊藻生物量为 39 cells· μL^{-1} 。但由于对比度增强在排除虚焦成像干扰的同时, 在一定程度上放大了散射光的干扰, 使得模型检测出的直链藻属、微囊藻属与小球藻属的生物量整体低于原始图像。图像在经过进一步的暗通道去散射处理后, 由于散射光去除后使得模型的漏检率得到了有效降低, 模型对三种水样图像检测出的藻类生物量明显高于原始图像和仅经过对比度增强后的图像。然而, 散射光的去除使得球形棕囊藻、微囊藻属和小球藻属之间的光学特征差异被弱化, 使得三种藻类之间的误检率略有上升, 但对整体识别效果影响不大。

综上所述, 与人类视觉相比, YOLOv8 目标检测模型不仅对水下微藻的识别计数效率更高 (每张图像检测所需的平均时长约 0.3s), 还能在暗场照明下准确区分球形褐囊藻和小球藻的细微颜色差异, 从而将两者的误检率限制在接近 0%。

表 5-1 YOLOv8 对图 5-20 所属测试集完整图像的藻类单位浓度计量统计 (cells· μL^{-1})

图像类型	水样类型	球形棕囊藻	直链藻属	微囊藻属	小球藻属
原始图像	球形棕囊藻藻液	261	0	1	1
	对照水样	0	95	62	68
	混合水样	6	90	53	135
图像对比度增强	球形棕囊藻藻液	262	0	1	0
	对照水样	3	102	50	56
	混合水样	39	68	40	61
图像对比度增强+暗通道去散射	球形棕囊藻藻液	326	0	0	1
	对照水样	4	99	57	122
	混合水样	35	84	49	155

5.4 本章小结

本章提出了以水下显微成像—图像处理—目标检测为基础的技术框架,以近年来南海北部湾有害藻华的主要原因种球形棕囊藻作为研究对象,开展了相关实验研究,主要结论有:

1) 本章搭建的水下显微成像装置通过隔绝近距离虚焦成像的干扰,在暗场照明条件下能够在水样中直接拍摄获取高质量的水下藻类图像,并清晰呈现出不同藻类的形态特征与光学特征。其中,形态特征相似的球形棕囊藻与小球藻属之间尽管存在一定程度上的光学特征差异,但依旧存在一定程度上的误检风险。

2) 自适应色阶对比度图像增强算法能够通过强化球形棕囊藻、微囊藻属和小球藻属之间的光学特征差异,有助于实现 YOLOv8 目标检测模型对藻类识别精确率的大幅提升,同时还能够有效区分图像中虚焦成像的干扰。

3) 暗通道先验算法能够有效去除水下图像背景中的散射干扰,大幅降低 YOLOv8 目标检测模型对图像中藻类的漏检率。原始图像在先后经过对比度增强与去散射处理后, YOLOv8 目标检测模型对球形棕囊藻的识别精确率从原先的 74% 提高到 91%。

4) 本章提出的有害藻华原因种水下原位监测技术框架在功能上兼具高效率和高精确率的特征,尤其对形态特征相近的球形棕囊藻与小球藻属实现了良好的分类效果,误检率接近 0。

第6章 结论与展望

6.1 结论

本文基于我国近海有害藻华区域性、非线性、随机性,以及原因种多样性特征,以南海北部湾近岸海域作为研究区域,对环境要素时空分布特征、环境因子特征选择,以及有害藻华的预测及其原因种监测方法开展了系统性研究。采用了空间插值和相关性分析揭示了北部湾近岸海域叶绿素 a 浓度、营养盐、水温、盐度、浊度等环境要素的时空分布特征,分析并讨论了各海域有害藻华风险上升的前提条件。采用了随机森林回归方法对影响藻华动态的环境因子进行了特征选择,探讨了藻华爆发前后的关键环境信号特征。以环境因子作为特征变量建立了逻辑回归二分类预测模型对藻华案例进行了预测分析,探究了营养盐吸收和原因种差异对藻华预测结果的影响,明确了掌握优势种信息对提高藻华预测能力的必要性。针对传统方法对异养藻类难以有效监测的问题,构建了以水下显微成像—图像处理—目标检测为基础的有害藻华原因种水下原位监测技术框架,以球形棕囊藻作为主要监测目标开展了水槽实验,并根据搭建的显微成像装置在不同水样中拍摄的藻类图像分析了不同藻种之间的光学图像特征差异,先后采用了自适应色阶对比度增强和暗通道去散射对原始图像进行了优化处理,采用 YOLOv8 目标检测模型对图像中的藻类进行训练和测试,并基于训练/测试结果评估了该监测技术框架的性能及应用前景。基于上述研究内容,本文得出的主要结论如下:

1) 叶绿素 a 浓度的年际空间分布主要受营养盐水平和盐度的双重影响,高营养盐水平和中盐度环境是导致廉州湾南流江河口附近海域叶绿素 a 浓度长期处于高水平的主要原因。当海水环境具备高营养水平、高水温,以及中盐度其中的至少两个条件时,藻华风险会大幅上升。

2) 环境因子中,水温、无机态营养盐(硝氮和活性磷酸盐)和盐度对叶绿素 a 浓度的影响较为显著。其中,硝氮与活性磷酸盐浓度在 24 小时内出现大幅度下降是有害藻华的重要预测信号,而适宜的水温或盐度环境能够将营养盐下降与藻华爆发之间的间隔缩短至 4 小时以内。研究区域内藻类的最佳生长水温和盐度范围分别为 30—32 °C 和 22—28 psu。相比之下,0—50 NTUs 范围内浊度变化引起的海水透光率下降对藻类生长的影响程度较小。

3) 以硝氮、活性磷酸盐、温度,以及盐度作为特征变量建立的有逻辑回归

预测模型对“藻华/常态”的二分类预测准确率最高可达 88.6%，不同原因种藻类对营养盐的吸收偏好差异会对预测结果产生显著影响。其中，蓝绿藻藻华对硝氮和活性磷酸盐的吸收都较为显著，预测精确率相对较高，至少达 70%；球形棕囊藻藻华对硝氮的吸收显著，但对活性磷酸盐的吸收不显著，预测精确率为 60.78%；中肋骨条藻藻华对硝氮和活性磷酸盐的吸收都不显著，预测精确率相对较低，仅为 50%。因此，掌握藻华优势种信息从而明确其优先吸收的营养盐类型，是提升有害藻华预测能力的必要条件之一。

4) 本研究提出的以水下显微成像—图像处理—目标检测为基础的有害藻华原因种监测技术框架在功能上兼具高效率和高精确率的特征，尤其对形态特征相近的球形棕囊藻与小球藻属实现了良好的分类效果，误检率接近 0。在原始图像处理过程中，自适应色阶对比度算法放大了藻类之间的颜色差异并消除了虚焦干扰，提高了模型对藻类的识别精确率；暗通道先验算法减少了图像背景中的散射干扰，降低了漏检率，使得 YOLOv8 目标检测模型对球形棕囊藻的识别精确率从 74%提升到 91%。

6.2 创新点

基于目前对我国近岸海域有害藻华研究现状及存在的问题，本文的主要创新点如下：

1) 根据藻华动态的环境因子特征选择结果，确立了无机态营养盐浓度的大幅下降作为 24 小时内预测藻华爆发的首要信号，且当水温与盐度条件适宜时，两者的时间间隔可缩短至 4 小时以内。该工作提高了对近岸海域有害藻华控制因素和形成机制的认识。

2) 针对有害藻华非线性、随机性以及原因种多样性等特征，提出了以营养盐、水温，以及盐度作为特征变量的“藻华/常态”二分类预测方法。预测结果表明，当藻类对营养盐吸收显著时，对藻华的预测精确率最高可达 90%。该工作为近岸海域有害藻华预测方法的研究提供了一种思路。

3) 建立了以水下显微成像—图像处理—目标检测为基础的有害藻华原因种监测技术框架，以球形棕囊藻作为主要监测目标开展了相关实验。根据不同藻类之间的光学图像特征差异，结合自适应色阶对比度增强与暗通道去散射两种图像处理方法，大幅提升了水下原位监测图像数据质量，使得 YOLOv8 目标检测模型对球形棕囊藻的识别精确率从 74%提高到 91%。该工作为实现有害藻华水下原位监测提供了一种可行性方案。

6.3 展望

本文的研究工作虽在一定程度上增加了对我国近岸海域有害藻华形成机制的认识,并为监测方案的制定和预测工作提供了理论指导和技术支持,但由于时间和条件所限,作者认为目前还存在一些细节问题需要进一步的完善和改进,主要包括以下几点:

1) 本研究的营养盐数据涵盖了硝氮和活性磷酸盐,缺少对氨氮以及硅酸盐等其他指标的数据,使得对中肋骨条藻藻华(如第 4 章的研究案例 3)的预测结果不理想。因此在未来对本研究跟进的工作中需补充其他类型营养盐数据进行进一步的分析。

2) 受限于初步试验阶段的预算,本研究搭建的水下显微成像装置目前处于原理样机阶段,未进一步安装结构复杂且昂贵的距离微调机械装置,使得水下显微成像实验中的暗场照明条件不完全,获取的原始图像中心处存在部分直射光,影响图像质量。因此在后续的研究中可考虑对水下显微成像装置进行针对性优化升级,在提升原始图像质量的同时进一步保证 YOLOv8 目标检测模型对不同藻类识别功能的提升。

3) 本文搭建的有害藻华原因种监测技术框架目前仅以球形棕囊藻为目标原因种进行了水槽实验,尚未对夜光藻、中肋骨条藻等其他分布在北部湾近岸海域的有害藻类进行目标检测实验。因此,在未来对该框架的细化完善过程中,YOLOv8 目标检测模型需对更多有害藻类的图像进行训练,进一步投入近岸海域有害藻华现场的监测与预测实践中。

参考文献

- [1] Chapman R L. Algae: the world's most important plants-an introduction[J]. Mitigation and Adaptation Strategies for Global Change, 2013, 18: 5-12.
- [2] Hoagland P, Jin D, Beet A, et al. The human health effects of Florida Red Tide (FRT) blooms: An expanded analysis[J]. Environment International, 2014, 68: 144-153.
- [3] Huang B, Liang Y, Pan H, et al. Hemolytic and cytotoxic activity from cultures of *Aureococcus anophagefferens* — a causative species of brown tides in the north-western Bohai Sea, China[J]. Chemosphere, 2020, 247:125819.
- [4] Xia Z, Cao X, Li S, et al. Distribution of *Ulva prolifera*, the dominant species in green tides along the Jiangsu Province coast in the Southern Yellow Sea, China[J]. Journal of Sea Research, 2023, 196: 102436.
- [5] Haro S, Bermejo R, Wilked R, et al. Monitoring intertidal golden tides dominated by *Ectocarpus siliculosus* using Sentinel-2 imagery[J]. International Journal of Applied Earth Observation and Geoinformation, 2023, 122: 103451.
- [6] Hallegraeff G M. A review of harmful algal blooms and their apparent global increase[J]. Phycologia, 1993, 32(2): 79-99.
- [7] Anderson D M, Fensin E, Gobler C J, et al. Marine harmful algal blooms (HABs) in the United States: History, current status and future trends[J]. Harmful Algae, 2021, 102(2): 101975.
- [8] Lehtiniemi M, Engström-Öst J, Viitasalo M. Turbidity decreases anti-predator behaviour in *pike larvae*, *Esox lucius*[J]. Environmental Biology of Fishes, 2005, 73(1): 1-8.
- [9] Gobler C J. Climate change and harmful algal blooms: insights and perspective[J]. Harmful Algae, 2019, 91: 101731.
- [10] Griffith A W, Doherty O M, Gobler C J. Ocean warming along temperate western boundaries of the Northern Hemisphere promotes an expansion of *Cochlodinium polykrikoides* blooms[J]. Proceedings of the Royal Society B: Biological Sciences, 2019, 286(1904): 20190340.
- [11] O'Neil J M, Davis T W, Burford M A, et al. The rise of harmful *cyanobacteria* blooms: The potential roles of eutrophication and climate change[J]. Harmful Algae, 2012, 14: 313-334.
- [12] 陈连增, 雷波. 中国海洋科学技术发展 70 年[J]. 海洋学报, 2019, 41(10): 3-22.

- [13] Zeng J, Yin B, Wang Y, et al. Significantly decreasing harmful algal blooms in China seas in the early 21st century[J]. Marine Pollution Bulletin, 2019, 139: 270-274.
- [14] Zhang Z, Hu B, Qiu H. Comprehensive assessment of ecological risk in southwest Guangxi-Beibu bay based on DPSIR model and OWA-GIS[J]. Ecological Indicators, 2021, 132: 108334.
- [15] 方雪原, 娄安刚, 贺成奇. 北部湾冬季风生环流的数值模拟及其对海洋环境的影响分析[J]. 海洋湖沼通报, 2015(1): 129-133.
- [16] Li J, Xu M, Wang J, et al. Effects of nutrient limitation on cell growth, exopolysaccharide secretion and TEP production of *Phaeocystis globosa*[J]. Marine Environmental Research, 2023, 183: 105801.
- [17] 贺成, 宋书群, 李才文. 广西北部湾海域球形棕囊藻囊体时空分布及其影响因素[J]. 海洋与湖沼, 2019, 50: 630-643.
- [18] 陈菊芳, 徐宁, 江天久, 等. 中国赤潮新记录种——球形棕囊藻(*Phaeocystis globosa*) [J]. 暨南大学学报: 自然科学与医学版, 1999, 20(3): 124-129.
- [19] He C, Xu S, Kang Z J, et al. Prokaryotic community composition and structure during *Phaeocystis globosa* blooms in the Beibu Gulf, China[J]. Aquatic Microbial Ecology, 2021, 86: 137-151.
- [20] Qi Y, Chen J, Wang Z, et al. Some observations on harmful algal bloom (HAB) events along the coast of Guangdong, southern China in 1998[J]. Hydrobiologia, 2004, 512(1-3): 209-214.
- [21] Kang Z, Yang B, Lai J, et al. *Phaeocystis globosa* bloom monitoring: based on *P. globosa* induced seawater viscosity modification adjacent to a nuclear power plant in Qinzhou Bay, China[J]. Journal of Ocean University of China, 2020, 19(5): 1207-1220.
- [22] Zhen Y, Mi T, Yu Z. Detection of *Phaeocystis globosa* using sandwich hybridization integrated with nuclease protection assay (NPA-SH)[J]. Journal of environmental sciences, 2008. 20(12): 1481-1486.
- [23] Gibson K, Song H, Chen N. Metabarcoding analysis of microbiome dynamics during a *Phaeocystis globosa* bloom in the Beibu Gulf, China[J]. Harmful algae, 2022, 114: 102217.
- [24] 袁涌铨, 吕旭宁, 吴在兴, 等. 北部湾典型海域关键环境因子的时空分布与影响因素[J]. 海洋与湖沼, 2019, 050(003): 579-589.
- [25] Wang X, Wang Y, Ou L, et al. Allocation costs associated with Induced defense in *Phaeocystis globosa* (Prymnesiophyceae): the effects of nutrient availability[J]. Scientific Reports, 2015, 5(1): 10850.
- [26] 李亚男, 沈萍萍, 黄良民, 等. 棕囊藻的分类及系统进化研究进展[J]. 生态学杂志, 2012, 31(3): 745-754.

- [27] 沈萍萍, 齐雨藻, 欧林坚. 中国沿海球形棕囊藻 (*Phaeocystis globosa*) 的分类、分布及其藻华[J]. 海洋科学, 2018, 42(10): 146-162.
- [28] 史文凯, 徐晓莹, 张凡, 等. 我国球形棕囊藻藻华危害与应对策略[J]. 渔业研究, 2023, 45(3): 311-316.
- [29] 贺立燕, 宋秀贤, 於凡, 等. 潜在影响防城港核电冷源系统的藻类暴发特点及其监测防控技术[J]. 海洋与湖沼, 2019, 50(3): 700-706.
- [30] Wang Y, Xu C, Lin Q, et al. Modeling of algal blooms: Advances, applications and prospects[J]. Ocean and Coastal Management, 2024, 255: 107250.
- [31] Gilpin L C, Davidson K, Roberts E C. The influence of changes in nitrogen: silicon ratios on diatom growth dynamics[J]. Journal of Sea Research, 2004, 51: 21-35.
- [32] Li X, Yu R, Geng H, et al. Increasing dominance of dinoflagellate red tides in the coastal waters of Yellow Sea, China[J]. Marine Pollution Bulletin, 2021, 168: 112439.
- [33] Redfield A C, Ketchum B H, Richards F A. The influence of organisms on the composition of sea-water[J]. The sea: ideas and observations on progress in the study of the seas, 1963, 2: 26-77.
- [34] Egge J K, Aksnes D L. Silicate as regulating nutrient in phytoplankton competition[J]. Marine Ecology Progress Series, 1992, 83: 281-289.
- [35] Bodeanu N. Algal blooms and development of the main phytoplanktonic species at the Romanian Black Sea littoral in conditions of intensification of the eutrophication process[J]. Marine Coastal Eutrophication, 1992: 891-906.
- [36] Xiao R, Zhao Z, Guo J, et al. Variations of dissolved inorganic nutrients and their influences on harmful algal blooms in Bohai Sea over the past thirteen years[J]. Estuarine, Coastal and Shelf Science, 2023, 287: 108335.
- [37] Lv X, Wu Z, Song X et al. Nutritional strategy for the preferential uptake of NO_3^- -N by *Phaeocystis globosa*[J]. Hydrobiologia, 2019, 846: 109-122.
- [38] Zhu J, Yu Z, He L, et al. Mechanisms of *Phaeocystis globosa* blooms in the Beibu Gulf revealed by metatranscriptome analysis[J]. Harmful Algae, 2023, 124: 102407.
- [39] Hallegraeff G M. On the global increase of harmful algal bloom[J]. Wetlands Australia, 2010, 12(1): 2-15.
- [40] Griffith A W, Gobler C J. Harmful algal blooms: A climate change co-stressor in marine and freshwater ecosystems[J]. Harmful Algae, 2020, 91: 101590.
- [41] Gobler C J, Doherty O M, Hattenrath-Lehmann T K, et al. Ocean warming since 1982 has expanded the niche of toxic algal blooms in the North Atlantic and North Pacific oceans[J]. Proceedings of the National Academy of Sciences of the United States of America, 2017, 114(19): 4975-4980.

- [42] Ding W, Zhang C, Shang S. The early assessment of harmful algal bloom risk in the East China Sea[J]. *Marine Pollution Bulletin*, 2022, 178: 113567.
- [43] Pang M, Xu J, Qu P, et al. Effect of CO₂ on growth and toxicity of *Alexandrium tamarense* from the East China Sea, a major producer of paralytic shellfish toxins[J]. *Harmful Algae*, 2017, 68: 240-247.
- [44] Wells M, Trainer V, Smayda T, et al. Harmful algal blooms and climate change: learning from the past and present to forecast the future[J]. *Harmful Algae*, 2015, 49: 68-93.
- [45] 陈炳章, 王宗灵, 朱明远, 等. 温度、盐度对具齿原甲藻生长的影响及其与中肋骨条藻的比较[J]. *海洋科学进展*, 2005, 23(1): 60-64.
- [46] 王云龙, 袁骐, 沈新强. 长江口及邻近水域春季浮游植物的生态特征[J]. *中国水产科学*, 2005, 12(3): 300-306.
- [47] Zhang Q, Yu R, Zhao J, et al. Distribution of *Aureococcus anophagefferens* in relation to environmental factors and implications for brown tide seed sources in Qinhuangdao coastal waters, China[J]. *Harmful Algae*, 2021, 109: 102105.
- [48] 于仁成, 李笑语, 周正熙. 地球大数据支撑可持续发展目标报告(2020)中国篇: 渤海藻华灾害风险评估[M]. 北京: 科学出版社, 2021, 215-220.
- [49] 方涛, 李道季, 余立华, 等. 光照和营养盐磷对微型及微微型浮游植物生长的影响[J]. *生态学报*, 2006, 26(9): 2783-2790.
- [50] Fichez R, Jickells T D, Edmunds H M. Algal blooms in high turbidity, a result of the conflicting consequences of turbulence on nutrient cycling in a shallow water estuary[J]. *Estuarine, Coastal and Shelf Science*, 1992, 35(6): 577-592.
- [51] Yan Z, Kamanmalek S, Alamdari N, et al. Predicting coastal harmful algal blooms using integrated data-driven analysis of environmental factors[J]. *Science of the Total Environment*, 2024, 912: 169253.
- [52] Franks P. Recent Advances in Modelling of Harmful Algal Blooms[C]. *Global Ecology and Oceanography of Harmful Algal Blooms*. Berlin: Springer International Publishing. 2018: 359-377.
- [53] Margalef R. Life-forms of phytoplankton as survival alternatives in an unstable environment[J]. *Oceanologia*, 1978, 1(4): 493-509.
- [54] Smayda T J, Reynolds C S. Community assembly in marine phytoplankton: application of recent models to harmful dinoflagellate blooms[J]. *Journal of Plankton Research*, 2001, 23(5): 447-461.
- [55] Glibert, P M. Margalef revisited: a new phytoplankton mandala incorporating twelve dimensions, including nutritional physiology[J]. *Harmful Algae*, 2016, 55: 25-30.
- [56] Winemiller K O, Fitzgerald D B, Bower, L M, et al., Functional traits, convergent evolution, and periodic tables of niches[J]. *Ecological Letters*, 2015,

- 18(8): 737-751.
- [57] Xiao W, Laws E A, Xie Y, et al. Responses of marine phytoplankton communities to environmental changes: New insights from a niche classification scheme[J]. *Water Research*, 2019, 166: 115070.
 - [58] Alves-de-Souza C, Iriarte J L, Mardones J I. Interannual variability of *Dinophysis acuminata* and *Protoceratium reticulatum* in a Chilean fjord: insights from the realized niche analysis[J]. *Toxins*, 2019, 11(1): 19.
 - [59] Accoroni S, Glibert P M, Pichierri S, et al. A conceptual model of annual *Ostreopsis cf. ovata* blooms in the northern Adriatic Sea based on the synergic effects of hydrodynamics, temperature, and the N:P ratio of water column nutrients[J]. *Harmful Algae*, 2015, 45: 14-25.
 - [60] Anderson C R, Siegel D A, Kudela R M, et al. Empirical models of toxigenic *Pseudo-nitzschia* blooms: Potential use as a remote detection tool in the Santa Barbara Channel[J]. *Harmful Algae*, 2009, 8(3): 478-492.
 - [61] Hastie T J. Generalized additive models[C]. *Statistical Models in S*. London: Chapman and Hall. 2017: 249-307.
 - [62] Díaz P A, Ruiz-Villarreal M, Pazos Y, et al. Climate variability and *Dinophysis acuta* blooms in an upwelling system[J]. *Harmful Algae*, 2016, 53: 145-159.
 - [63] Xiao W, Liu X, Irwin A J, et al., Warming and eutrophication combine to restructure diatoms and dinoflagellates[J]. *Water Research*, 2018, 128: 206-216.
 - [64] Mohapatra J B, Jha P, Jha M K, et al. Efficacy of machine learning techniques in predicting groundwater fluctuations in agro-ecological zones of India[J]. *Science of the Total Environment*, 2021, 785(1):147319.
 - [65] Liu N, Chen S, Chen Z, et al. Long-term prediction of sea surface chlorophyll-A concentration based on the combination of spatio-temporal features[J]. *Water Research*, 2022, 211: 118040.
 - [66] Guallar C, Delgado M, Diogene J, et al. Artificial neural network approach to population dynamics of harmful algal blooms in Alfacs Bay (NW Mediterranean): Case studies of *Karlodinium* and *Pseudo-nitzschia*[J]. *Ecological Modelling*, 2016, 338:37-50.
 - [67] Yu P, Gao R, Zhang D, et al. Predicting coastal algal blooms with environmental factors by machine learning methods[J]. *Ecological Indicators*, 2021, 123: 107334.
 - [68] Zhao C, Shao N, Yang S, et al. Predicting *cyanobacteria* bloom occurrence in lakes and reservoirs before blooms occur[J]. *Science of the Total Environment*, 2019, 670: 837-848.
 - [69] Zhang J, Zhi M, Zhang Y. Combined Generalized Additive model and Random

- Forest to evaluate the influence of environmental factors on phytoplankton biomass in a large eutrophic lake[J]. *Ecological Indicators*, 2021, 130: 108082.
- [70] Park J, Patel K, Lee W H. Recent advances in algal bloom detection and prediction technology using machine learning[J]. *Science of the Total Environment*, 2024, 938: 173546.
- [71] Park Y, Lee H K, Shin J K, et al. A machine learning approach for early warning of cyanobacterial bloom outbreaks in a freshwater reservoir[J]. *Journal of Environmental Management*, 2021, 288(2-3): 112415.
- [72] Park Y, Cho K H, Park J, et al. Development of early-warning protocol for predicting chlorophyll-a concentration using machine learning models in freshwater and estuarine reservoirs, Korea[J]. *Science of The Total Environment*, 2015, 502: 31-41.
- [73] Zahir M, Su Y, Shahzad M I, et al. A review on monitoring, forecasting, and early warning of harmful algal bloom[J]. *Aquaculture*, 2024, 593: 741351.
- [74] 于仁成, 刘东艳. 我国近海藻华灾害现状, 演变趋势与应对策略[J]. *中国科学院院刊*, 2016, 31(10): 1167-1174.
- [75] Hodgkiss I J, Ho K C. Are changes in N:P ratios in coastal waters the key to increased red tide blooms?[J]. *Hydrobiologia*, 1997, 352: 141-147.
- [76] 于连生, 徐雷. 基于数字显微镜的赤潮生物计数精度检验方法研究[J]. *海洋技术*, 2004, 23(1): 31-34.
- [77] 孔凡洲, 徐子钧, 李钦亮, 等. 渤黄海贝毒和有毒赤潮生物分布状况的研究[C]中国赤潮研究与防治学术研讨会. 中国海洋学会, 2004, 27-34.
- [78] 张敏, 孔凡洲, 杨锐, 等. 2019—2021 年中国近海有毒有害微藻和藻毒素分布数据集[J]. *中国科学数据*, 2024, 9(1): 217-229.
- [79] Lubac B, Loisel H, Guiselin N, et al. Hyperspectral and multispectral ocean color inversions to detect *Phaeocystis globosa* blooms in coastal waters[J]. *Journal of Geophysical Research*, 2008, 113(C6): C06026.
- [80] Ma J, Jin S, Li J, et al. Spatio-temporal variations and driving forces of harmful algal blooms in Chaohu Lake: a multi-source remote sensing approach[J]. *Remote Sensing*, 2021, 13: 427.
- [81] Caballero I, Raúl F, Escalante O M, et al. New capabilities of sentinel-2A/B satellites combined with in situ data for monitoring small harmful algal blooms in complex coastal waters[J]. *Scientific Reports*, 2020, 10: 8743.
- [82] Chen C, Liang J, Yang G, et al. Spatio-temporal distribution of harmful algal blooms and their correlations with marine hydrological elements in offshore areas, China[J]. *Ocean & Coastal Management*, 2023, 238: 106554.
- [83] Pour A B, Hashim M. Identification of high potential bays for HABs occurrence in peninsular malaysia using palsar remote sensing data[J].

- International Archives of the Photogrammetry Remote Sensing and Spatial Information Sciences, 2016, XLII-4/W1: 97-101.
- [84] Alharbi B. Remote sensing techniques for monitoring algal blooms in the area between Jeddah and Rabigh on the Red Sea Coast[J]. Remote Sensing Applications: Society and Environment, 2023, 30: 100935.
- [85] Robbins I C, Kirkpatrick G J, Blackwell S M, et al. Improved monitoring of HABs using autonomous underwater vehicles (AUV)[J]. Harmful Algae, 2006, 5(6): 749-761.
- [86] Sieracki M E, Benfield M, Hanson A, et al. Optical plankton imaging and analysis systems for ocean observation[C]. Ocean information for society: sustaining the benefits, realizing the potential. Venice: OceanObs'09, 2010: 21-25.
- [87] Junku Y, Giacomo M, Richard B. Applications of marine robotic vehicles[J]. Intelligent Service Robotics. 2011: 221-231.
- [88] 于翔, 宋家驹, 于连生. 水下全自动显微成像仪[J]. 海洋技术学报, 2009, 28(004): 14-16.
- [89] Baek S S, Jung E Y, Pyo J, et al. Hierarchical deep learning model to simulate phytoplankton at phylum/class and genus levels and zooplankton at the genus level[J]. 2022, Water Research, 218: 118494.
- [90] Yuan A, Wang B, Li J, et al. A low-cost edge AI-chip-based system for real-time algae species classification and HAB prediction[J]. Water Research, 2023, 233: 119727.
- [91] Otálora P, Guzmán J L, Acien F G, et al. An artificial intelligence approach for identification of microalgae cultures[J]. New Biotechnology, 2023, 77: 58-67.
- [92] Zhou S, Jiang J, Hong X, et al. Vision meets algae: a novel way for microalgae recognition and health monitor[J]. Frontiers in Marine Science, 2023, 10: 1105545.
- [93] Chan W H, Fung B S B, Tsang D, et al. A freshwater algae classification system based on machine learning with StyleGAN2-ADA augmentation for limited and imbalanced datasets[J]. Water Research, 2023, 243: 120409.
- [94] Verity P G, Medlin L K. Observations on colony formation by the cosmopolitan phytoplankton genus *Phaeocystis*[J]. Journal of Marine Systems, 2003, 43: 153-164.
- [95] Lau S, Lane S. Biological and chemical factors influencing shallow lake eutrophication: a long-term study[J]. The Science of the Total Environment, 2002, 288(3): 167-181.
- [96] 张永丰, 李欣阳, 张万磊, 等. 微型藻华爆发海域硅酸盐与叶绿素 a 分布特征研究[J]. 生态科学, 2013, 32(4): 509-513.

- [97] 吕学研, 张文涛, 吴时强. 水华前后叶绿素 a 变化及其与水质因子的关系[J]. 人民黄河, 2012, 34(2): 73-75.
- [98] Longhurst A R, Harrison W G. The biological pump: Profiles of plankton production and consumption in the upper ocean[J]. Progress in Oceanography, 1989, 22(1): 47-123.
- [99] Bharathi M D, Venkataramana V, Sarma V V. Phytoplankton community structure is governed by salinity gradient and nutrient composition in the tropical estuarine system[J]. Continental Shelf Research, 2022, 234: 104643.
- [100] Lehman P W, Kurobe T, Teh S J. Impact of extreme wet and dry years on the persistence of *Microcystis* harmful algal blooms in San Francisco Estuary[J]. Quaternary International, 2020, 621: 16-25.
- [101] Gameiro C, Cartaxana P, Cabrita M T, et al. Variability in chlorophyll and phytoplankton composition in an estuarine system[J]. Hydrobiologia, 2004, 525(1-3): 113-124.
- [102] 黎树式, 戴志军, 葛振鹏, 等. 北部湾北部生态环境灾害变化研究[J]. 灾害学, 2014, 29(4): 43-47.
- [103] 黄以琛, 李炎, 邵浩, 等. 北部湾夏冬季海表温度、叶绿素和浊度的分布特征及调控因素[J]. 厦门大学学报(自然科学版), 2008, 47(6): 856-863.
- [104] 庄军莲, 许铭本, 张荣灿, 等. 广西防城港湾周年浮游植物生态特征[J]. 应用生态学报, 2011, 22(5): 1309-1315.
- [105] 卢天和, 黄光华, 马华威, 等. 陆基家庭水产养殖对广西南流江、钦江、防城江环境影响的初步研究[J]. 水产养殖, 2017, 038(007): 32-38.
- [106] 蓝文陆. 近 20 年广西钦州湾有机污染状况变化特征及生态影响[J]. 生态学报, 2011, 31(20): 5970-5976.
- [107] Lu D, Zhang D, Zhu W, et al. Sources and long-term variation characteristics of dissolved nutrients in Maowei Sea, Beibu Gulf, China[J]. Journal of Hydrology, 2022, 615: 128576.
- [108] 彭小燕, 喻泽斌, 蓝文陆, 等. 近 10a 廉州湾富营养化因子变化特征及其与赤潮演变的关系[J]. 海洋环境科学, 2018, 37(5): 670-677.
- [109] Zhang J, Mo L, Li X, et al. Distribution, historical variations, and geochemical fractions of toxic trace metals and their ecological risks in sediments of the Nanliu River Estuary, South China[J]. Ecological Indicators, 2022, 145: 109708.
- [110] Feng Y, Bethel B J, Dong C, et al. Marine heatwave events near Weizhou Island, Beibu Gulf in 2020 and their possible relations to coral bleaching[J]. Science of The Total Environment, 2022, 823: 153414.
- [111] Ning Z, Fang C, Yu K, et al. Influences of phosphorus concentration and porewater advection on phosphorus dynamics in carbonate sands around the

- Weizhou Island, northern South China Sea[J]. *Marine Pollution Bulletin*, 2020, 160: 111668.
- [112] 广西壮族自治区海洋局. 广西壮族自治区海洋环境质量公报[M]. 广西: 广西壮族自治区海洋局办公室, 2014: 4-21.
- [113] 韩丽君, 李天深, 蓝文陆, 等. 2013 年钦州湾水质自动监测结果与分析[J]. *环境科学与技术*, 2015(011): 038.
- [114] 李波, 蓝文陆, 李天深, 等. 球形棕囊藻赤潮消亡过程环境因子变化及其消亡原因[J]. *生态学杂志*, 2015, 34(05): 1351-1358.
- [115] 肖娟娟, 张金奋, 吴达, 等. 基于克里金法的极地海冰密集度空间插值方法[J]. *大连海事大学学报*, 2023, 49(1): 66-74.
- [116] Le N D, Zidek J V. *Statistical Analysis of Environmental Space-Time Processes*, Springer, New York[M]. 2006: 107-110.
- [117] Hou C, Chu M L, Guzman J A. Risk assessment of harmful algal blooms (HAB) occurrence in the agroecosystem: A hydro-ecologic modeling framework and environmental risk matrix[J]. *Ecological Indicators*, 2022, 145: 109617.
- [118] Chislock M F, Doster E, Zitomer R A, et al. Eutrophication: Causes, consequences, and controls in aquatic ecosystems[J]. *Nature Education Knowledge*. 2013, 4(4): 10.
- [119] 滕筱萱. 有害藻华的发展过程及影响因素[J]. *生物化工*, 2017(5): 98-104.
- [120] Spearman C S. The proof and measurement of association between two things[J]. *The American Journal of Psychology*, 1904, 15(1): 72-101.
- [121] Hauke J, Kossowski T. Comparison of values of Pearson's and Spearman's correlation coefficients on the same sets of data[J]. *Quaestiones Geographicae*, 2011, 30(2): 87-93.
- [122] 赵宇航, 韦钦胜, 辛明, 等. 春末东海北部冷涡区环境特征及藻华成因探讨[J]. *中国环境科学*, 2023, 43(3): 1349-1359.
- [123] Bearon R, Grünbaum D, Cattolico R. Effects of salinity structure on swimming behavior and harmful algal bloom formation in *Heterosigma akashiwo*, a toxic raphidophyte[J]. *Marine Ecology Progress*, 2006, 306: 153-163.
- [124] 王宪, 李文权. 盐度, pH 对海洋藻类光合作用速率的影响[J]. *海洋环境科学*, 1991, 10(1): 37-40.
- [125] Chi L, Jiang K, Ding Y, et al. Uncovering nutrient regeneration, transformation pattern, and its contribution to harmful algal blooms in mariculture waters[J]. *Science of The Total Environment*, 2024, 919: 170652.
- [126] 游亮, 崔莉凤, 刘载文, 等. 藻类生长过程中 DO、pH 与叶绿素相关性分析[J]. *环境科学与技术*, 2007, 30(9): 42-44.
- [127] 胡晓坤, 张清春, 陈振帆, 等. 北部湾海域球形棕囊藻遗传多样性分析[J]. *海洋与湖沼*, 2019, 50(3): 601-610.

- [128] Sin Y, Lee H. Changes in hydrology, water quality, and algal blooms in a freshwater system impounded with engineered structures in a temperate monsoon river estuary[J]. *Journal of Hydrology: Regional Studies*, 2020, 32: 100744.
- [129] Guo J, Wang Y, Lai J, et al. Spatiotemporal distribution of nitrogen biogeochemical processes in the coastal regions of northern Beibu Gulf, south China sea[J]. *Chemosphere*, 2020, 239: 124803.
- [130] Lu J, Garcia A G, Chuang A, et al. Nutrient metrics to compare algal photosynthetic responses to point and non-point sources of nitrogen pollution[J]. *Ecological Indicators*, 2024, 158: 111425.
- [131] Huang Y, Li Z, Sun C, et al. Using the roughness height and manning number in hydrodynamic model to estimate the impact of intensive oyster aquaculture by floating & fixed rafts on water exchange with an application in Qinzhou Bay, China[J]. *Ecological Modeling*, 2023, 476: 110230.
- [132] 周争桥, 夏维. 防城港海域潮流特征分析[J]. *海洋湖沼通报*, 2021, 4: 62-67.
- [133] Li Y, Nwankwegu A S, Huang Y, et al. Evaluating the phytoplankton, nitrate, and ammonium interactions during summer bloom in tributary of a subtropical reservoir[J]. *Journal of Environmental Management*, 2020, 271(1): 110971.
- [134] Zhou J, Lao Y, Song J, et al. Temporal heterogeneity of microbial communities and metabolic activities during a natural algal bloom[J]. *Water Research*, 2024, 183: 116020.
- [135] 齐雨藻. 中国沿海赤潮[M]. 北京: 科学出版社, 2003.
- [136] Breiman L. Random forest[J]. *Machine Learning*, 2001, 45: 5-32.
- [137] 杨凯, 侯艳, 李康. 随机森林变量重要性评分及其研究进展[J]. 2015.
- [138] Oostende N V, Fawcett S E, Marconi D J, et al. Variation of summer phytoplankton community composition and its relationship to nitrate and regenerated nitrogen assimilation across the North Atlantic Ocean[J]. 2017, *Deep Sea Research Part I: Oceanographic Research Papers*, 121: 79-94.
- [139] Boyd C E, Musig Y. Orthophosphate uptake by phytoplankton and sediment[J]. *Aquaculture*, 1981, 22: 165-173.
- [140] Hall R O, Yackulic C B, Kennedy T A, et al. Turbidity, light, temperature, and hydropeaking control primary productivity in the Colorado River, Grand Canyon[J]. *Limnology and Oceanography*, 2015, 60(2): 512-526.
- [141] Li D, Wang B, Jin H, et al. Decoupling of high-resolution surface pH and DO reveals temporal algal bloom dynamics on the East China Sea[J]. *Water Research*, 2024, 261: 122030.
- [142] Seegers B N, Birch J M, Marin R, et al. Subsurface seeding of surface harmful

- algal blooms observed through the integration of autonomous gliders, moored environmental sample processors, and satellite remote sensing in southern California[J]. *Limnology and Oceanography*, 2015, 60(3): 754-764.
- [143] Zhang C, He J, Yao X, et al. Dynamics of phytoplankton and nutrient uptake following dust additions in the northwest Pacific[J]. *Science of the Total Environment*, 2020, 739: 139999.
- [144] Anju M, Valsala V, Smitha B R, et al. Observed denitrification in the northeast Arabian Sea during the winter-spring transition of 2009[J]. *Journal of Marine Systems*, 2022, 227: 103680.
- [145] Li H, Kim H, Shin K, et al. Effects of temperature and light on the growth and reproduction of an endophytic pest alga *Ectocarpus siliculosus* (Ectocarpales) found in wild *Gracilaria textorii* (Gracilariales) [J]. *Aquaculture*, 2022, 560: 738526.
- [146] Gao S, Waller P, Khawam G, et al. Incorporation of salinity, nitrogen, and shading stress factors into the Huesemann Algae Biomass Growth model[J]. *Algal Research*, 2018, 35: 462-470.
- [147] Wu Z, Li Q, Rivkin R B, et al. Role of diatom-derived oxylipins in organic phosphorus recycling during coastal diatom blooms in the northern South China Sea[J]. *Science of the Total Environment*, 2023, 903: 166518.
- [148] Conley D J, Paerl H W, Howarth R W, et al. Ecology Controlling Eutrophication: Nitrogen and Phosphorus[J]. *Science*, 2009, 323(5917): 1014-1015.
- [149] Yao Y, Li D, Chen Y, et al. High-resolution distribution of internal phosphorus release by the influence of harmful algal blooms (HABs) in Lake Taihu[J]. 2021, *Environmental Research*, 201: 111525.
- [150] Oh H M, Rhee G Y. A comparative study of microalgae isolated from flooded rice paddies: light-limited growth, C fixation, growth efficiency and relative N and P requirement[J]. *Journal of Applied Phycology*, 1991, 3(3): 211-220.
- [151] Luhede A, Freund J A, Dajka J C, et al. The value of information in predicting harmful algal blooms[J]. *Journal of Environmental Management*, 2025, 373: 123288.
- [152] El-Hamid H T A, Reda R, Zarzoura F, Integrated approach of remote sensing and machine learning to simulate and predict petroleum pollution and algal blooms along Aqaba Gulf[J]. *Biocatalysis and Agricultural Biotechnology*, 2022, 46: 102528.
- [153] 罗金福, 李天深, 蓝文陆. 北部湾海域赤潮演变趋势及防控思路[J]. *环境保护*, 2016, 44(20): 3.
- [154] Ai H, Zhang K, Sun J, et al. Short-term Lake Erie algal bloom prediction by

- p>classification and regression models[J]. Water Research, 2023, 232: 119710.
- [155] 郭皓, 林凤翱, 刘永健, 等. 近年来我国海域多发性赤潮生物种类以及赤潮风险指数分级预警方法[J]. 海洋环境科学, 2014, 33(1): 94-98.
- [156] He X, Bai Y, Pan D, et al. Satellite views of the seasonal and interannual variability of phytoplankton blooms in the eastern China seas over the past 14 yr (1998-2011)[J]. Biogeosciences, 2013, 10: 4721-4739.
- [157] 袁翔宇, 张蓬鹤, 熊素琴, 等. 基于逻辑回归算法的异常用电辨识方法研究[J]. 电测与仪表, 2021, 58(12): 81-87.
- [158] Stoltzfus J C. Logistic Regression: a brief primer[J]. Academic Emergency Medicine, 2011, 18(10): 1099-1104.
- [159] Xu S, Xiao Y, Xu Y, et al. Effects of seasonal variations and environmental factors on phytoplankton community structure and abundance in Beibu Gulf, China[J]. Ocean and Coastal Management, 2024, 248: 106982.
- [160] Kasan N, Yusof S, Manan H, et al. Inhibitory effect of thiourea derivatives on the growth of blue-green algae[J]. Journal of Environmental Management, 2021, 294: 113008.
- [161] 丁建清, 张军毅. YSI6600 传感器在太湖蓝藻预警工作中的应用[J]. 环境监测管理与技术, 2011, 023(001): 67-70.
- [162] 齐雨藻, 吕颂辉, 欧林坚. 南海赤潮的生物学特征[C]. 中国海洋湖沼学会藻类学分会. 呼和浩特: 中国海洋湖沼学会藻类学分会第七届会员大会暨第十四次学术讨论会论文摘要集, 2007: X55.
- [163] 梁松, 钱宏林, 齐雨藻. 中国沿海的赤潮问题[J]. 生态科学, 2000, 19(4): 44-50.
- [164] 孙荣恒. 应用数理统计 (第三版) [M]. 北京: 科学出版社, 2014: 204-206.
- [165] Egge J K, Aksnes D L. Silicate as regulating nutrient in phytoplankton competition[J]. Marine Ecology Progress Series, 1992, 83: 281-289.
- [166] Guallar C, Chapelle A, Bacher C. Realised niche and suitability index highlight spatial and temporal distribution of toxic phytoplankton species[J]. Marine Ecology Progress Series, 2020, 662: 15-34.
- [167] Xu N, Huang B, Hu Z, et al. Effects of temperature, salinity, and irradiance on the growth of harmful algal bloom species *Phaeocystis globosa* Scherffel (Prymnesiophyceae) isolated from the South China Sea[J]. Chinese Journal of Oceanology and Limnology, 2017, 35: 557-565.
- [168] 孙军. 夏季北部湾的浮游植物群落[J]. 海洋湖沼通报, 2011, 3: 1-7.
- [169] Zhang T, Zhang C, Chen Y, et al. Rapid monitoring and early warning of *Phaeocystis globosa* bloom based on an effective electrochemical biosensor[J]. Biochemical Engineering Journal, 2024, 210: 10944.
- [170] 王西艳, 薛玥, 孟不凡, 等. 球形棕囊藻 (*Phaeocystis globosa* Scherffel)

- 细胞形态转变及转录组比较研究[J/OL]. 热带海洋学报, 2024, 43(05): 49-57.
- [171] 胡鸿钧, 魏印心. 中国淡水藻类——系统分类及生态[M]. 北京: 科学出版社, 2006.
- [172] Malin D. Darkfield Illumination[M]. Boston: The Focal Encyclopedia of Photography (Fourth Edition), 2007: 526-527.
- [173] Jörg Haus. Darkfield Microscopy with HighPower LED Illumination[J]. Optik & Photonik, 2015, 10(1): 29-31.
- [174] Li Y, Li D, Gao Z, et al. Underwater image enhancement utilizing adaptive color correction and model conversion for dehazing[J]. Optics and Laser Technology, 2024, 169: 110039.
- [175] 王新伟, 孙亮, 王敏敏, 等. 水下二维及三维距离选通成像去噪技术研究[J]. 红外与激光工程, 2020, 49(2): 27-37.
- [176] Wang Y, Song W, Fortino G, et al. An experimental-based review of image enhancement and image restoration methods for underwater imaging[J]. IEEE Access, 2019, 7: 140233-140251.
- [177] Ji T L, Sundareshan M K, Roehrig H. Adaptive image contrast enhancement based on human visual properties[J]. IEEE Transactions on Medical Imaging, 1994, 13(4): 573-586.
- [178] Goyal S, Baghla S. Region growing Adaptive Contrast Enhancement of Medical MRI Images[J]. Journal of Global Research in Computer Science, 2011, 2(7): 93-95.
- [179] Redmon J, Divvala S, Girshick R, et al. You only look once: unified, realtime object detection[C]. 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Las Vegas: Institute of Electrical and Electronics Engineers, 2016: 779-788.
- [180] Lima B P, Borges L, Hirose E, et al. A lightweight and enhanced model for detecting the Neotropical brown stink bug, *Euschistus heros* (Hemiptera: Pentatomidae) based on YOLOv8 for soybean fields[J]. Ecological Informatics, 2024, 80: 102543.
- [181] Zhou Y, Zhu W, He Y, et al. YOLOv8-based spatial target part recognition[J]. 2023 IEEE 3rd International Conference on Information Technology, Big Data and Artificial Intelligence, 2023, 3: 1684-1687.
- [182] Ma B, Hua Z, Wen Y, et al. Using an improved lightweight YOLOv8 model for real-time detection of multi-stage apple fruit in complex orchard environments[J]. Artificial Intelligence in Agriculture, 2024, 11: 70-82.
- [183] 王春梅, 刘欢. YOLOv8-VSC: 一种轻量级的带钢表面缺陷检测算法[J]. 计算机科学与探索, 2024, 18(1): 151-160.
- [184] 赵晓霞, 王汝琳. 改进的多尺度 Retinex 算法及其应用[J]. 计算机工程,

- 2011, 37(6): 209-211.
- [185] Jobson D J, Rahman Z, Woodell G A. Properties and Performance of a Center/Surround Retinex[J]. IEEE International Conference on Image Processing, 1997, 6(3): 451-462.
- [186] 王超, 孙玉秋, 徐石瑶, 等. 自适应直方图均衡化图像增强算法研究[J]. 长江大学学报: 自然科学版, 2018, 15(1): 55-59.
- [187] 尚晋, 杨有, 李晓虹. 一种改进的自适应直方图均衡化增强档案图像的方法[J]. 计算机科学, 2007, 34(5): 237-239.
- [188] 杨宁, 苏海冰, 张涛. 自适应水下图像增强算法[J]. 激光与光电子学进展, 2024, 61(8): 0837001.
- [189] Guo Y, Li H, Zhuang P. Underwater Image Enhancement Using a Multiscale Dense Generative Adversarial Network[J]. IEEE Journal of Oceanic Engineering, 2019, 45(3): 862-870.
- [190] He K, Sun J, Tang X. Single Image Haze Removal Using Dark Channel Prior[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2011, 33(12): 1956-1963.
- [191] Levin A, Lischinski D, Weiss Y. A Closed Form Solution to Natural Image Matting[J]. IEEE Computer Society, 2006, 1: 61-68.

附录

附录 A 补充列表

表 A-2 YSI 6600 型多参数水质仪质检参数

传感器	测量范围	准确度	响应时间	分辨率
叶绿素 a 浓度	0—400 $\mu\text{g}\cdot\text{L}^{-1}$	线性: $R^2 > 0.999$ 检出限: $0.09 \mu\text{g}\cdot\text{L}^{-1}$	T63 < 2s	$0.01 \mu\text{g}\cdot\text{L}^{-1}$
水温	-5—50 $^{\circ}\text{C}$	-5—35 $^{\circ}\text{C}$: $\pm 0.01 ^{\circ}\text{C}$ 35—50 $^{\circ}\text{C}$: $\pm 0.05 ^{\circ}\text{C}$	T63 < 1s	$0.001 ^{\circ}\text{C}$
盐度	0—70 psu	± 0.1 psu	T63 < 2s	0.01 psu
溶解氧	0—50 $\text{mg}\cdot\text{L}^{-1}$	0—20 $\text{mg}\cdot\text{L}^{-1}$: $\pm 0.1 \text{mg}\cdot\text{L}^{-1}$ 20—50 $\text{mg}\cdot\text{L}^{-1}$: $\pm 0.5 \text{mg}\cdot\text{L}^{-1}$	T63 < 5s	$0.01 \text{mg}\cdot\text{L}^{-1}$
pH	0—14	± 0.1 , 校准温度 $\pm 10 ^{\circ}\text{C}$ ± 0.1 , 全温度量程	T63 < 3s	0.01
浊度	0—4000 FNU 1 FNU=1.3 NTU	0—999 FNU: 0.3 FNU 1000—4000 FNU: 0.8 FNU	T63 < 2s	0.01 FNU
蓝绿藻- 藻蓝蛋白	0—280 $\text{cells}\cdot\mu\text{L}^{-1}$	线性: $R^2 > 0.999$ 检出限: $0.22 \text{cells}\cdot\mu\text{L}^{-1}$	T63 < 2s	$0.001 \text{cells}\cdot\mu\text{L}^{-1}$

表 A-2 2013 年与 2014 年重点监测区域叶绿素 a 浓度与其他环境要素的相关系数 (角标信息

同图 2-10)

年份	测站点	硝氮	活性磷酸盐	水温	盐度	溶解氧	pH	浊度
2013	GX03	-0.218***	-0.212***	0.255***	-0.413***	0.271***	0.452***	0.057**
	GX04	0.156***	-0.026	0.333***	-0.568***	-0.139***	-0.419***	0.492***
	GX06	-0.19***	-0.01	0.094***	0.105***	0.316***	0.524***	0.004
	GX09	-0.1***	-0.114***	0.263***	-0.097***	0.135***	0.381***	0.099***
	GX10	0.12***	-0.076**	0.242***	-0.162***	0.273***	0.292***	0.045
	GX12	-0.26***	-0.198***	0.248***	0.111***	0.147***	0.297***	-0.056**
2014	GX03	0.243***	0.259***	0.283***	0.218***	0.175***	0.031	0.136***
	GX04	-0.249***	-0.108***	-0.02	-0.236***	0.193***	0.035	0.092***
	GX06	0.003	0.127***	0.298***	-0.057*	0.139***	0.194***	0.077**
	GX09	-0.211***	0.174***	0.363***	-0.011	-0.005	0.21***	0.198***
	GX10	0.01	-0.15***	0.104***	-0.105***	0.244***	0.199***	0.173***
	GX12	0.001	-0.03	-0.006	0.103***	-0.118***	0.264***	0.365***

附录 B YOLOv8 模型训练与测试结果




图 B01 YOLOv8 目标检测模型训练结果中的 F1-置信度曲线




图 B02 YOLOv8 目标检测模型训练结果中的精确率-置信度曲线




图 B03 YOLOv8 目标检测模型训练结果中的召回率-置信度曲线




图 B04 YOLOv8 目标检测模型训练结果中的精确率-召回率曲线




图 B05 YOLOv8 目标检测模型对拍摄的球形棕囊藻藻液原始图像（测试集）的目标检测结果




图 B06 YOLOv8 目标检测模型对拍摄的对照水样原始图像（测试集）的目标检测结果




图 B07 YOLOv8 目标检测模型对拍摄的混合水样原始图像（测试集）的目标检测结果




图 B10 YOLOv8 目标检测模型对拍摄的混合水样自适应色阶对比度图像（测试集）的目标检测结果



图 B11 YOLOv8 目标检测模型对拍摄的球形棕囊藻藻液自适应色阶对比度+暗通道去散射图像（测试集）的目标检测结果

发表论文和参加科研情况说明

发表论文与专利：

- [1] Ecological Indicators, 2023, 第一作者.
- [2] Science of the Total Environment, 2024, 第一作者.
- [3] Applied Optics, 2025, 第一作者.
- [4] 中国发明专利（已公开），2024，指导老师第一发明人，本人第二发明人.

致谢

因校盲审要求隐去此部分。